UNIVERSIDADE FEDERAL DE JUIZ DE FORA
PROGRAMA DE PÓS-GRADUAÇÃO EM MODELAGEM COMPUTACIONAL

Maicom Peters Xavier

Reprodução dos Níveis de Anticorpos Após Cinco Regimes Distintos de Vacinação com ChAdOx1 nCoV-19 por Meio de Coortes Virtuais de Indivíduos

Juiz de Fora

2026

Maicom Peters Xavier

Reprodução dos Níveis de Anticorpos Após Cinco Regimes Distintos de Vacinação com ChAdOx1 nCoV-19 por Meio de Coortes Virtuais de Indivíduos

Tese apresentada ao Programa de Pós-graduação em Modelagem Computacional da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de Doutor em Modelagem Matemática. Área de concentração: Interdisciplinar.

Orientador: Prof. Dr. Marcelo Lobosco

Coorientador: Prof. Dr. Rodrigo Weber dos Santos

Juiz de Fora

2026

Ficha catalográfica elaborada através do Modelo Latex do CDC da UFJF
com os dados fornecidos pelo(a) autor(a)

Xavier, Maicom P..
Reprodução dos Níveis de Anticorpos Após Cinco Regimes Distintos de Vacinação com ChAdOx1 nCoV-19 por Meio de Coortes Virtuais de Indivíduos / Maicom Peters Xavier. – 2026.
111 f. : il.

Orientador: Marcelo Lobosco
Coorientador: Rodrigo Weber dos Santos
Tese (Doutorado) – Universidade Federal de Juiz de Fora, . Programa de Pós-graduação em Modelagem Computacional, 2026.

1. Modelagem Computacional. 2. Sistema imune. 3. Vacina COVID-19. 4. Equações diferenciais ordinárias. I. Lobosco, Marcelo, orient. II. dos Santos, Rodrigo Weber, coorient. III. Xavier, Maicom Peters. IV. Título.

Maicom Peters Xavier

Reprodução dos Níveis de Anticorpos Após Cinco Regimes Distintos de Vacinação com ChAdOx1 nCoV-19 por Meio de Coortes Virtuais de Indivíduos

Tese apresentada ao Programa de Pós-graduação em Modelagem Computacional da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de Doutor em Modelagem Matemática. Área de concentração: Interdisciplinar.

Aprovada em XX de abril de 2026

BANCA EXAMINADORA

Professor Dr. Alexandre Bittencourt Pigozzo
Universidade Federal de São João Del-Rei

Professor Dr. Bernardo Martins Rocha
Universidade Federal de Juiz de Fora

Professora Dra. Carla Rezende Barbosa Bonin
IF Sudeste MG - Campus Avançado Cataguases

Professor Dr. Helton da Costa Santiago
Universidade Federal de Minas Gerais

Professor Dr. Marcelo Lobosco - Orientador
Universidade Federal de Juiz de Fora

AGRADECIMENTOS

A lista de agradecimentos poderia se estender por muitas páginas, contemplando todos que fizeram parte dessa caminhada. Como isso não é viável, destaco aqui aqueles que foram fundamentais ao longo do percurso.

Agradeço, primeiramente, aos meus pais, Antônio e Cláudia, por me educarem e cuidarem de mim em todas as fases da minha vida — inclusive atualmente. Vocês são os maiores presentes que eu poderia receber, e espero conseguir retribuir todo esse amor.

Ao meu irmão, Micael, por ser uma inspiração tanto no âmbito pessoal quanto profissional, e por ter me incentivado a me aventurar pelos caminhos da Modelagem Computacional, abrindo portas para que eu me desenvolvesse em diferentes frentes.

À minha cunhada, Laís, por ser uma irmã para mim, pelo apoio constante às minhas escolhas e por estar sempre disposta a me ouvir e aconselhar nos momentos em que precisei.

À minha namorada, Alice, pela companhia constante e pelo incentivo em todos os projetos que me proponho a realizar, fazendo-se presente em todas as minhas escolhas, seja em viagens planejadas ou de última hora, seja nas conversas diárias que encurtam a distância física e fortalecem ainda mais o nosso laço.

Aos meus primos, André e Escobar, por serem amigos presentes em diversos momentos e por saber que posso sempre contar com vocês.

Aos velhos e novos amigos que fiz ao longo da vida e que faço questão de manter por perto.

Aos meus orientadores, Rodrigo e Lobosco. Ao Rodrigo, por suas ideias, muitas vezes ousadas/malucas, que sempre impulsionaram a pesquisa e contribuíram para o meu crescimento. Ao Lobosco, por toda a paciência, apoio incondicional, dedicação para que o trabalho nunca estagnasse e pelo acolhimento ao longo desses anos, desde o mestrado até o doutorado.

Ao Programa de Pós-Graduação em Modelagem Computacional da UFJF, por proporcionar um ambiente de aprendizado e troca, com professores, pesquisadores e colegas que contribuíram significativamente para a minha formação.

A todos, o meu muito obrigado!

"Science is a way of thinking much more than it is a body of knowledge."
"A ciência é muito mais uma forma de pensar do que um conjunto de conhecimentos."

Carl Sagan

RESUMO

Este estudo investiga a resposta imune induzida pela vacina ChAdOx1 nCoV-19, abrangendo tanto a imunização primária quanto as doses de reforço. Um modelo matemático foi desenvolvido para simular a dinâmica imunológica sob diferentes esquemas vacinais e calibrado com dados clínicos provenientes de coorte. Para aumentar a robustez das análises, foi construída uma Coorte Virtual (CV) composta por mais de 16.000 indivíduos, gerada a partir da amostragem de conjuntos de parâmetros biologicamente plausíveis capazes de reproduzir as trajetórias observadas de anticorpos. Ensaios *in silico* foram realizados para avaliar cinco cenários de vacinação em adultos (18 a 55 anos), incluindo regimes de duas doses e estratégias de reforço administradas entre 8–12, 15–25 e 44–45 semanas, além de um regime com terceira dose adicional. Adicionalmente, foram conduzidas simulações exploratórias com variação sistemática do intervalo entre doses, com o objetivo de identificar regimes que maximizem a duração e a magnitude da resposta imune. As previsões do modelo foram comparadas com dados longitudinais de uma coorte acompanhada por um ano após o reforço, apresentando boa concordância com a cinética observada de anticorpos. A análise da CV permitiu identificar intervalos de dose associados a respostas imunes mais duradouras em regimes de duas e três doses. Esses resultados destacam o potencial da modelagem computacional, aliada ao uso de populações virtuais, como ferramenta para apoiar o planejamento de estratégias vacinais. Adicionalmente, simulações envolvendo doses fracionadas sugerem respostas imunes comparáveis às obtidas com a dose padrão, em concordância com evidências reportadas na literatura.

Palavras-chave: Modelagem matemática da vacinação; ChAdOx1 nCoV-19; Simulação de coortes virtuais; Otimização do intervalo entre doses.

ABSTRACT

This study investigates the immune response induced by the ChAdOx1 nCoV-19 vaccine, encompassing both primary immunization and booster doses. A mathematical model was developed to simulate the immune dynamics under different vaccination regimens and calibrated using clinical cohort data. To enhance the robustness of the analyses, a Virtual Cohort (VC) comprising more than 16,000 individuals was constructed by sampling biologically plausible parameter sets capable of reproducing the observed antibody trajectories. In silico experiments were conducted to evaluate five vaccination scenarios in adults (18–55 years), including two-dose regimens and booster strategies administered at intervals of 8–12, 15–25, and 44–45 weeks, as well as a three-dose regimen. Additionally, exploratory simulations were performed with systematic variation of the inter-dose interval to identify schedules that maximize both the magnitude and duration of the immune response. Model predictions were compared with longitudinal data from a cohort followed for one year after booster administration, showing good agreement with the observed antibody kinetics. The analysis of the VC enabled the identification of dosing intervals associated with more sustained immune responses in both two- and three-dose regimens. These findings highlight the potential of computational modeling, combined with virtual populations, as a tool to support the design of vaccination strategies. Furthermore, simulations involving fractional dosing suggest immune responses comparable to those obtained with the standard dose, in agreement with evidence reported in the literature.

Keywords: Mathematical modeling of vaccination; ChAdOx1 nCoV-19; Virtual cohort simulation; Dose interval optimization.

LISTA DE ILUSTRAÇÕES

Principais eventos iniciais da pandemia de COVID-19 15
Distribuição global de casos confirmados de COVID-19 por regiões da OMS 16
Principais medidas não farmacológicas de profilaxia contra a COVID-19 18
Células essenciais do sistema imune inato. 27
Ativação de linfócitos T no sistema imune adaptativo. 29
Ativação de linfócitos B e diferenciação celular após estímulo vacinal. 30
Estrutura básica de um anticorpo. 31
Estrutura do SARS-CoV-2 e processo simplificado da infecção celular. 33
Estrutura da proteína *spike* do SARS-CoV-2. 34
Escalas de disseminação de doenças infecciosas 38
Principais plataformas vacinais contra a COVID-19 39
Comparação entre coortes virtuais e gêmeos digitais. 41
Fluxograma do Modelo. 43
Simulando 2.000 observações da Coorte Virtual do modelo calibrado. 56
Níveis de anticorpos do modelo calibrado para segunda dose no dia 63. 57
Diagrama com as interações entre as 11 populações do modelo. 64
Dinâmica das 11 populações do modelo simulando 500 dias. 66
Análise dos índices de Sobol de primeira ordem para o cenário de três doses do modelo, considerando a segunda dose no dia 98 e a terceira no dia 308. 68
Análise dos índices de Sobol de ordem total para o cenário de três doses do modelo, considerando a segunda dose no dia 98 e a terceira no dia 308. 69
Quantificação de incertezas para o modelo com duas doses, considerando a segunda dose no dia 63. 71
Quantificação de incertezas para o modelo com duas doses, considerando a segunda dose no dia 69. 72
Quantificação de incertezas para o modelo com duas doses, considerando a segunda dose no dia 114. 73
Quantificação de incertezas para o modelo com duas doses, considerando a segunda dose no dia 313. 74
Quantificação de incertezas para o modelo com três doses, considerando a segunda dose no dia 98 e a terceira no dia 308. 75
Regime de dosagem otimizado para duas doses da ChAdOx1 nCoV-19. 77
Análise de sensibilidade do limiar de proteção para o regime de duas doses da ChAdOx1 nCoV-19. 78
Regime de dosagem otimizado para três doses da ChAdOx1 nCoV-19. 79
Análise de sensibilidade do limiar de proteção para o regime de três doses da ChAdOx1 nCoV-19. 80

Comparação do modelo para diferentes cenários de doses fracionadas da vacina: DP/DP versus MD/MD. 82
Comparação do modelo para diferentes cenários de doses fracionadas da vacina: DP/DP versus MD/DP. 84
Comparação do modelo para diferentes cenários de doses fracionadas da vacina: DP/DP versus DP/MD. 85
Níveis de anticorpos do modelo para regime de duas doses com acompanhamento superior a um ano utilizando parâmetros calibrados no cenário de 8 a 12 semanas. 99
Níveis de anticorpos do modelo para regime de duas doses com intervalo de 15 a 25 semanas utilizando parâmetros calibrados no cenário de 8 a 12 semanas. 100
Níveis de anticorpos do modelo para regime de duas doses com intervalo de 44 a 45 semanas utilizando parâmetros calibrados no cenário de 8 a 12 semanas. 100
Níveis de anticorpos do modelo para regime de três doses utilizando parâmetros calibrados no cenário de 8 a 12 semanas. 101
Simulando 2.000 observações da Coorte Virtual para o regime de duas doses com acompanhamento superior a um ano. 101
Simulando 2.000 observações da Coorte Virtual para o regime de duas doses com intervalo de 15 a 25 semanas. 102
Simulando 2.000 observações da Coorte Virtual para o regime de duas doses com intervalo de 44 a 45 semanas. 102
Simulando 2.000 observações da Coorte Virtual para o regime de três doses. 103
Análise dos índices de Sobol de primeira ordem para o cenário de duas doses do modelo, considerando a segunda dose no dia 63. 104
Análise dos índices de Sobol de ordem total para o cenário de três doses do modelo, considerando a segunda dose no dia 98 e a terceira no dia 308. 105
Análise dos índices de Sobol de primeira ordem para o cenário de duas doses do modelo, considerando a segunda dose no dia 69. 106
Análise dos índices de Sobol de ordem total para o cenário de duas doses do modelo, considerando a segunda dose no dia 69. 107
Análise dos índices de Sobol de primeira ordem para o cenário de duas doses do modelo, considerando a segunda dose no dia 114. 108
Análise dos índices de Sobol de ordem total para o cenário de duas doses do modelo, considerando a segunda dose no dia 114. 109
Análise dos índices de Sobol de primeira ordem para o cenário de duas doses do modelo, considerando a segunda dose no dia 313. 110
Análise dos índices de Sobol de ordem total para o cenário de duas doses do modelo, considerando a segunda dose no dia 313. 111

LISTA DE TABELAS

Tabela 1 – Síntese de casos, óbitos, incidência e mortalidade por COVID-19 no Brasil e regiões 16
Tabela 2 – Configuração do algoritmo de Evolução Diferencial (ED) para calibração do modelo. 54
Tabela 3 – Erros relativos e valores de RMSE comparando as simulações do modelo com os dados de IgG da coorte em diferentes cenários de vacinação. 55
Tabela 4 – Valores de base, parâmetros calibrados e valores iniciais do modelo. . . 58
Tabela 5 – Níveis de anticorpos IgG (GMT) 28 dias após a 2ª dose (intervalo > 12 semanas). 87

LISTA DE ABREVIATURAS E SIGLAS

ADCC	*Antibody-Dependent Cellular Cytotoxicity* - Citotoxicidade Celular Dependente de Anticorpos
APCs	*Antigen Presenting Cells* - Células Apresentadoras de Antígeno
BCRs	*B Cells Receptors* - Receptores de Células B
ChAdOx1	*Chimpanzee Adenovirus Oxford* 1
COVID-19	*Coronavirus Disease* 2019
CV	Coorte Virtual
DP	Dose Padrão - (5×10^{10} partículas/ml)
ELISA	*Enzyme-linked Immunosorbent Assay* - Ensaio Imunoenzimático
GMT	*Geometric Mean Titer* - Média Geométrica de Títulos de Anticorpos
IgG	Imunoglobulina do tipo G
MD	Meia Dose ($2,5 \times 10^{10}$ partículas/ml)
nCoV-19	*novel Coronavirus* 2019
OMS	Organização Mundial da Saúde
PBMCs	*Peripheral Blood Mononuclear Cells* - Células Mononucleares do Sangue Periférico
PFF2/PFF3	Peça Facial Filtrante nível 2 ou nível 3
RMSE	*Root Mean Square Error* - Raiz do Erro Quadrático Médio
SARS-CoV-2	*Severe Acute Respiratory Syndrome Coronavirus* 2
SDRA	Síndrome do Desconforto Respiratório Agudo
SFUs	*Spot Forming Units* - Unidades Formadoras de Pontos
TPS	Tempo de Proteção Sustentada
UQ	*Uncertainty Quantification* - Quantificação de Incertezas
WHO	*World Health Organization*

SUMÁRIO

1 Introdução 14
1.1 Motivação 14
1.2 Vacina ChAdOx1 nCoV-19 (AZD1222) 18
1.3 Revisão da Literatura 21
1.4 Objetivos e Hipótese de Pesquisa 23
1.5 Organização 24
2 Fundamentação Teórica 26
2.1 Sistema Imune Humano - SIH 26
2.1.1 Fundamentos do Sistema Imunológico 26
2.1.2 Dinâmica dos Linfócitos B 29
2.1.3 Estrutura e Função dos Anticorpos 31
2.2 *Coronavirus Disease 2019* - COVID-19 32
2.2.1 Aspectos Clínicos 35
2.2.2 Aspectos Epidemiológicos 37
2.2.3 Vacinas contra a COVID-19 39
2.3 Coortes Virtuais 41
3 Métodos 43
3.1 Dados da Coorte e Sua Adaptação Para Uso nas Simulações 44
3.2 Modelo Matemático 45
3.2.1 Hipóteses e Simplificações Adotadas pelo Modelo Matemático 46
3.2.2 Dinâmica Viral e da Proteína *Spike* 48
3.2.3 Ativação das Células Apresentadoras de Antígenos 49
3.2.4 Dinâmica das Células T e B 50
3.2.5 Produção de Anticorpos 52
3.3 Calibração do Modelo e Geração da Coorte Virtual 53
3.3.1 Suporte da Literatura para os Parâmetros do Modelo 59
3.4 Análise de Sensibilidade e Quantificação de Incertezas 60
3.4.1 Implementação Computacional 62
4 Resultados Computacionais 64
4.1 Identificação dos Parâmetros Mais Sensíveis do Modelo 67
4.2 Quantificação de Incertezas - UQ 70
4.3 Otimização do Intervalo Entre Doses 75
4.4 Limitações do Modelo 81
5 Discussão 86
6 Considerações Finais 89
REFERÊNCIAS 91

A APÊNDICE A – Simulações adicionais para diferentes intervalos entre doses: modelo calibrado e Coorte Virtual 99
B APÊNDICE B – Resultados adicionais da análise de sensibilidade de Sobol 104

1 Introdução

1.1 Motivação

A pandemia de COVID-19, causada pelo vírus SARS-CoV-2 (*Severe Acute Respiratory Syndrome Coronavirus 2*), representou um dos maiores desafios sanitários do século XXI, produzindo impactos profundos e duradouros nos sistemas de saúde, na economia e na dinâmica social em escala global. Desde os primeiros registros da doença no final de 2019, observou-se uma elevada taxa de transmissão associada a manifestações clínicas heterogêneas, que variam desde infecções assintomáticas até quadros graves caracterizados por pneumonia viral, síndrome do desconforto respiratório agudo (SDRA) e falência de múltiplos órgãos, resultando em elevada mortalidade, especialmente em populações vulneráveis, incluindo idosos, indivíduos com comorbidades e pessoas com maior risco imunológico ou menor acesso à assistência em saúde. Diante da rápida disseminação internacional e do aumento exponencial de casos, a Organização Mundial da Saúde (OMS) declarou, em janeiro de 2020, a COVID-19 como uma emergência de saúde pública de interesse internacional, reconhecendo o potencial da doença em sobrecarregar sistemas de saúde e gerar consequências globais severas (World Health Organization, 2020; YANG *et al.*, 2020).

Os primeiros casos da doença posteriormente denominada COVID-19 foram identificados e notificados em dezembro de 2019 na cidade de Wuhan, província de Hubei, na China, inicialmente associados a um agrupamento de pneumonias de etiologia desconhecida. Em janeiro de 2020, a rápida propagação do agente infeccioso, tanto no território chinês quanto internacionalmente, levou à implementação de medidas sanitárias rigorosas, incluindo isolamento social, restrições de mobilidade e intensificação da vigilância epidemiológica (World Health Organization, 2020). A Figura 1 ilustra a sequência dos principais eventos associados à emergência e disseminação inicial da COVID-19.

Apesar desses esforços iniciais, a elevada transmissibilidade do vírus resultou em sua disseminação global em poucas semanas, culminando no reconhecimento da COVID-19 como uma pandemia pela Organização Mundial da Saúde (OMS) em 11 de março de 2020 (World Health Organization, 2020; HU *et al.*, 2021; HUANG *et al.*, 2020; ZHOU *et al.*, 2020; LI *et al.*, 2020).

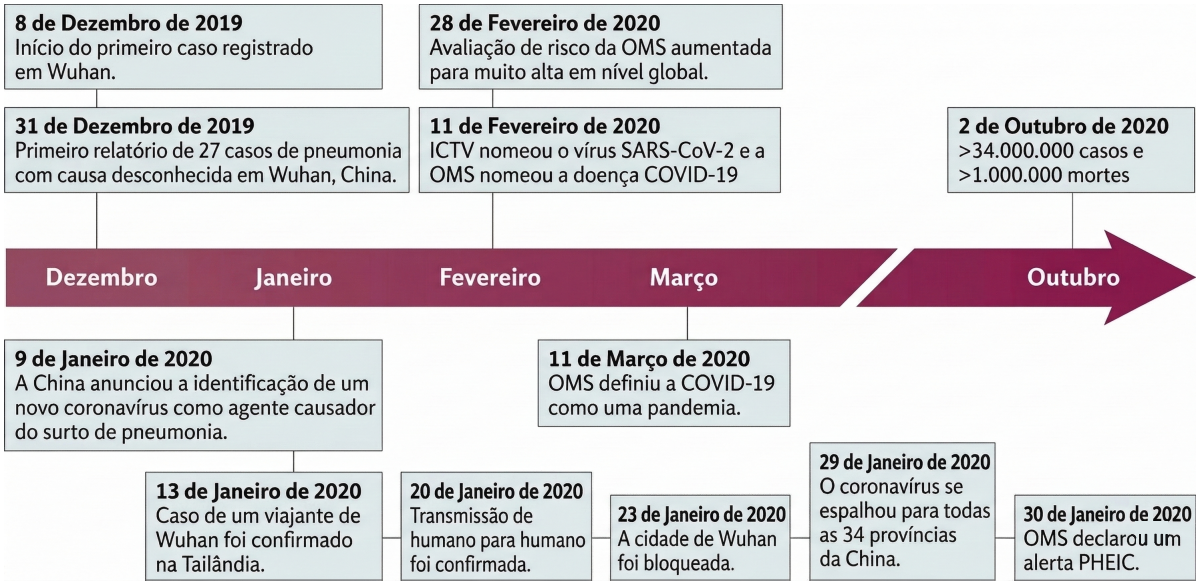

Figura 1: – Linha do tempo dos principais eventos associados ao surgimento e à disseminação inicial da COVID-19, desde os primeiros casos de pneumonia de causa desconhecida identificados em Wuhan, China, em dezembro de 2019, até a caracterização da doença como pandemia pela Organização Mundial da Saúde (OMS) em 11 de março de 2020 e a rápida expansão global observada nos meses seguintes. Destacam-se eventos relevantes, como a identificação do novo coronavírus pela China, a confirmação da transmissão entre humanos, a designação do vírus SARS-CoV-2 pelo *International Committee on Taxonomy of Viruses*[1] e a declaração de Emergência de Saúde Pública de Importância Internacional (*Public Health Emergency of International Concern*) pela OMS. Figura adaptada de HU *et al.* (2021).

No contexto brasileiro, a pandemia de COVID-19 assumiu proporções particularmente severas, refletindo desafios estruturais, sociais e sanitários pré-existentes. Desde a confirmação do primeiro caso no país, em fevereiro de 2020, o Brasil passou a figurar entre as nações mais impactadas pela doença, tanto em número de casos quanto em mortalidade. De acordo com dados consolidados das autoridades de saúde e da OMS, até o encerramento do estado de emergência sanitária global, o Brasil registrou mais de 39 milhões de casos confirmados e mais de 700 mil óbitos associados à COVID-19 (Ministério da Saúde (Brasil), 2020–2025), enquanto, em escala global, os números ultrapassaram 770 milhões de casos confirmados, com mais de 7 milhões de mortes (World Health Organization, 2026). A distribuição global desses casos, bem como a posição do Brasil nesse cenário, pode ser observada na Figura 2, que ilustra a concentração de casos por região da Organização Mundial da Saúde.

Esses valores evidenciam o impacto expressivo da pandemia no país e reforçam a relevância de estratégias de vigilância, vacinação e análise quantitativa para a compreensão da dinâmica da doença e da resposta imune em diferentes contextos populacionais.

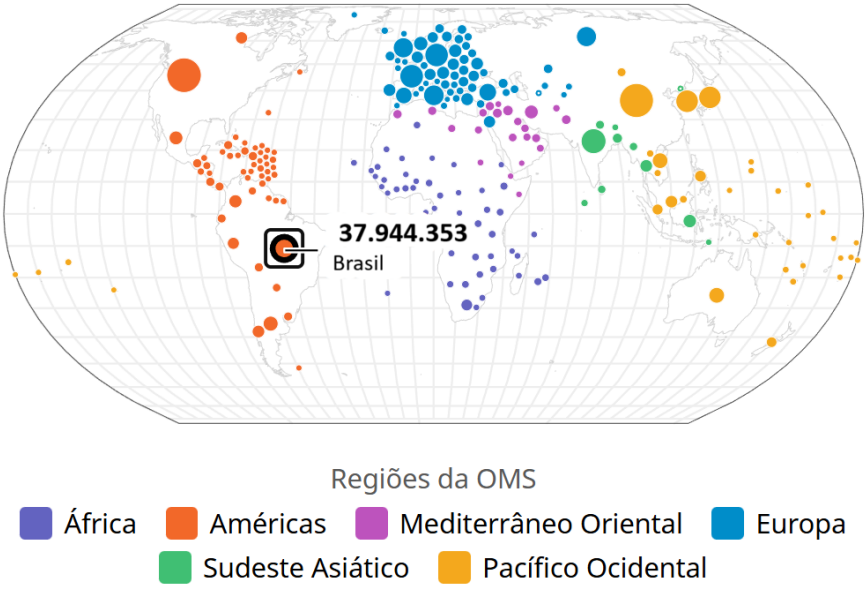

Figura 2: – Mapa mundial ilustrando a distribuição dos casos confirmados de COVID-19 por país. Os círculos representam o número acumulado de casos (com tamanho proporcional), enquanto as cores indicam as regiões da OMS. Destaca-se o Brasil, com 37.944.353 casos confirmados registrados até 24 de janeiro de 2026. Figura e dados obtidos do painel de monitoramento da COVID-19 da Organização Mundial da Saúde (World Health Organization (2026)).

De acordo com dados do Ministério da Saúde do Brasil, apresentados na Tabela 1, observa-se que a região Sudeste concentrou os maiores números absolutos de casos confirmados e óbitos por COVID-19. Entretanto, quando considerados os indicadores relativos à população, como incidência e mortalidade por 100 mil habitantes, destacam-se as regiões Centro-Oeste e Sul, evidenciando diferenças regionais importantes na dinâmica da pandemia.

Tabela 1 – Síntese de casos, óbitos, incidência e mortalidade por COVID-19 no Brasil e regiões

Região	**Casos**	**Óbitos**	**Incidência (por 100 mil hab.)**	**Mortalidade (por 100 mil hab.)**
Brasil	39.318.227	716.626	18.709,9	341,0
Sudeste	15.738.754	346.149	17.809,8	391,7
Nordeste	7.635.671	137.296	13.379,1	240,6
Norte	3.014.402	52.244	16.355,1	283,5
Sul	8.311.862	113.590	27.728,4	378,9
Centro-Oeste	4.617.538	67.347	28.333,5	413,2

Fonte: Ministério da Saúde do Brasil. Painel COVID-19. Dados atualizados em 08 de setembro de 2025.

Na Figura 2, comparando-se os números de casos confirmados de COVID-19

reportados pela OMS, que registrou 37.944.353 casos no Brasil em 24 de janeiro de 2026 (World Health Organization, 2026), com aqueles divulgados pelo Ministério da Saúde, que indicam 39.318.227 casos em 08 de setembro de 2026, observa-se uma diferença numérica relevante entre as duas fontes oficiais. Essa discrepância pode ser atribuída a fatores metodológicos e operacionais, incluindo diferenças nos fluxos de atualização, nos critérios de consolidação das notificações e nos processos de validação dos dados. Enquanto o Ministério da Saúde incorpora de forma contínua reclassificações epidemiológicas, correções de duplicidades e atualizações decorrentes de investigações laboratoriais, a OMS depende do reporte oficial enviado pelos países, o qual está sujeito a atrasos e a etapas adicionais de harmonização antes de sua divulgação internacional.

Ainda que tais diferenças reflitam aspectos técnicos dos sistemas de vigilância epidemiológica, os dados convergem ao indicar que a COVID-19 permanece, em 2026, como um problema relevante de saúde pública. Apesar da ampla disponibilidade de vacinas eficazes e da redução expressiva nas taxas diárias de casos graves e óbitos em comparação aos períodos mais críticos da pandemia, novos casos e mortes continuam a ser registrados de forma contínua. Esse cenário reflete a circulação persistente do SARS-CoV-2, ainda que em níveis controlados, e evidencia que, sobretudo nas fases iniciais da crise sanitária, o enfrentamento da doença não poderia se apoiar em intervenções farmacológicas específicas.

Nesse contexto inicial, marcado pela rápida disseminação do SARS-CoV-2 no início de 2020 e pela ausência de terapias ou vacinas disponíveis, diversas medidas não farmacológicas de profilaxia foram amplamente adotadas em escala global com o objetivo de reduzir a transmissão viral e mitigar a sobrecarga dos sistemas de saúde. Entre as principais estratégias recomendadas por autoridades sanitárias internacionais, incluindo a OMS, destacaram-se o uso de máscaras faciais[2], a higienização frequente das mãos (principalmente por meio do uso de álcool a 70%), o distanciamento físico interpessoal, a limitação de aglomerações e a implementação de períodos de isolamento social e *lockdowns*[3], conforme ilustrado na Figura 3. Embora de natureza temporária e associadas a impactos sociais e econômicos significativos, tais intervenções mostraram-se eficazes na redução da taxa de contágio, no achatamento das curvas epidemiológicas e no ganho de tempo para a organização dos serviços de saúde e o desenvolvimento de soluções biomédicas mais duradouras, como vacinas e tratamentos específicos.

[2] Foram recomendadas a Peça Facial Filtrante nível 2 (PFF2) com eficiência mínima de 94% de filtragem de partículas e PFF3 com eficiência mínima de 99%, indicadas para a redução da inalação de aerossóis respiratórios potencialmente contaminados

[3] Medidas temporárias de restrição da circulação e de atividades presenciais, adotadas para reduzir o contato social e conter a transmissão do vírus.

Figura 3: – Representação esquemática das principais medidas não farmacológicas adotadas mundialmente para a prevenção e mitigação da transmissão do SARS-CoV-2 durante a pandemia de COVID-19, incluindo o uso de máscaras faciais, o distanciamento social mínimo entre indivíduos, a higienização frequente das mãos com água e sabão ou álcool em gel, e a implementação de restrições de mobilidade (*lockdowns*). Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

1.2 Vacina ChAdOx1 nCoV-19 (AZD1222)

Em resposta a esse cenário, a comunidade científica e a indústria farmacêutica mobilizaram esforços em escala global para o desenvolvimento de estratégias profiláticas eficazes, culminando em um processo acelerado de pesquisa, desenvolvimento e aprovação de vacinas. Em um intervalo de aproximadamente 17 meses após o início do surto, a OMS autorizou o uso emergencial de seis vacinas contra a COVID-19, com taxas de eficácia reportadas entre 50% e 95% na prevenção de infecções sintomáticas (FENG *et al.*, 2021). Essas vacinas contemplam diferentes plataformas tecnológicas, incluindo RNA mensageiro (Pfizer–BioNTech e Moderna), vírus inativado (Sinopharm e CoronaVac) e vetores virais não replicantes (Oxford–AstraZeneca e Janssen), refletindo abordagens imunológicas distintas, mas convergentes na indução de proteção clínica relevante. A implementação em larga escala dessas vacinas contribuiu de maneira significativa para a redução de casos graves, hospitalizações e óbitos, alterando substancialmente o curso da pandemia em diversos países.

Entre os imunizantes desenvolvidos durante a pandemia de COVID-19, a vacina ChAdOx1 nCoV-19 (AZD1222) destaca-se por ter sido amplamente estudada em diferentes contextos clínicos, fornecendo um conjunto robusto de evidências sobre eficácia,

imunogenicidade e regimes de vacinação.

Os ensaios clínicos da vacina ChAdOx1 nCoV-19 (AZD1222), desenvolvida pela Universidade de Oxford em parceria com a AstraZeneca, representam um marco na luta contra a pandemia de COVID-19 e um notável exemplo de como eventos inesperados podem levar a descobertas científicas cruciais. Os estudos de fase III, conduzidos de forma multicêntrica e envolvendo milhares de voluntários no Reino Unido, Brasil e África do Sul, foram fundamentais para a aprovação e distribuição global do imunizante (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2021, 2023).

A vacina ChAdOx1 nCoV-19 fundamenta-se em um vetor adenoviral não replicante de chimpanzé (*Chimpanzee Adenovirus Oxford 1* - ChAdOx1), o qual é geneticamente modificado para a transdução da sequência codificante da proteína *spike* (proteína S) do SARS-CoV-2. Esta plataforma vacinal caracteriza-se pela capacidade de deflagrar uma resposta imunológica bifásica, integrando os braços humoral e celular mediante a ativação de linfócitos T auxiliares ($CD4^+$) e citotóxicos ($CD8^+$), concomitantemente à síntese de anticorpos neutralizantes (FOLEGATTI *et al.*, 2020).

Um dos resultados mais surpreendentes e impactantes desses ensaios surgiu de um erro acidental ocorrido no braço do estudo conduzido no Reino Unido. Devido a uma inconsistência na quantificação da concentração viral, um subgrupo de 1367 participantes recebeu, inadvertidamente, uma primeira dose reduzida seguida por uma dose padrão, regime conhecido como meia dose/dose padrão (MD/DP), com intervalo igual ou superior a 12 semanas entre as aplicações (VOYSEY *et al.*, 2021). Ao analisar os dados de eficácia de um total de 11.636 participantes, os pesquisadores observaram que este grupo MD/DP apresentou uma eficácia de 90,0%, significativamente superior à eficácia de 62,1% registrada no grupo que recebeu duas doses padrão (regime DP/DP) (VOYSEY *et al.*, 2021, 2023). Esse evento de serendipidade científica[4] foi o ponto de partida para investigações mais aprofundadas sobre os regimes de dosagem e intervalos entre as aplicações.

Análises subsequentes demonstraram que, além da quantidade da dose, o intervalo entre a primeira e a segunda aplicação é uma variável crítica para a magnitude da resposta imune. Observou-se que um intervalo "*prime-boost*" superior a 12 semanas estava associado a uma eficácia vacinal significativamente mais elevada, atingindo 81,3%, em comparação com 55,1% para intervalos inferiores a 6 semanas (VOYSEY *et al.*, 2021, 2023). Esses resultados indicaram que a otimização temporal da revacinação desempenha papel central na imunogenicidade da vacina, provavelmente devido à maturação das células B de memória e à expansão clonal mais eficiente quando o estímulo secundário ocorre após uma janela imunológica adequada.

Em um outro estudo, FLAXMAN *et al.* (2021) avaliaram participantes que rece-

[4] Serendipidade científica é a descoberta de resultados relevantes de forma inesperada, frequentemente associada a erros ou observações acidentais.

beram a segunda dose após um intervalo ainda mais prolongado, com mediana de 44 a 45 semanas entre as aplicações. O grupo demonstrou um perfil de segurança favorável e apresentou uma resposta de anticorpos IgG anti-*spike* substancialmente superior à observada em regimes com intervalos mais curtos. Esses achados confirmaram que tanto o intervalo quanto o regime de dosagem influenciam significativamente a eficácia imunológica da ChAdOx1 nCoV-19, contribuindo para ajustes nas estratégias de vacinação em diversos países.

Além desses estudos, o trabalho conduzido por BARRETT *et al.* (2021) investigou diretamente diferentes esquemas de dosagem da ChAdOx1 nCoV-19 (AZD1222), comparando os regimes DP/DP (duas doses padrão) e DP/MD (dose padrão seguida de meia dose). A análise considerou não apenas a eficácia clínica, mas também parâmetros laboratoriais da resposta imune, incluindo títulos de IgG anti-*spike*, neutralização de vírus vivo e neutralização de pseudovírus. Os resultados indicaram que, embora o regime DP/MD apresentasse níveis absolutos de anticorpos ligeiramente inferiores, a resposta imune permaneceu robusta e potencialmente suficiente para conferir proteção contra a COVID-19. Esses achados reforçam a hipótese de que o intervalo entre as doses pode exercer influência mais significativa na resposta imunológica do que a quantidade exata de antígeno administrado.

Evidências adicionais sobre a influência do regime de dosagem foram apresentadas no Projeto Viana, conduzido no Brasil, no município de Viana, no estado do Espírito Santo (VALIM *et al.*, 2022). Nesse estudo observacional, os autores avaliaram a eficácia, segurança e imunogenicidade da administração de meia dose da vacina ChAdOx1 nCoV-19 em comparação com o regime padrão. Os resultados indicaram que a estratégia de dose reduzida foi capaz de induzir resposta imunológica robusta, com níveis significativos de anticorpos anti-*spike* e adequada capacidade de neutralização viral, além de apresentar perfil de segurança favorável. Esses achados sugerem que regimes de dosagem alternativos podem manter níveis relevantes de proteção imunológica, reforçando a importância de investigar quantitativamente a relação entre quantidade de antígeno administrado, intervalos entre doses e magnitude da resposta imune (VALIM *et al.*, 2022). Sendo assim, estudos dessa natureza fornecem evidências empíricas importantes para o desenvolvimento de abordagens de modelagem matemática voltadas à compreensão da dinâmica da resposta imunológica induzida por diferentes estratégias vacinais.

Esses dados clínicos consolidaram uma compreensão mais refinada da relação entre regime vacinal, intervalo entre doses e intensidade da resposta imunológica, motivando o desenvolvimento de modelos matemáticos capazes de representar quantitativamente essas interações.

Apesar dos avanços rápidos no desenvolvimento e na implementação de vacinas contra a COVID-19, permanecem questões fundamentais relacionadas à durabilidade e à

qualidade da imunidade induzida ao longo do tempo, particularmente diante do surgimento contínuo de variantes virais com diferentes perfis de transmissibilidade e escape imunológico. Embora diversos estudos experimentais e clínicos tenham contribuído para o entendimento da resposta imune associada à vacinação, ainda são limitadas as abordagens capazes de integrar, de forma sistemática, a dinâmica temporal da resposta imunológica com a avaliação comparativa de diferentes esquemas vacinais, especialmente no que se refere à definição de intervalos ótimos entre doses e à análise de estratégias de reforço. Além disso, a investigação experimental desses cenários envolve custos elevados, restrições éticas e limitações logísticas, o que dificulta a exploração abrangente de múltiplas combinações de parâmetros em populações heterogêneas.

Nesse contexto, a modelagem matemático-computacional apresenta-se como uma abordagem complementar promissora, ao permitir a representação quantitativa dos processos biológicos envolvidos na resposta imune e a realização de experimentos *in silico* sob condições controladas. No presente trabalho, propõe-se o desenvolvimento de um modelo matemático da resposta imune induzida pela vacina ChAdOx1 nCoV-19, calibrado com dados clínicos e utilizado na construção de uma coorte virtual, com o objetivo de investigar, de forma sistemática, o impacto de diferentes esquemas vacinais sobre a dinâmica de anticorpos. A partir desse modelo, são avaliados cenários envolvendo regimes de duas e três doses, bem como diferentes intervalos entre aplicações, buscando identificar configurações associadas a respostas imunes mais duradouras. Dessa forma, este estudo contribui para o avanço do entendimento quantitativo da resposta à vacinação, oferecendo subsídios que podem auxiliar na análise e no planejamento de estratégias vacinais.

1.3 Revisão da Literatura

A modelagem matemático-computacional tem desempenhado papel central na investigação da resposta imune a patógenos e vacinas, permitindo a integração de mecanismos biológicos, dados experimentais e variabilidade populacional em um mesmo arcabouço quantitativo (DELISI; BERZOFSKY, 1985; GROOT *et al.*, 2001; KUMAR *et al.*, 2006; DOYTCHINOVA; FLOWER, 2007; DAVIES *et al.*, 2009; HAYNES *et al.*, 2012; TYAGI *et al.*, 2013; DAINA; MICHIELIN; ZOETE, 2017; PAPPALARDO *et al.*, 2015; LEE *et al.*, 2008; FLOWER *et al.*, 2010; NANDY; BASAK, 2016; YANG *et al.*, 2019; ALLEMAILEM, 2021; RAPPUOLI, 2000; XAVIER *et al.*, 2020; THOMAS *et al.*, 2022; REIS *et al.*, 2021; XAVIER *et al.*, 2021; MA *et al.*, 2023; XAVIER; SANTOS; LOBOSCO, 2025).

Desde os trabalhos pioneiros de PERELSON (1989) e BAKER; BOCHAROV; PAUL (1997), as equações diferenciais ordinárias (EDOs) consolidaram-se como a principal ferramenta para descrever a dinâmica temporal da resposta imune, incluindo processos como ativação celular, proliferação, diferenciação e produção de anticorpos. Esses modelos têm sido amplamente utilizados para representar a interação entre antígenos, células do

sistema imune e imunoglobulinas, permitindo a estimação de parâmetros fisiológicos e a análise de diferentes esquemas vacinais (CHANG; LINDERMAN; KIRSCHNER, 2005; VODOVOTZ *et al.*, 2006; BONIN *et al.*, 2016, 2017; XAVIER *et al.*, 2021; XAVIER; SANTOS; LOBOSCO, 2025).

A fim de incorporar maior realismo biológico, diferentes extensões desses modelos foram propostas ao longo das últimas décadas. Modelos baseados em equações diferenciais parciais (EDPs) passaram a incluir efeitos espaciais e difusivos (PETTET *et al.*, 1996; SU *et al.*, 2009; FLEGG *et al.*, 2012; PIGOZZO *et al.*, 2013; QUINTELA; SANTOS; LOBOSCO, 2014), enquanto abordagens estocásticas, autômatos celulares e modelos baseados em agentes introduziram mecanismos para representar heterogeneidade celular e variabilidade intrínseca (CHAO *et al.*, 2004; XAVIER *et al.*, 2017; CELADA; SEIDEN, 1992; MORPURGO *et al.*, 1995; KOHLER *et al.*, 2000; BERNASCHI; CASTIGLIONE, 2001; PAPPALARDO *et al.*, 2018). Mais recentemente, o conceito de gêmeos digitais tem sido explorado no contexto biomédico como uma estratégia para a construção de representações virtuais de sistemas fisiológicos, com potencial aplicação em medicina personalizada e otimização de estratégias vacinais (HELGERS *et al.*, 2021; LAUBENBACHER *et al.*, 2022, 2024; WILLCOX; SEGUNDO, 2024).

No campo da vacinologia, essas abordagens têm sido empregadas tanto na identificação de alvos imunogênicos, por meio de estratégias de vacinologia reversa (RAPPUOLI, 2000; DOYTCHINOVA; FLOWER, 2007; FLOWER *et al.*, 2010), quanto na avaliação de regimes de dosagem, intervalos de administração e duração da resposta imune. Aplicações em diferentes doenças infecciosas, como a febre amarela (BONIN *et al.*, 2017; XAVIER *et al.*, 2017; BONIN *et al.*, 2020), evidenciam o potencial da modelagem matemática como ferramenta de apoio à tomada de decisão em saúde pública.

No entanto, a modelagem da resposta imune induzida por vacinas contra o SARS-CoV-2 ainda apresenta limitações relevantes. Estudos recentes têm se concentrado predominantemente na descrição empírica da cinética de anticorpos ou em modelos simplificados. Por exemplo, UWAMINO *et al.* (2023) utilizaram modelos compartimentais e formulações bi-exponenciais para descrever o decaimento de anticorpos após a vacinação com BNT162b2, obtendo boa concordância com dados de curto prazo, mas sem incorporar mecanismos imunológicos de longa duração, como a dinâmica de células B de memória.

De forma semelhante, RHODES *et al.* (2022) investigaram a relação entre dose vacinal e resposta imune por meio de modelos de imunodinâmica baseados em funções sigmoides e exponenciais (RHODES *et al.*, 2019). Embora úteis para estimar regimes de dosagem, esses modelos apresentam baixo nível de detalhamento mecanicista, limitando sua capacidade de representar de forma integrada os múltiplos componentes da resposta imune adaptativa.

De maneira geral, observa-se que os estudos existentes tendem a abordar aspectos

específicos da resposta imune, como a cinética de anticorpos ou a relação dose-resposta, de forma isolada, frequentemente sem integrar múltiplos mecanismos imunológicos em um mesmo modelo ou sem considerar explicitamente a variabilidade interindividual. Além disso, a avaliação sistemática de diferentes esquemas vacinais, incluindo intervalos entre doses e estratégias de reforço, ainda é limitada, especialmente em análises baseadas em populações heterogêneas.

Nesse contexto, a utilização de coortes virtuais (PAPPALARDO *et al.*, 2015; LEE *et al.*, 2008) surge como uma abordagem promissora, permitindo a geração de populações sintéticas que incorporam variabilidade biológica e possibilitam a realização de experimentos *in silico* em larga escala. Apesar desse potencial, ainda são escassos os estudos que combinam modelos mecanicistas detalhados com coortes virtuais calibradas a dados clínicos para a análise sistemática de estratégias vacinais.

Diante dessas lacunas, este trabalho propõe a integração de um modelo matemático mecanicista da resposta imune induzida pela vacina ChAdOx1 nCoV-19 (XAVIER; SANTOS; LOBOSCO, 2025) com a construção de uma coorte virtual calibrada a dados clínicos (FLAXMAN *et al.*, 2021). O objetivo é investigar, de forma sistemática, o impacto de diferentes regimes de vacinação e intervalos entre doses na dinâmica de anticorpos, contribuindo para o avanço da modelagem imunológica aplicada à vacinologia.

1.4 Objetivos e Hipótese de Pesquisa

A questão científica que orienta este trabalho é: *em que medida a dinâmica da resposta imune humoral induzida por vacinas pode ser explicada e prevista por mecanismos imunológicos fundamentais? Em particular, busca-se avaliar essa dinâmica quando representada por modelos matemáticos mecanicistas e analisada em nível populacional por meio de coortes virtuais.*

A hipótese central deste trabalho é que a dinâmica da resposta imune humoral induzida por vacinas pode ser explicada por um conjunto reduzido de mecanismos imunológicos fundamentais, como ativação, expansão, diferenciação e decaimento de populações celulares. Esses processos podem ser representados por um modelo mecanicista de baixa dimensionalidade, sem a necessidade de explicitar todos os componentes celulares e moleculares do sistema imune, como citocinas específicas ou subpopulações celulares detalhadas.

Adicionalmente, hipotetiza-se que a variabilidade interindividual observada na resposta de anticorpos decorre predominantemente de variações nos parâmetros associados a esses mecanismos, e não de diferenças estruturais no modelo. Nesse contexto, a integração do modelo a uma coorte virtual calibrada com dados clínicos é suficiente para reproduzir tanto o comportamento médio quanto a dispersão observada na população, bem como para prever, de forma consistente, os efeitos de diferentes regimes de vacinação.

De forma mais específica, o trabalho investiga as seguintes sub-hipóteses:

- A dinâmica temporal da resposta humoral induzida por vacinas de vetor viral pode ser descrita por um conjunto reduzido de equações diferenciais ordinárias que capturam os principais processos de ativação, expansão, diferenciação e decaimento da resposta imune;
- A variabilidade interindividual observada em dados clínicos pode ser explicada majoritariamente por variações nos parâmetros do modelo, sem a necessidade de modificações em sua estrutura mecanicista;
- Diferentes esquemas de vacinação (intervalos entre doses e administração de reforços) produzem efeitos quantitativamente distintos e previsíveis na magnitude e na persistência da resposta de anticorpos, como consequência da interação entre memória imunológica e cinética de resposta.

O objetivo geral deste trabalho é avaliar se um modelo mecanicista da resposta imune, integrado a uma coorte virtual calibrada com dados clínicos de pacientes que receberam a vacina ChAdOx1 nCoV-19 (AZD1222), é capaz de descrever, explicar e prever a dinâmica da resposta humoral sob diferentes regimes de vacinação.

Para atingir esse objetivo, definem-se os seguintes objetivos específicos:

- Avaliar a capacidade do modelo em reproduzir dados clínicos de dinâmica de anticorpos do tipo IgG;
- Investigar o papel da variabilidade interindividual na resposta imune por meio da análise de uma coorte virtual;
- Comparar quantitativamente diferentes esquemas vacinais, analisando seus efeitos sobre a magnitude e a persistência da resposta de anticorpos;
- Analisar o potencial preditivo do modelo na extrapolação de cenários não observados experimentalmente.

Do ponto de vista metodológico, o trabalho baseia-se na construção de um modelo mecanicista descrito por equações diferenciais ordinárias, calibrado a dados clínicos, e na geração de uma coorte virtual para a realização de simulações *in silico* em larga escala.

1.5 Organização

O presente trabalho está organizado da seguinte forma. O presente capítulo apresentou a motivação, revisão da literatura e os objetivos do trabalho. O Capítulo 2 descreve

a fundamentação teórica, contemplando as principais células do Sistema Imunológico Humano, os princípios de modelagem matemática de sistemas biológicos, equações diferenciais aplicadas à dinâmica imunológica e técnicas de otimização utilizadas na calibração de parâmetros, com destaque para o algoritmo de Evolução Diferencial. No Capítulo 3 é apresentado o modelo matemático proposto, incluindo sua formulação, hipóteses adotadas, definição dos parâmetros, procedimentos de calibração e implementação computacional. O Capítulo 4 dedica-se à apresentação e análise dos resultados numéricos, discutindo as simulações realizadas, a validação com dados clínicos e as implicações biológicas e epidemiológicas dos cenários investigados. Por fim, o Capítulo 6 reúne as conclusões do trabalho, as principais contribuições obtidas, as limitações identificadas e as perspectivas para pesquisas futuras.

2 Fundamentação Teórica

Este capítulo apresenta os fundamentos teóricos necessários para a compreensão dos principais mecanismos do Sistema Imune Humano (SIH), bem como aspectos relevantes relacionados à COVID-19 e à resposta imunológica induzida pelas vacinas. Os conceitos discutidos ao longo deste capítulo fornecem a base conceitual indispensável para a formulação, interpretação e análise do modelo matemático-computacional desenvolvido neste trabalho, o qual será detalhado no Capítulo 3. A exposição teórica fundamenta-se em referências clássicas e consolidadas da área de imunologia, garantindo consistência científica e coerência com os objetivos propostos.

2.1 Sistema Imune Humano - SIH

Esta sessão se dedica a detalhar os pilares teóricos fundamentais para a compreensão do problema abordado nesta pesquisa. Serão examinados os mecanismos do Sistema Imune Humano (SIH), com ênfase na vacinação contra a COVID-19, mais precisamente sob a análise da vacina ChAdOx1 nCoV-19 (AZD1222).

2.1.1 Fundamentos do Sistema Imunológico

O sistema imunológico constitui uma rede altamente integrada de órgãos, tecidos, células e moléculas especializadas na defesa do organismo contra agentes infecciosos, denominados patógenos, incluindo vírus, bactérias, fungos e protozoários capazes de desencadear processos patológicos (LEVINSON, 2016; SOMPAYRAC, 2019). A compreensão completa das dinâmicas imunes ainda representa um desafio científico, uma vez que múltiplas interações celulares e moleculares, especialmente em nível intracelular, permanecem objeto de investigação. De forma geral, o sistema imunológico organiza-se em dois componentes funcionais interdependentes: a imunidade inata e a imunidade adaptativa, cuja atuação coordenada caracteriza a resposta imune (ABBAS; LICHTMAN; PILLAI, 2015).

A imunidade inata constitui a primeira linha de defesa do organismo e é composta por mecanismos de resposta rápida e inespecífica. Entre esses mecanismos, destacam-se as barreiras físicas e químicas, como os epitélios, o muco e secreções presentes nas superfícies mucosas, que atuam na prevenção da entrada de patógenos (DELVES *et al.*, 2017). Uma vez ultrapassadas essas barreiras, a resposta inata envolve a ativação de diferentes populações celulares, com destaque para os fagócitos, como neutrófilos, macrófagos e monócitos, responsáveis pela internalização e eliminação de microrganismos, bem como pela remoção de detritos celulares. As células dendríticas, além de sua capacidade fagocítica, desempenham papel central na captura e processamento de antígenos, atuando como elo entre a imunidade inata e a adaptativa (DELVES *et al.*, 2017).

O processo de fagocitose inicia-se com o reconhecimento e a internalização do patógeno por meio da emissão de *pseudópodes*, resultando na formação de um fagossomo. Este, por sua vez, funde-se a lisossomos, originando o fagolisossomo, onde ocorre a degradação do material fagocitado por ação de enzimas hidrolíticas e espécies reativas. Paralelamente, células do sistema imune secretam mediadores solúveis, como citocinas e quimiocinas, que regulam a intensidade da resposta inflamatória e promovem o recrutamento de outras células para o sítio de infecção (SOMPAYRAC, 2019).

Outro componente relevante da imunidade inata são as células *Natural Killer* (NK), um subtipo de linfócitos que atua na eliminação de células infectadas por vírus ou transformadas neoplasticamente. Essas células reconhecem alterações na expressão de moléculas do complexo principal de histocompatibilidade (MHC) e induzem a morte celular por mecanismos citotóxicos, como a liberação de perforinas e granzimas, levando à apoptose das células-alvo (SOMPAYRAC, 2019).

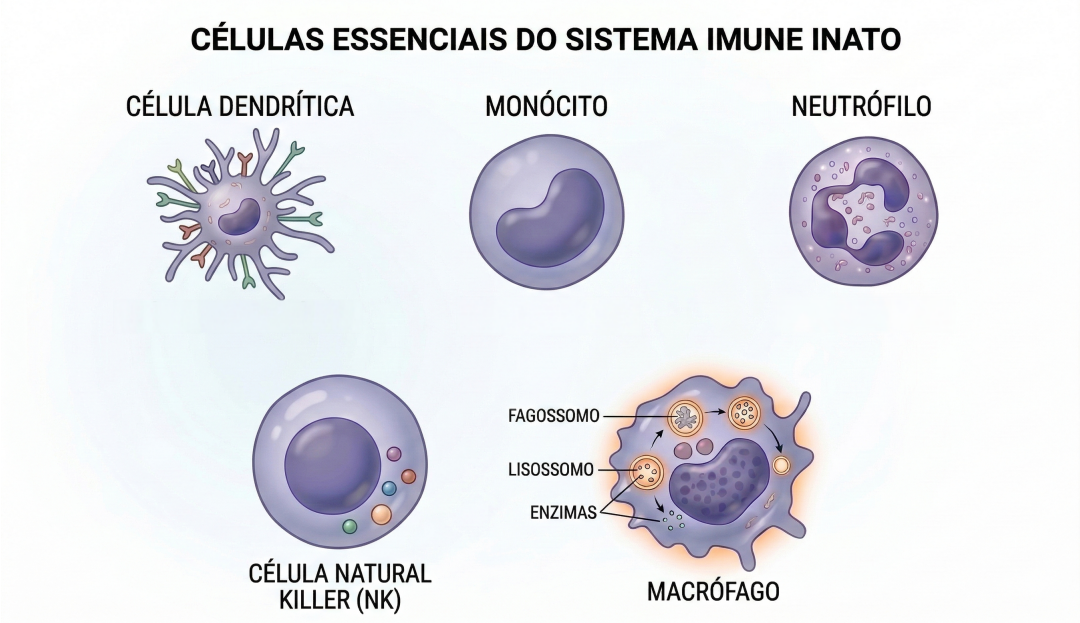

Figura 4: – Representação esquemática de algumas das principais células que compõem o sistema imune inato. Entre elas destacam-se as células dendríticas, responsáveis pela captura e apresentação de antígenos; os monócitos, que circulam no sangue e podem diferenciar-se em macrófagos ou células dendríticas nos tecidos; os neutrófilos, importantes fagócitos nas fases iniciais da resposta inflamatória; e as células *Natural Killer* (NK), especializadas na eliminação de células infectadas ou tumorais. O esquema também ilustra o processo de fagocitose, no qual partículas são internalizadas em fagossomos que posteriormente se fundem com lisossomos, permitindo sua degradação enzimática. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

Além das populações celulares, a imunidade inata inclui o sistema complemento, um conjunto de proteínas plasmáticas que, uma vez ativadas em cascata, contribuem diretamente para a eliminação de patógenos por meio de mecanismos como opsonização, lise celular e amplificação da resposta inflamatória, além de favorecerem a quimiotaxia

de células imunes (SOMPAYRAC, 2019). Apesar de sua relevância funcional, o sistema complemento não é explicitamente modelado neste trabalho, uma vez que o foco recai sobre os mecanismos associados à resposta imune humoral.

A imunidade adaptativa é ativada quando os mecanismos inatos não são suficientes para eliminar o agente infeccioso. Esse sistema caracteriza-se por alta especificidade e memória imunológica, sendo mediado principalmente por linfócitos B e T. A ativação da resposta adaptativa envolve o processamento e a apresentação de antígenos por células apresentadoras, seguido da ativação e expansão clonal de linfócitos específicos (ABBAS; LICHTMAN; PILLAI, 2015). Em comparação com a imunidade inata, a resposta adaptativa apresenta início mais lento, porém resulta em respostas mais específicas e duradouras (SOMPAYRAC, 2019).

Os linfócitos T subdividem-se principalmente em células $TCD4^+$ (auxiliares, ou do inglês, *T helper*) e $TCD8^+$ (citotóxicas, também conhecidas como *T killer*). Como apresentado na Figura 5, as células $TCD4^+$ desempenham papel central na coordenação da resposta imune, sendo ativadas após o reconhecimento de antígenos apresentados por células apresentadoras no contexto de MHC classe II, promovendo a ativação de outras células por meio da secreção de citocinas, incluindo os linfócitos B. Já as células $TCD8^+$ reconhecem antígenos apresentados por moléculas de MHC de classe I e induzem a morte de células infectadas (processo denominado apoptose). Neste trabalho, o foco recai sobre a resposta humoral; dessa forma, a dinâmica associada às células $TCD8^+$ não é explicitamente modelada, entretanto, o papel auxiliar das células $TCD4^+$ é considerado no processo de ativação dos linfócitos B.

Os linfócitos B, por sua vez, são responsáveis pela mediação da resposta imune humoral. Após ativação, essas células podem diferenciar-se em plasmócitos, especializados na produção de anticorpos, ou em células B de memória, que conferem resposta mais rápida e eficiente em exposições subsequentes ao mesmo antígeno (SOMPAYRAC, 2019). Os anticorpos exercem múltiplas funções efetoras, incluindo neutralização de patógenos, opsonização e ativação do sistema complemento, contribuindo para a eliminação do agente infeccioso.

Considerando que o objetivo deste estudo é modelar a resposta imune humoral induzida por vacinação contra a COVID-19, as seções seguintes concentram-se na dinâmica dos linfócitos B e na produção de anticorpos, elementos centrais do modelo matemático proposto.

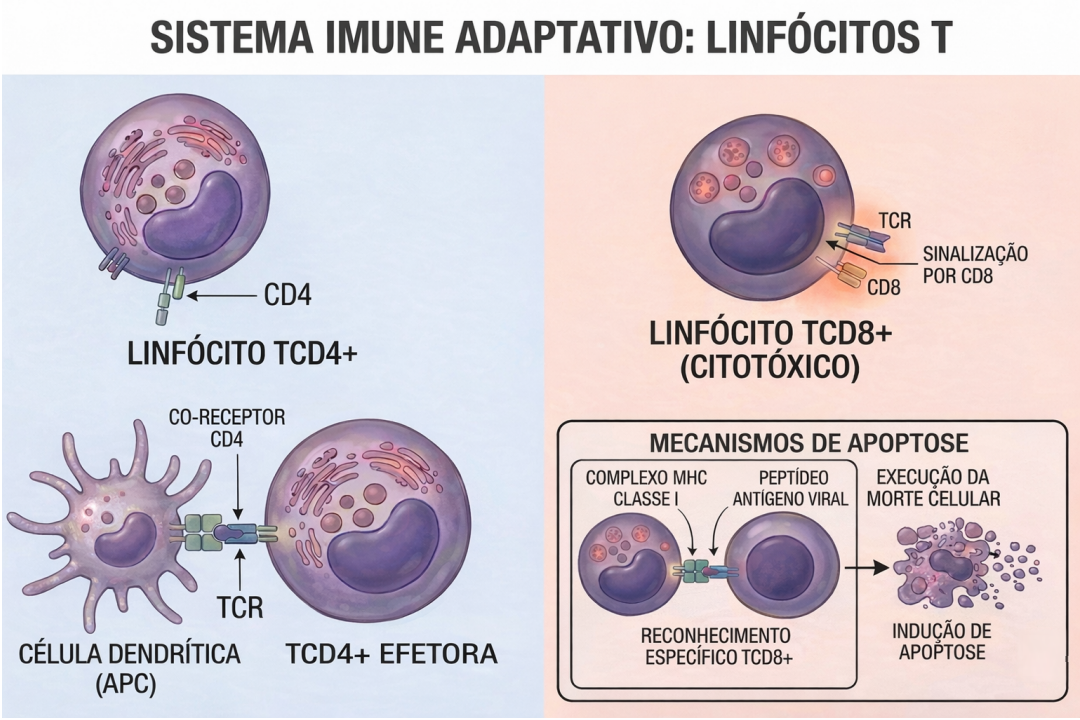

Figura 5: – Representação esquemática da ativação de linfócitos T no sistema imune adaptativo. Linfócitos TCD4$^+$ são ativados após o reconhecimento de antígenos apresentados por células apresentadoras de antígeno (APCs), como as células dendríticas, por meio da ligação do receptor de célula T (TCR) ao complexo MHC classe II–antígeno, levando à diferenciação em células T efetoras. Por sua vez, linfócitos TCD8$^+$ reconhecem antígenos apresentados por MHC classe I na superfície de células infectadas, resultando na indução de apoptose. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

2.1.2 Dinâmica dos Linfócitos B

A denominação dos linfócitos B tem origem histórica em estudos realizados em aves, nos quais essas células foram inicialmente associadas à bursa de Fabricius (ABBAS; LICHTMAN; PILLAI, 2015). Em mamíferos, incluindo humanos, a maturação dos linfócitos B ocorre na medula óssea. Essas células desempenham papel central na imunidade adaptativa, sendo continuamente produzidas ao longo da vida e distribuídas entre o sangue periférico e órgãos linfoides secundários, como linfonodos e baço, onde permanecem em estado quiescente até o encontro com o antígeno (SOMPAYRAC, 2019).

A Figura 6 apresenta a ativação dos linfócitos B que se inicia com o reconhecimento específico de epítopos antigênicos[1] por meio dos receptores de células B (BCRs). Esse processo pode ocorrer por vias dependentes ou independentes do auxílio de linfócitos TCD4$^+$, sendo a via dependente de células T a mais relevante para a geração de respostas humorais robustas e duradouras. Nessa via, após a ligação do antígeno ao BCR, o linfócito B internaliza, processa e apresenta peptídeos antigênicos em moléculas de MHC de classe II,

[1] Epítopos antigênicos são pequenas regiões específicas de um antígeno reconhecidas por receptores do sistema imune.

interagindo com células TCD4$^+$ auxiliares, que fornecem sinais coestimuladores essenciais para sua ativação completa (ABBAS; LICHTMAN; PILLAI, 2015; SOMPAYRAC, 2019).

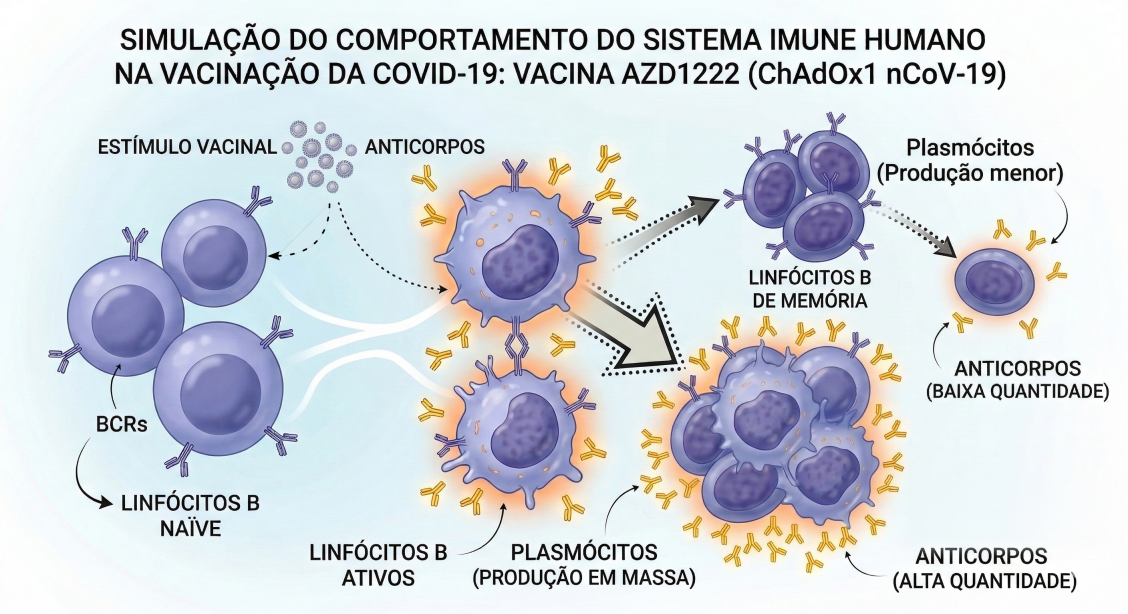

Figura 6: – Representação esquemática do processo de ativação e diferenciação dos linfócitos B após estímulo antigênico. Linfócitos B *naïve* expressam receptores de células B (BCRs), que reconhecem epítopos específicos. Após ativação, frequentemente mediada por interação com linfócitos TCD4$^+$, essas células proliferam e se diferenciam em plasmócitos, responsáveis pela produção de anticorpos, e em células B de memória, que sustentam respostas imunes secundárias mais rápidas e eficazes. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

Uma vez ativados, os linfócitos B proliferam e se diferenciam em células efetoras e células de memória. As células efetoras correspondem aos plasmócitos, responsáveis pela secreção de anticorpos, podendo ser classificados, do ponto de vista funcional, em plasmócitos de vida curta e de vida longa. Os primeiros estão associados à resposta inicial, enquanto os segundos contribuem para a manutenção prolongada de níveis de anticorpos circulantes. Paralelamente, a formação de células B de memória é fundamental para a resposta imune secundária, permitindo uma resposta mais rápida e intensa em exposições subsequentes ao mesmo antígeno.

No contexto deste trabalho, cujo objetivo é propor um modelo matemático simplificado da resposta imune humoral a partir do estímulo vacinal, assume-se que a produção de anticorpos é realizada por uma população agregada de plasmócitos, sem distinção explícita entre subtipos de vida curta e longa. Essa simplificação permite capturar as principais dinâmicas da resposta humoral mantendo a tratabilidade do modelo.

É importante destacar que a eficácia da resposta vacinal está diretamente relacionada à geração adequada tanto de plasmócitos quanto de células B de memória. Em alguns casos, a resposta imune induzida pela vacinação pode não resultar na produção

sustentada de anticorpos ou na formação eficiente de memória imunológica, o que compromete a duração da proteção. Nesse contexto, a soroconversão refere-se à detecção de níveis mensuráveis de anticorpos específicos no soro após a exposição ao antígeno (por infecção ou vacinação), sendo um indicador de que houve ativação da resposta humoral. Entretanto, a presença de anticorpos detectáveis não implica necessariamente proteção duradoura, a qual depende também da persistência de plasmócitos de vida longa e da formação de células B de memória.

2.1.3 Estrutura e Função dos Anticorpos

As imunoglobulinas (Ig) são glicoproteínas produzidas por plasmócitos e constituem os principais mediadores da resposta imune humoral. Estruturalmente, a unidade básica de uma imunoglobulina apresenta conformação em "Y", sendo composta por duas cadeias pesadas (*H*, do inglês *heavy*) e duas cadeias leves (*L*, do inglês *light*), organizadas em pares idênticos, como apresentado na Figura 7. Essas cadeias são mantidas unidas por ligações covalentes do tipo pontes dissulfeto, além de interações não covalentes que contribuem para a estabilidade conformacional da molécula (DELVES *et al.*, 2017).

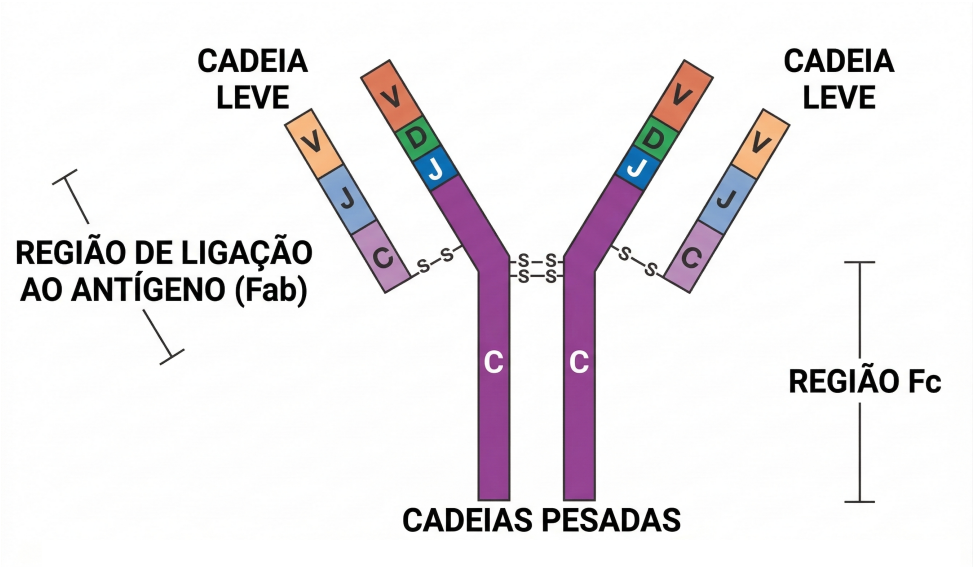

Figura 7: – Representação esquemática da estrutura molecular de um anticorpo (imunoglobulina). A molécula é composta por duas cadeias pesadas e duas cadeias leves, unidas por ligações dissulfeto. As extremidades das cadeias formam as regiões variáveis, constituídas pelos segmentos gênicos V (variável), D (diversidade, presente apenas nas cadeias pesadas) e J (junção), responsáveis pela formação do sítio específico de reconhecimento do antígeno. Essas porções correspondem à região Fab (*Fragment antigen-binding*), responsável pela ligação ao epítopo do antígeno. A porção inferior da molécula corresponde à região Fc (*Fragment crystallizable*), formada pelas regiões constantes das cadeias pesadas, que medeia funções efetoras do sistema imune, como a interação com receptores celulares e a ativação do sistema complemento. Figura gerada com auxílio de inteligência artificial generativa (Gemini) e adaptada de SOMPAYRAC (2019).

Do ponto de vista funcional, as imunoglobulinas podem ser divididas em duas regiões principais. A região de ligação ao antígeno, denominada Fab (*Fragment antigen-binding*), é formada pelos domínios variáveis das cadeias leve e pesada, além de parte de seus domínios constantes, sendo responsável pelo reconhecimento específico de epítopos presentes nos antígenos. Essa especificidade decorre da variabilidade estrutural das regiões variáveis, gerada por mecanismos de recombinação somática dos segmentos gênicos V (variável), D (diversidade, presente apenas nas cadeias pesadas) e J (junção) (SOMPAYRAC, 2019).

A região Fc (*Fragment crystallizable*), por sua vez, é composta exclusivamente pelos domínios constantes das cadeias pesadas e está associada às funções efetoras do anticorpo. Essa região interage com receptores Fc (FcR) expressos na superfície de diversas células do sistema imune, como macrófagos e células NK, promovendo processos como opsonização e citotoxicidade celular dependente de anticorpos (ADCC). Além disso, a região Fc pode ativar o sistema complemento por meio da via clássica, estabelecendo um elo entre o reconhecimento do antígeno e sua eliminação efetiva.

Entre as regiões Fab e Fc, encontra-se a região de dobradiça (*hinge region*), responsável por conferir flexibilidade estrutural à molécula. Essa flexibilidade permite que os braços do anticorpo se ajustem espacialmente para se ligar a epítopos distribuídos em diferentes distâncias e orientações na superfície de patógenos.

As imunoglobulinas são classificadas em cinco isotipos principais (IgA, IgD, IgE, IgG e IgM) definidos pela estrutura da região constante das cadeias pesadas (α, δ, ϵ, γ e μ, respectivamente). Cada isotipo apresenta propriedades funcionais e distribuição tecidual distintas. Dentre eles, a IgG é o isotipo predominante no soro humano, correspondendo a aproximadamente 75% das imunoglobulinas circulantes (SOMPAYRAC, 2019). Destaca-se por sua capacidade de atravessar a barreira placentária, conferindo imunidade passiva ao feto, além de desempenhar papel central na neutralização de patógenos e toxinas, na opsonização e na mediação de ADCC.

2.2 *Coronavirus Disease 2019* - COVID-19

O agente etiológico da COVID-19 é o vírus denominado SARS-CoV-2, sigla derivada do inglês *Severe Acute Respiratory Syndrome Coronavirus 2*. Esse vírus pertence ao gênero *Betacoronavirus*, da família *Coronaviridae*, sendo assim nomeado em função de sua proximidade filogenética com o SARS-CoV, responsável pelo surto de síndrome respiratória aguda grave ocorrido entre 2002 e 2003 (KSIAZEK *et al.*, 2003). O SARS-CoV-2 é um dos coronavírus humanos com capacidade comprovada de causar surtos epidêmicos de grande escala associados a manifestações respiratórias graves, apresentando aproximadamente 80% de similaridade genômica com o SARS-CoV (HU *et al.*, 2021; ZHOU *et al.*, 2020).

O SARS-CoV-2, representado ilustrativamente na Figura 8, é um vírus envelopado de RNA de fita simples de polaridade positiva, com um genoma de aproximadamente 30

kb (quilobases) de comprimento, figurando entre os maiores genomas descritos para vírus de RNA (V'KOVSKI *et al.*, 2021).

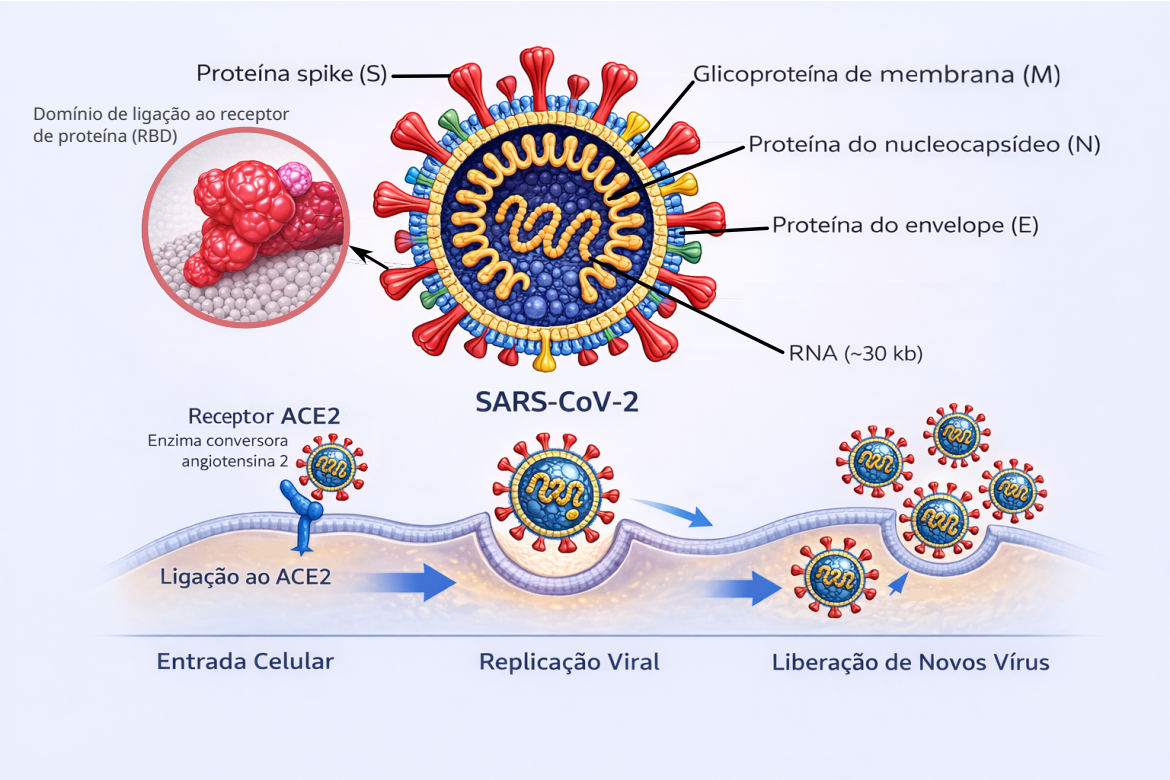

Figura 8: – Representação esquemática da estrutura do SARS-CoV-2 e do processo de infecção celular. O painel superior apresenta os principais componentes estruturais do vírus, incluindo a proteína *spike* (S) e seu domínio de ligação ao receptor (RBD), a proteína de membrana (M), a proteína de envelope (E) e a proteína do nucleocapsídeo (N), associada ao RNA genômico de fita simples de polaridade positiva. O painel inferior ilustra etapas do ciclo viral, incluindo ligação ao receptor ACE2, entrada na célula hospedeira, replicação viral e liberação de novas partículas virais. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

O genoma do SARS-CoV-2 codifica inicialmente poliproteínas que são processadas em um conjunto de proteínas não estruturais, responsáveis pela formação do complexo replicase-transcriptase, essencial para a replicação e transcrição do RNA viral. Além dessas, o vírus apresenta quatro proteínas estruturais principais: a proteína *spike* (S), a proteína de envelope (E), a proteína de membrana (M) e a proteína do nucleocapsídeo (N).

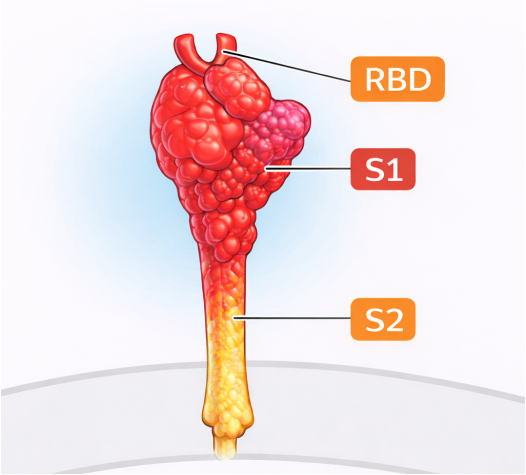

Figura 9: – Representação esquemática da proteína *spike* (S) do SARS-CoV-2, destacando suas principais subunidades funcionais. A subunidade S1 contém o domínio de ligação ao receptor (RBD), responsável pela interação com o receptor ACE2, enquanto a subunidade S2 está associada ao processo de fusão de membranas. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

A proteína *spike* (S), expressa na superfície viral, desempenha papel central na infecção, mediando tanto a ligação ao receptor celular quanto a fusão de membranas. Sua subunidade S1 contém o domínio de ligação ao receptor (*receptor-binding domain*, RBD), responsável pelo reconhecimento da enzima conversora de angiotensina 2 (ACE2), enquanto a subunidade S2 está envolvida na fusão da membrana viral com a membrana da célula hospedeira. Devido a essas funções, a proteína S é considerada o principal determinante da infectividade viral e o principal alvo das vacinas atualmente disponíveis (WALLS *et al.*, 2020; WRAPP *et al.*, 2020).

As proteínas M e E desempenham papéis essenciais na montagem, brotamento[2] e liberação de novas partículas virais, enquanto a proteína N está associada ao empacotamento do RNA genômico e pode também atuar na modulação da resposta imune do hospedeiro. A interação coordenada entre essas proteínas estruturais é fundamental para a formação de vírions estáveis e infecciosos, sendo, portanto, central para a dinâmica de propagação viral.

A ACE2 (*Angiotensin-Converting Enzyme 2*) é uma enzima transmembranar amplamente expressa em diferentes tecidos humanos, incluindo epitélio respiratório, endotélio vascular e trato gastrointestinal. No contexto da infecção pelo SARS-CoV-2, a ACE2 atua como o principal receptor celular, sendo reconhecida pela subunidade S1 da proteína *spike*, o que permite a ligação viral e desencadeia o processo de entrada do vírus na célula hospedeira. Esse mecanismo estabelece a etapa inicial da infecção e condiciona o tropismo tecidual do vírus.

A compreensão dessas características estruturais e funcionais do SARS-CoV-2

[2] Processo pelo qual vírus envelopados adquirem seu envelope ao emergirem da célula hospedeira.

fornece a base biológica necessária para interpretar tanto os mecanismos de infecção quanto a resposta imune do hospedeiro, aspectos fundamentais para o desenvolvimento de modelos matemáticos da dinâmica da doença. A seguir, são apresentados os principais aspectos clínicos associados à COVID-19.

2.2.1 Aspectos Clínicos

A COVID-19 apresenta um amplo espectro de manifestações clínicas, variando desde infecções assintomáticas ou com poucos sintomas (paucissintomáticas), até quadros graves e potencialmente fatais. Estima-se que a maioria dos indivíduos infectados desenvolva sintomas leves a moderados, enquanto uma fração menor evolui para formas graves da doença, caracterizadas por comprometimento respiratório significativo e necessidade de hospitalização. Essa heterogeneidade clínica reflete interações complexas entre o vírus, o sistema imune do hospedeiro e fatores individuais, como idade e presença de comorbidades.

Nos casos sintomáticos, as manifestações clínicas mais frequentes incluem febre, tosse seca, fadiga, mialgia e cefaleia, podendo estar associadas a sintomas respiratórios superiores, como congestão nasal e dor de garganta (HUANG *et al.*, 2020). Alterações neurossensoriais, como perda do paladar e/ou do olfato, também foram amplamente relatadas, especialmente nas fases iniciais da infecção, configurando sinais clínicos relativamente específicos da COVID-19. Em alguns indivíduos, sintomas gastrointestinais, como náuseas, vômitos e diarreia, podem estar presentes, indicando o caráter sistêmico da infecção pelo SARS-CoV-2 (HUANG *et al.*, 2020).

Uma parcela dos pacientes evolui para quadros clínicos mais graves, geralmente após a primeira semana de sintomas, caracterizados pelo agravamento da falta de ar subjetiva e baixa oxigenação do sangue[3], além de possível desenvolvimento de pneumonia viral. Em situações mais críticas, a infecção pode culminar na Síndrome do Desconforto Respiratório Agudo (SDRA), condição associada a intensa inflamação pulmonar, necessidade de suporte ventilatório e elevada taxa de mortalidade. Além do comprometimento respiratório, casos graves frequentemente apresentam disfunções multissistêmicas, incluindo alterações cardiovasculares, renais e neurológicas (HUANG *et al.*, 2020).

A gravidade da COVID-19 apresenta grande associação a fatores de risco bem estabelecidos, como idade avançada, presença de doenças crônicas pré-existentes, incluindo hipertensão arterial, diabetes *mellitus*, obesidade e doenças cardiovasculares, além de condições que cursam com imunossupressão. Esses grupos populacionais apresentam maior probabilidade de evolução desfavorável, hospitalização prolongada e óbito, o que reforça

[3] A saturação arterial de oxigênio (SaO_2) corresponde à porcentagem de hemoglobina ligada ao oxigênio no sangue arterial, sendo determinada com precisão por meio da gasometria arterial, um exame invasivo. Diferentemente da saturação estimada pelo oxímetro de pulso (SpO_2), a SaO_2 reflete de forma direta a oxigenação arterial. Em indivíduos saudáveis, seus valores costumam permanecer acima de 95%, sendo considerados críticos quando inferiores a 90%.

a importância da avaliação criteriosa do risco clínico e do acompanhamento sistemático desses indivíduos.

Além das manifestações agudas, um subconjunto significativo de pacientes apresenta sintomas persistentes por semanas ou meses após a infecção inicial, condição denominada COVID longa ou síndrome pós-COVID. Esse quadro pode incluir fadiga crônica, dispneia (comumente conhecida como falta de ar), distúrbios cognitivos, alterações cardiovasculares e impacto substancial na qualidade de vida, mesmo em indivíduos que apresentaram formas inicialmente leves da doença. A existência dessas manifestações prolongadas evidencia que os efeitos clínicos da infecção pelo SARS-CoV-2 não se restringem à fase aguda, ampliando os desafios clínicos e epidemiológicos associados à doença (HUANG *et al.*, 2023).

A progressão clínica da COVID-19 também pode envolver um fenômeno imunológico conhecido como tempestade de citocinas (*cytokine storm*), caracterizado por uma resposta inflamatória exacerbada do sistema imune. Durante esse processo, células do sistema imune inato e adaptativo liberam grandes quantidades de citocinas pró-inflamatórias, como interleucina-6 (IL-6), TNF-α e outras moléculas sinalizadoras que, embora façam parte da defesa antiviral, podem levar a inflamação sistêmica, dano tecidual e comprometimento de órgãos, especialmente no pulmão. Evidências sugerem que, em alguns pacientes, a infecção pelo SARS-CoV-2 pode desregular a resposta imune e intensificar a produção dessas moléculas inflamatórias, contribuindo para quadros clínicos mais graves e maior risco de mortalidade (TISONCIK *et al.*, 2012; TAY *et al.*, 2020; TANG *et al.*, 2020). Logo, a própria resposta imune do hospedeiro passa a desempenhar um papel central na progressão da doença, uma vez que a inflamação excessiva resultante da produção descontrolada de citocinas pode causar danos significativos aos tecidos.

A complexidade das interações entre o vírus e os diferentes componentes do sistema imune torna desafiadora a compreensão completa desses mecanismos apenas por meio de observações clínicas ou experimentais. Nesse contexto, abordagens matemático-computacionais têm sido utilizadas para investigar a dinâmica da resposta imune e o papel das citocinas na evolução da doença, permitindo testar hipóteses sobre os fatores que diferenciam casos leves de quadros graves associados à síndrome de liberação de citocinas (REIS *et al.*, 2021).

A diversidade de apresentações clínicas da COVID-19 está relacionada, em grande medida, às diferenças na resposta imune do hospedeiro ao SARS-CoV-2. Respostas imunes eficazes tendem a favorecer a eliminação viral e estão frequentemente associadas a quadros leves da doença, enquanto respostas desreguladas podem desencadear processos inflamatórios exacerbados e dano tecidual significativo. Esses mecanismos ajudam a explicar não apenas a variabilidade dos sintomas observados entre os indivíduos, mas também a evolução clínica e os desfechos associados à infecção.

Além do impacto no nível individual, tais características influenciam diretamente a

dinâmica de disseminação da doença em populações, afetando padrões de transmissão, taxas de hospitalização e mortalidade. Assim, a compreensão dos aspectos clínicos da COVID-19 constitui um passo importante para a interpretação de seu comportamento em escala populacional. A seguir, são apresentados os principais aspectos epidemiológicos associados à doença.

2.2.2 Aspectos Epidemiológicos

A epidemiologia é a área do conhecimento dedicada ao estudo da distribuição, dos determinantes e da dinâmica das doenças em populações humanas, permitindo compreender como agentes infecciosos emergem, se propagam e podem ser controlados. Nesse contexto, alguns conceitos fundamentais são utilizados para caracterizar a magnitude e a extensão espacial de eventos relacionados a doenças transmissíveis, destacando-se os termos surto, epidemia e pandemia.

Um surto refere-se ao aumento localizado e geralmente inesperado do número de casos de uma determinada doença em uma área geográfica restrita ou em um grupo populacional específico, como uma comunidade, instituição ou cidade. Quando esse aumento excede de forma sustentada o nível esperado de ocorrência e passa a atingir uma região mais ampla, envolvendo múltiplas localidades ou unidades administrativas, o evento passa a ser classificado como uma epidemia. Por sua vez, o termo pandemia é empregado quando a disseminação da doença ocorre em escala global, com transmissão sustentada em múltiplos países ou continentes.

Além dessas classificações, o termo endemia descreve a ocorrência contínua ou esperada de uma doença em uma determinada região geográfica ou população ao longo do tempo. Nesses casos, a incidência da doença tende a permanecer relativamente estável, podendo apresentar variações sazonais associadas a fatores ambientais, climáticos e sociais. Doenças transmitidas por vetores em regiões tropicais frequentemente apresentam esse comportamento. No Brasil e em outros países de clima tropical, enfermidades como a febre amarela, a dengue, a zika e a chikungunya são exemplos típicos de doenças endêmicas, uma vez que sua persistência está associada à presença contínua de vetores e a condições ambientais favoráveis à transmissão.

Essas classificações não dependem exclusivamente do número absoluto de casos, mas também de fatores como a taxa de crescimento da infecção, a extensão geográfica afetada e o impacto sobre os sistemas de saúde. Do ponto de vista quantitativo, tais aspectos são frequentemente analisados por meio de indicadores epidemiológicos, como a taxa de incidência, a taxa de prevalência e o número básico de reprodução (R_0), que expressa o número médio de novos casos gerados por um indivíduo infectado em uma população suscetível.

A pandemia de COVID-19 ilustra claramente essa dinâmica epidemiológica. Os

primeiros casos foram identificados como um surto localizado em Wuhan, na China, evoluindo posteriormente para epidemias em diferentes regiões e, por fim, para uma pandemia com disseminação global, como apresentado anteriormente sua evolução cronológica na Figura 10.

No caso da COVID-19, os primeiros registros corresponderam a um conjunto de casos de pneumonia de etiologia inicialmente desconhecida, relatados no final de 2019, posteriormente associados ao SARS-CoV-2 (LI *et al.*, 2020). Em poucos meses, a transmissão sustentada entre diferentes países levou a Organização Mundial da Saúde a declarar a situação como uma pandemia, em março de 2020 (World Health Organization, 2020), evidenciando a rápida disseminação global do vírus.

Figura 10: – Representação esquemática das diferentes escalas de disseminação de doenças infecciosas. Um surto corresponde ao aumento localizado de casos em uma área restrita; uma epidemia caracteriza-se pela expansão da doença em uma região ou país; e uma pandemia refere-se à disseminação global com transmissão sustentada entre múltiplos continentes. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

A evolução da COVID-19 em escala global evidenciou a necessidade de estratégias eficazes de controle, incluindo intervenções não farmacológicas e o desenvolvimento de vacinas. Do ponto de vista da modelagem matemática, esses processos são frequentemente descritos por modelos compartimentais que buscam representar a dinâmica de transmissão da doença e avaliar o impacto de diferentes estratégias de intervenção. A seguir, são apresentados os principais aspectos relacionados ao desenvolvimento e à utilização de vacinas contra o SARS-CoV-2.

2.2.3 Vacinas contra a COVID-19

O desenvolvimento de vacinas contra a COVID-19 ocorreu em tempo recorde, impulsionado por esforços científicos globais e por avanços prévios em biotecnologia e imunologia. Diferentes plataformas tecnológicas foram empregadas com o objetivo comum de induzir resposta imune protetora contra o SARS-CoV-2, particularmente direcionada à proteína *spike* (S), principal antígeno viral envolvido na entrada do vírus nas células hospedeiras.

De forma geral, as vacinas podem ser classificadas em quatro categorias principais: vacinas de RNA mensageiro (mRNA), vacinas de vetor viral não replicante, vacinas de vírus inativado e vacinas de subunidade proteica, conforme ilustrado na Figura 11.

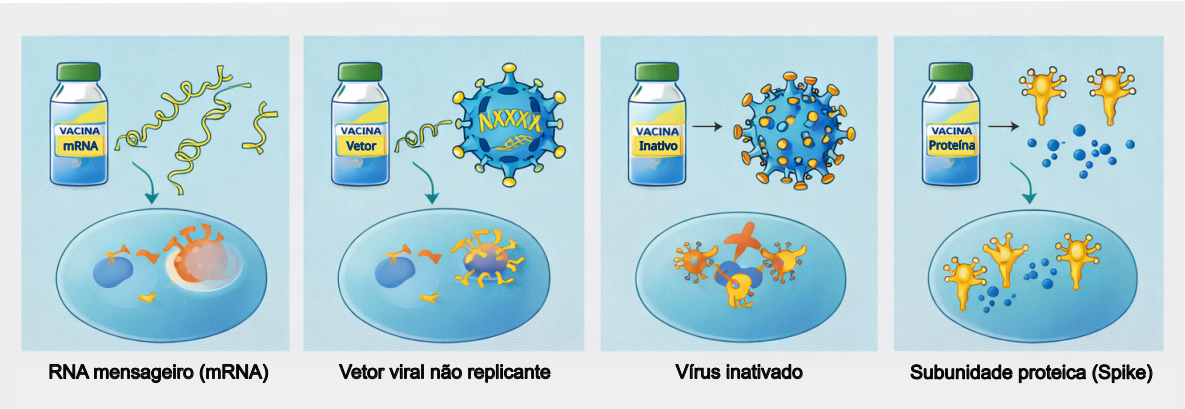

Figura 11: – Representação esquemática das principais plataformas tecnológicas utilizadas no desenvolvimento de vacinas contra a COVID-19. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

As vacinas de mRNA utilizam moléculas sintéticas que codificam a proteína *spike*, levando as células do hospedeiro a expressá-la transitoriamente e induzir respostas humorais e celulares. Já as vacinas de vetor viral não replicante utilizam adenovírus modificados para transportar o gene da *spike*, promovendo sua expressão e ativação da resposta imune adaptativa. Vacinas de vírus inativado empregam partículas virais incapazes de replicação, mas que mantêm sua antigenicidade, enquanto vacinas de subunidade proteica utilizam fragmentos purificados do antígeno viral.

Apesar das diferenças tecnológicas, todas essas plataformas têm como objetivo induzir imunidade protetora por meio da produção de anticorpos neutralizantes e da ativação de linfócitos T, incluindo respostas mediadas por células T CD4+ e CD8+, fundamentais para a coordenação da resposta imune e eliminação de células infectadas.

Neste trabalho, o foco recai sobre vacinas baseadas em vetor adenoviral, em particular a vacina ChAdOx1 nCoV-19 (AZD1222), amplamente utilizada no Brasil durante a fase inicial da pandemia. Essa vacina emprega um adenovírus não replicante como vetor para a entrega do gene da proteína *spike*, induzindo respostas humorais e celulares de forma integrada.

Com a emergência de variantes do SARS-CoV-2, versões atualizadas dessa plataforma foram propostas, como a vacina AZD2816, desenvolvida para expressar a proteína *spike* da variante Beta (B.1.351). Embora compartilhe o mesmo mecanismo de ação da AZD1222, essa formulação visa ampliar a cobertura imunológica frente a variantes específicas (DOREMALEN *et al.*, 2022).

Do ponto de vista epidemiológico e tecnológico, observou-se uma transição ao longo do tempo no uso das diferentes plataformas vacinais. Vacinas baseadas em vetor viral, como a AZD1222, desempenharam papel central nas campanhas iniciais, mas tiveram sua utilização progressivamente reduzida em favor de plataformas mais adaptáveis, como as vacinas de mRNA. Esse movimento reflete tanto a evolução do vírus quanto a necessidade de atualização contínua das estratégias vacinais.

Embora as vacinas baseadas na plataforma ChAdOx1 tenham desempenhado papel central nas campanhas globais de vacinação contra a COVID-19, sua utilização foi progressivamente reduzida nos anos seguintes à fase inicial da pandemia. A vacina ChAdOx1 nCoV-19 (também conhecida como AZD1222 ou Vaxzevria), amplamente empregada em diversos países, teve sua autorização de comercialização retirada na União Europeia em 2024 a pedido da própria fabricante. Esse processo ocorreu em um contexto de diminuição da demanda global e de transição para vacinas atualizadas, desenvolvidas para ampliar a proteção frente às variantes circulantes do SARS-CoV-2 (European Medicines Agency, 2024). Como consequência, a produção e distribuição global da AZD1222 foram encerradas em maio de 2024. Nesse mesmo contexto, versões atualizadas baseadas na mesma plataforma, como a vacina AZD2816, não avançaram para ampla distribuição, permanecendo principalmente no âmbito de estudos experimentais e clínicos (DOREMALEN *et al.*, 2022).

A diversidade de plataformas e mecanismos de ação impõe desafios significativos à compreensão da cinética da resposta imune ao longo do tempo. Em particular, a duração da imunidade e a necessidade de doses de reforço dependem de fatores como o tipo de vacina, o esquema de administração e as características individuais dos indivíduos vacinados.

A complexidade inerente às diferentes plataformas vacinais, aliada à variabilidade interindividual da resposta imune, torna desafiadora a avaliação sistemática da dinâmica imunológica em estudos clínicos tradicionais. Limitações relacionadas ao tamanho amostral, heterogeneidade dos indivíduos e restrições experimentais dificultam a exploração abrangente de diferentes cenários de vacinação. Nesse contexto, abordagens baseadas em modelagem matemática e simulações *in silico* emergem como ferramentas essenciais. Em particular, a utilização de coortes virtuais permite incorporar variabilidade biológica de forma controlada, viabilizando a análise da resposta imune em nível populacional sob diferentes estratégias vacinais.

2.3 Coortes Virtuais

Nos últimos anos, a integração entre modelagem matemática e biologia computacional tem impulsionado o desenvolvimento de abordagens capazes de representar a variabilidade biológica de forma quantitativa. Entre essas abordagens, destacam-se as *Coortes Virtuais* e os *Digital Twins* (Gêmeos Digitais), que compartilham fundamentos metodológicos semelhantes, mas diferem em seus objetivos e aplicações. Enquanto as *Coortes Virtuais* são utilizadas para investigar a heterogeneidade em nível populacional por meio da simulação de múltiplos indivíduos artificiais, os *Digital Twins* são projetados para representar digitalmente um indivíduo específico, integrando dados clínicos personalizados, conforme ilustrado na Figura 12.

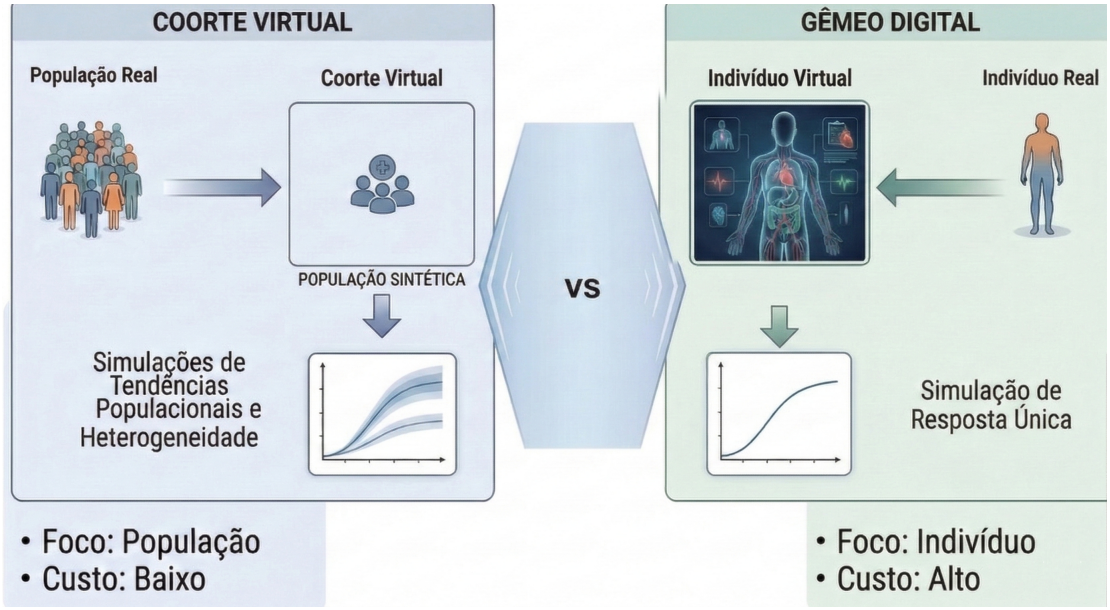

Figura 12: – Representação esquemática da diferença entre coortes virtuais e gêmeos digitais. Coortes virtuais utilizam populações sintéticas derivadas de dados reais para simular tendências populacionais e heterogeneidade entre indivíduos. Já os gêmeos digitais correspondem a modelos computacionais individualizados que reproduzem características de um indivíduo específico, permitindo a simulação de respostas personalizadas a intervenções. Figura gerada com auxílio de inteligência artificial generativa por meio da ferramenta Gemini.

Uma Coorte Virtual (CV, do inglês *Virtual Cohort*) consiste em uma população artificial composta por um grande número de indivíduos virtuais, cada um caracterizado por um conjunto específico de parâmetros fisiológicos e imunológicos (WILLCOX; SEGUNDO, 2024; LAUBENBACHER *et al.*, 2022). Esses parâmetros são tipicamente amostrados a partir de distribuições estatísticas inferidas de dados experimentais e clínicos, de modo que as trajetórias simuladas reproduzam, de forma realista, a variabilidade observada em populações reais. Essa abordagem permite a realização de experimentos *in silico*, nos quais diferentes intervenções, como esquemas vacinais e estratégias terapêuticas, podem ser avaliadas de maneira sistemática, com baixo custo e alta reprodutibilidade.

Por sua vez, os gêmeos digitais correspondem a representações computacionais individualizadas, continuamente calibradas com dados clínicos específicos de um único indivíduo (HELGERS *et al.*, 2021; LAUBENBACHER *et al.*, 2024). Essa abordagem está fortemente associada ao desenvolvimento da medicina personalizada, permitindo a simulação de respostas individuais a intervenções ao longo do tempo.

Dessa forma, enquanto as Coortes Virtuais são particularmente adequadas para a análise de variabilidade interindividual e tendências populacionais, os gêmeos digitais se destacam em contextos que demandam modelagem personalizada e predição individualizada. Ambas as abordagens representam avanços importantes na aplicação de modelos computacionais em biomedicina, sendo complementares no estudo de sistemas biológicos complexos.

3 Métodos

Esta seção descreve os métodos utilizados para reproduzir os níveis de anticorpos após diferentes esquemas vacinais com a vacina ChAdOx1 nCoV-19. A Figura 13 resume esquematicamente a abordagem adotada. Primeiramente, os dados de coorte foram extraídos da literatura (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023) e adaptados para uso nas simulações (Seção 3.1). Em seguida, desenvolvemos um novo modelo matemático (Seção 3.2), baseado em um modelo previamente publicado (BONIN *et al.*, 2020), para reproduzir *in silico* a resposta imune induzida pela vacina ChAdOx1 nCoV-19.

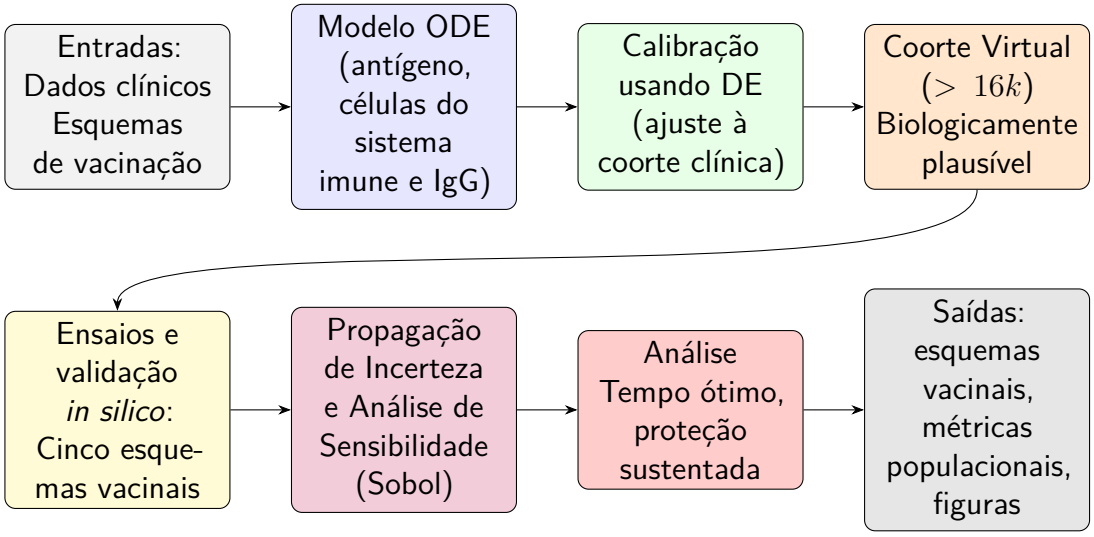

Figura 13: – Fluxo de trabalho do modelo imunológico dentro do hospedeiro, mostrando a integração dos dados clínicos, calibração, geração da coorte virtual, propagação de incerteza, análise de sensibilidade e otimização para identificar esquemas vacinais eficazes.

O modelo foi calibrado para um esquema vacinal representativo reportado na literatura (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023). A calibração utilizou o método de Evolução Diferencial (STORN; PRICE, 1997), um algoritmo de otimização que minimiza a discrepância entre as saídas do modelo e os dados de coorte (ver Seção 3.3). Os parâmetros foram variados dentro de limites predefinidos. Mantivemos todos os conjuntos de parâmetros cujas saídas do modelo apresentaram erros abaixo de um limite de aceitação predefinido; esses conjuntos formam a Coorte Virtual (CV; ver Seção 3.3). O conjunto de parâmetros que melhor se ajustou aos dados (aquele que minimiza o erro) foi salvo como ajuste de referência. Os parâmetros selecionados para a CV foram validados utilizando esquemas vacinais diferentes do esquema de calibração.

Foi realizada uma análise de sensibilidade para identificar os parâmetros mais influentes (Seção 3.4). A incerteza foi propagada perturbando os principais parâmetros ao redor dos valores de melhor ajuste, a fim de avaliar a variabilidade das saídas.

Os resultados serão apresentados no Capítulo 4. Este capítulo também apresentará

os resultados de um ciclo de otimização para identificar possíveis esquemas de reforço (Seção 4.3). O objetivo desse ciclo foi maximizar a fração da população virtual que mantém níveis de anticorpos acima de um limiar protetor predefinido.

3.1 Dados da Coorte e Sua Adaptação Para Uso nas Simulações

Este estudo utilizou dados de um estudo de coorte (COV001 e COV002) realizado no Reino Unido (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023), focando em participantes de 18 a 55 anos que receberam uma ou duas doses da vacina ChAdOx1 nCoV-19 durante a fase 1/2. O estudo de coorte avaliou a reatogenicidade e a imunogenicidade daqueles que aceitaram o convite para uma nova vacinação. Alguns participantes que receberam duas doses da vacina, com um intervalo de 8 a 12 semanas entre a primeira e a segunda dose, foram monitorados por um ano após a segunda dose, confirmando a persistência de anticorpos após esse período (VOYSEY *et al.*, 2023). Notavelmente, indivíduos que haviam recebido apenas uma dose da vacina receberam uma segunda dose tardia, aproximadamente 44–45 semanas após a primeira dose (FLAXMAN *et al.*, 2021). Aqueles que já haviam recebido duas doses da vacina receberam uma terceira dose entre 28–38 semanas após a segunda dose (FLAXMAN *et al.*, 2021). Este trabalho compara os dados obtidos pelo estudo de coorte (FLAXMAN *et al.*, 2021) com os resultados numéricos gerados pelo nosso modelo matemático.

Os dados da coorte expressam os valores de anticorpos em diferentes momentos para distintos intervalos entre doses: 8-12 semanas, 15-25 semanas e 44-45 semanas (FLAXMAN *et al.*, 2021). A coorte de duas doses consistiu em 261 indivíduos para os quais havia dados de imunogenicidade disponíveis. Dentre eles, 115 (44%) receberam a segunda dose com intervalo de 8–12 semanas, 116 (44%) com 15–25 semanas e 30 (11%) com 44–45 semanas (FLAXMAN *et al.*, 2021). Oitenta participantes que já haviam tomado duas doses da vacina ChAdOx1 nCoV-19 receberam a terceira dose entre 28–38 semanas após a segunda dose (mediana de 30 semanas) (FLAXMAN *et al.*, 2021). O estudo que avaliou a presença de anticorpos IgG (VOYSEY *et al.*, 2023) não especifica o número exato de participantes (entre os 704 incluídos) que receberam ambas as doses padrão com intervalo de 8 a 12 semanas entre elas.

Embora o estudo de coorte (FLAXMAN *et al.*, 2021) forneça evidências da ativação de células T após a vacinação, ele não descreve os tipos específicos de células T envolvidas (CD8+, CD4+ ou células T reguladoras). Em vez disso, documenta apenas a resposta de células T medida por unidades formadoras de pontos (SFUs) por milhão de células mononucleares de sangue periférico (PBMCs). Portanto, apesar de incorporarmos células T auxiliares em nosso modelo, não é possível comparar diretamente seu comportamento com os dados do estudo de coorte.

A dose padrão da ChAdOx1 nCoV-19 contém 5×10^{10} partículas virais. O modelo

requer uma concentração inicial da vacina (partículas por ml) após a inoculação. Estimamos essa concentração assumindo uma diluição homogênea no fluido corporal total. A água corporal total varia com a idade, o sexo e a composição corporal, variando tipicamente de 50% a 70% da massa corporal (ADOLPH, 1933; SAWKA; CHEUVRONT; CARTER, 2005). Utilizamos a fórmula de Watson (WATSON; WATSON; BATT, 1980) e assumimos um adulto médio com altura de 1,70 m e massa de 70 kg. A fração média de água corporal total resultante é de aproximadamente 0,53. Assim, a concentração inicial do adenovírus é

$$V_0 = \frac{5 \times 10^{10}}{70 \times 1000 \times 0,53} \approx 1,35 \times 10^6 \text{ partículas ml}^{-1}. \tag{3.1}$$

O estudo de origem (FLAXMAN *et al.*, 2021) reporta medianas, títulos de média geométrica (GMT) e intervalos, mas não fornece medidas de dispersão como desvio padrão ou erro padrão. Quando a dispersão foi necessária para a calibração ou propagação de incerteza, estimamos o desvio padrão a partir do intervalo reportado. Como um padrão transparente e reprodutível, aplicamos o estimador de Ramirez e Cox (RAMIREZ; COX, 2012), que ajusta a estimativa baseada no intervalo de acordo com o tamanho da amostra n:

$$\sigma \approx \frac{\text{intervalo da amostra}}{3\sqrt{\ln n} - 1,5}, \tag{3.2}$$

onde n denota o tamanho da amostra. Ramirez e Cox demonstraram que este estimador tem um desempenho confiável para dados aproximadamente normais com tamanhos de amostra moderados, e eles também fornecem alternativas para amostras pequenas ou fortemente assimétricas. Embora uma abordagem totalmente Bayesiana representaria um tratamento mais fundamentado, ela está além do escopo deste estudo. Dada a ausência de dispersão reportada e os tamanhos de amostra moderados disponíveis, o estimador baseado no intervalo fornece uma solução adequada e reprodutível para o presente trabalho.

3.2 Modelo Matemático

Para simular a cinética da resposta imune induzida pela vacina ChAdOx1 nCoV-19, foi desenvolvido um modelo mecanicista formulado como um sistema de onze equações diferenciais ordinárias (EDOs). O modelo descreve, de forma integrada, as interações entre os principais componentes da resposta imune: vetor viral, antígeno, células apresentadoras de antígenos (APCs), células T $CD4^+$, células B e suas respostas temporais.

A estrutura do modelo segue a cascata de eventos biológicos associados à imunização: a introdução do vetor adenoviral (V), a expressão da glicoproteína *spike* (S), a ativação e maturação das APCs (A_p e A_{pm}), a ativação de células T $CD4^+$ auxiliares *naïve* (T_{hn}) e sua diferenciação em células T *helper* efetoras (T_{he}), seguidas pela ativação de células B *naïve* (B_n) e geração de células B ativas (B_a), plasmócitos secretores de anticorpos (P_c) e

células B de memória (B_m). O produto final do modelo é a concentração de anticorpos IgG, um correlato chave da proteção imunológica.

Do ponto de vista conceitual, o modelo adota uma abordagem mecanicista de baixa dimensionalidade, na qual populações celulares e componentes moleculares são representados por variáveis agregadas que descrevem quantidades funcionais efetivas. Assim, cada variável não corresponde necessariamente a uma entidade biológica isolada, mas sim ao efeito combinado de múltiplos processos subjacentes.

Essa escolha implica a não representação explícita de diversos mediadores imunológicos, como citocinas específicas, subpopulações celulares especializadas (por exemplo, células T foliculares auxiliares ou subtipos de células B) e vias de sinalização intracelular. Em vez disso, os efeitos desses componentes são incorporados implicitamente nos termos de ativação, proliferação, diferenciação e decaimento presentes nas equações do modelo.

Nesse contexto, o modelo deve ser interpretado como uma representação funcional da resposta imune, voltada à descrição e predição de observáveis experimentais (em particular, a dinâmica de anticorpos), e não como uma descrição exaustiva de todos os mecanismos moleculares envolvidos. A próxima subseção apresenta as principais hipóteses e simplificações adotadas.

3.2.1 Hipóteses e Simplificações Adotadas pelo Modelo Matemático

A modelagem matemática da resposta imune induzida por vacinação exige a adoção de hipóteses estruturais que permitam representar, de forma tratável, um sistema biológico altamente complexo. O sistema imune envolve múltiplas populações celulares, mediadores solúveis, organização espacial e interações não lineares em diferentes escalas temporais e biológicas. Nesse contexto, o modelo desenvolvido neste trabalho adota uma abordagem mecanística reduzida, orientada à descrição dos principais determinantes da resposta humoral, mantendo um compromisso entre realismo biológico, identificabilidade paramétrica e viabilidade computacional.

Uma das principais simplificações consiste na representação agregada de populações celulares. Em vez de descrever explicitamente subpopulações específicas, como linfócitos T auxiliares diferenciados (como Th1, Th2, Tfh), células dendríticas com diferentes estados de ativação ou subtipos de células B em distintos estágios de maturação, o modelo considera populações funcionais equivalentes. Essas populações são definidas com base em sua capacidade de reconhecer o antígeno vacinal, proliferar e contribuir para a produção de anticorpos. Dessa forma, processos como ativação, diferenciação e cooperação celular são representados por taxas efetivas, que sintetizam mecanismos subjacentes complexos.

Em particular, mecanismos centrais da resposta adaptativa, como a formação e dinâmica de centros germinativos, não são modelados explicitamente. Processos como seleção clonal, maturação de afinidade e diferenciação em células plasmáticas de curta e

longa duração são incorporados de forma implícita nos termos que governam a expansão celular e a produção de anticorpos. Essa escolha reflete tanto a limitação de dados quantitativos diretamente observáveis para esses processos quanto o foco do modelo em desfechos mensuráveis em nível sistêmico.

De maneira análoga, mediadores solúveis, como citocinas e quimiocinas (por exemplo, IL-2, IL-6, IFN-γ), não são representados como variáveis explícitas. Embora desempenhem papel fundamental na regulação da resposta imune, sua inclusão implicaria um aumento substancial na dimensionalidade do modelo e na incerteza paramétrica. Assim, seus efeitos são incorporados de forma indireta nos termos de ativação, proliferação e regulação celular, que refletem a ação integrada dessas moléculas no microambiente imunológico.

Outra hipótese relevante é a ausência de organização espacial explícita. O modelo assume um sistema bem misturado, no qual as interações entre antígeno, células e anticorpos ocorrem de forma homogênea. Estruturas anatômicas especializadas, como linfonodos, são representadas de forma efetiva por parâmetros cinéticos. Essa abordagem é apropriada quando o interesse principal reside na dinâmica temporal de variáveis globais, como títulos de anticorpos, em vez da organização espacial da resposta imune.

No que se refere à resposta imune celular, o modelo não inclui explicitamente populações como linfócitos T citotóxicos ($CD8^+$) ou subtipos específicos de células T auxiliares. No entanto, a contribuição dessas populações é considerada de forma implícita nos mecanismos de ativação e suporte à resposta humoral.

A memória imunológica também é tratada de forma agregada. O modelo não distingue explicitamente entre diferentes compartimentos de memória, como células B de memória e células plasmáticas de longa duração residentes na medula óssea. Em vez disso, a persistência da resposta de anticorpos ao longo do tempo é capturada por parâmetros que governam a longevidade das populações celulares e a taxa de decaimento dos anticorpos. Essa abordagem permite reproduzir perfis de resposta de longo prazo sem a necessidade de introduzir múltiplos compartimentos adicionais de difícil calibração.

O reconhecimento antigênico é modelado de forma implícita por meio de parâmetros que representam afinidade funcional entre os componentes do sistema imune e o antígeno vacinal. Processos moleculares detalhados, como apresentação antigênica via MHC, interação receptor-ligante e sinalização intracelular, são incorporados em taxas efetivas de ativação. Essa abstração é consistente com a escala de descrição adotada e com os dados disponíveis para calibração.

Por fim, a variabilidade interindividual não é representada por modificações estruturais no modelo, mas sim por meio da variação dos parâmetros que definem cada indivíduo virtual. Dessa forma, diferenças associadas a fatores como histórico imunológico prévio, idade ou condições fisiológicas são refletidas indiretamente na heterogeneidade

paramétrica utilizada na construção das coortes virtuais.

Em conjunto, essas hipóteses definem um modelo que busca capturar os mecanismos essenciais da resposta imune humoral induzida por vacinação, ao mesmo tempo em que reconhece explicitamente os limites impostos pela complexidade biológica e pela disponibilidade de dados. Essa estratégia permite construir um arcabouço mecanístico interpretável, capaz de reproduzir dados experimentais e explorar cenários vacinais de forma sistemática, sem recorrer a uma descrição excessivamente detalhada e pouco identificável do sistema imune.

Antes de apresentar as equações, é importante destacar que cada termo do modelo deve ser interpretado como uma representação agregada de processos biológicos complexos. Em particular, constantes de taxa não correspondem a mecanismos únicos, mas sim a efeitos combinados de múltiplas etapas, como reconhecimento antigênico, sinalização intracelular, proliferação celular e interações mediadas por citocinas. Dessa forma, o modelo não busca descrever eventos moleculares específicos, mas capturar seus efeitos líquidos sobre a dinâmica das populações celulares e dos níveis de anticorpos.

A seguir, cada componente do modelo é detalhado.

3.2.2 Dinâmica Viral e da Proteína *Spike*

A vacina ChAdOx1 nCoV-19 utiliza um vetor adenoviral de chimpanzé deficiente em replicação, projetado para expressar a glicoproteína *spike* (DOREMALEN *et al.*, 2020; VOYSEY *et al.*, 2021). Após a administração intramuscular, o vetor viral penetra nas células hospedeiras, levando à produção intracelular da proteína *spike*, que atua como principal antígeno da resposta imune.

No modelo, a variável V representa a carga efetiva de vetor viral disponível para transdução celular, enquanto S representa a concentração efetiva de antígeno *spike* disponível para reconhecimento imunológico. É importante destacar que S não corresponde diretamente à concentração física da proteína, mas sim a uma medida funcional da disponibilidade antigênica percebida pelo sistema imune.

Como o vetor não se replica, sua dinâmica é descrita por um decaimento ao longo do tempo:

$$\frac{d}{dt}V = -\delta_v V - \delta_{v_{igg}} VIgG. \tag{3.3}$$

O termo $\delta_v V$ representa a depuração efetiva do vetor viral, agregando processos como degradação, eliminação por mecanismos do sistema imune inato, fagocitose e perda de capacidade de transdução. Diferentemente de modelos mais detalhados, não há separação explícita entre imunidade inata e processos físico-químicos, sendo ambos incorporados em um único parâmetro efetivo (δ_v). O termo $\delta_{v_{igg}} VIgG$ representa a neutralização mediada

por anticorpos, capturando a ligação de IgG ao vetor e a consequente redução de sua disponibilidade para infectar células-alvo, sem distinção entre subclasses de imunoglobulinas (IgG1, IgG2, IgG3 ou IgG4) ou mecanismos efetores específicos.

A dinâmica do antígeno *spike* é descrita por:

$$\frac{d}{dt}S = \alpha_s V - \delta_{s_{igg}} SIgG - \delta_{s_{ap}} SA_p. \tag{3.4}$$

O termo $\alpha_s V$ modela a produção de antígeno como proporcional à carga viral efetiva. Os termos de remoção,$\delta_{s_{igg}}$ e $\delta_{s_{ap}}$,representam, respectivamente, neutralização por anticorpos e captação por células apresentadoras de antígenos (APCs). Aqui, a interação SA_p deve ser interpretada como um processo agregado de reconhecimento, internalização e processamento antigênico, sem distinção explícita entre vias de apresentação (MHC I vs. MHC II).

É importante ressaltar novamente que a variável S não representa diretamente a concentração física da proteína *spike*, mas sim uma medida funcional da disponibilidade antigênica percebida pelo sistema imune. Assim, processos como apresentação antigênica via MHC, degradação intracelular e exposição do antígeno são incorporados implicitamente. A neutralização de S por anticorpos deve ser interpretada como a formação de complexos antígeno-anticorpo e sua subsequente remoção, servindo como uma aproximação dos mecanismos de neutralização viral observados *in vivo*.

3.2.3 Ativação das Células Apresentadoras de Antígenos

As células apresentadoras de antígenos desempenham papel central na ponte entre imunidade inata e adaptativa. No modelo, distinguem-se duas populações: APCs imaturas (A_p) e APCs maduras (A_{pm}). Essa distinção representa, de forma agregada, o processo de ativação, migração e aumento da capacidade de apresentação antigênica.

A dinâmica das APCs imaturas é dada por:

$$\frac{d}{dt}A_p = \alpha_{ap}(A_{p0} - A_p) - \gamma_{s_{ap}} A_p S. \tag{3.5}$$

O termo $\alpha_{ap}(A_{p0} - A_p)$ representa a homeostase[1] da população, enquanto $\gamma_{s_{ap}} A_p S$ modela a ativação induzida por antígeno. Esse termo agrega múltiplos sinais biológicos, incluindo reconhecimento por receptores de padrão, sinais inflamatórios e coestimulação, que não são explicitamente modelados.

As APCs maduras são descritas por:

[1] Homeostase refere-se à manutenção do equilíbrio funcional das populações celulares por meio de processos regulatórios que controlam sua produção, proliferação e morte.

$$\frac{d}{dt}A_{pm} = \gamma_{s_{ap}} A_p S - \delta_{apm} A_{pm}. \tag{3.6}$$

Essa população representa células com capacidade efetiva de apresentação antigênica a linfócitos T, incluindo expressão de MHC e moléculas coestimuladoras. O modelo não distingue subtipos celulares (como células dendríticas convencionais ou macrófagos), tratando-os como uma população funcional única.

Do ponto de vista biológico, o processo de ativação das APCs agrega múltiplos sinais do sistema imune inato, incluindo reconhecimento por receptores, sinalização inflamatória e interação com padrões moleculares associados a patógenos. Esses mecanismos não são modelados explicitamente, sendo representados de forma efetiva pelo termo de ativação, $\gamma_{s_{ap}}$, dependente do antígeno, representado por S. Já o decaimento natural dessas células é representado por δ_{apm}.

3.2.4 Dinâmica das Células T e B

A resposta adaptativa é modelada a partir da interação entre APCs e linfócitos T CD4$^+$, que regula a ativação através do parâmetro β_{th} na Equação 3.7. Após serem ativadas, as T *helper* efetoras (T_{he}) coordenam a ativação de células B. Como mencionado anteriormente, o modelo não distingue subpopulações de células T auxiliares (como Tfh, Th1, Th2), assumindo que sua função coletiva pode ser representada por uma população efetora única.

As células T *naïve* (T_{hn}) evoluem segundo:

$$\frac{d}{dt}T_{hn} = \alpha_{th}(T_{hn0} - T_{hn}) - \beta_{th} A_{pm} T_{hn}. \tag{3.7}$$

A ativação mediada por APCs agrega processos de apresentação antigênica. Esta população *naïve* também apresenta, assim como as apresentadoras, um termo de homeostase $\alpha_{th}(T_{hn0} - T_{hn})$. Já a população efetora é descrita por:

$$\frac{d}{dt}T_{he} = \beta_{th} A_{pm} T_{hn} + \pi_{th} A_{pm} T_{he} - \delta_{the} T_{he}. \tag{3.8}$$

A expansão clonal é modelada de forma simplificada, sem representação explícita de citocinas como IL-2, IL-21 ou outras, cujos efeitos são incorporados na taxa π_{th}.

A população T_{he} deve ser interpretada como uma representação funcional agregada das células T auxiliares. Em particular, a função de suporte às células B, essencial para a formação de memória imunológica e produção de anticorpos, está incorporada nesse termo, sem distinção explícita entre vias de sinalização ou perfis de citocinas.

No compartimento de células B, o modelo distingue populações *naïve*, ativas e de memória, representando os principais estados funcionais relevantes para a resposta humoral.

Não são explicitamente modelados processos como formação de centros germinativos ou maturação de afinidade. Tais efeitos são implicitamente refletidos nas taxas de diferenciação e produção de anticorpos.

$$\frac{d}{dt}B_n = \alpha_{bn}(B_{n_0} - B_n) - \beta_{bn_{ba}}B_nT_{he} - \beta_{bm}T_{he}B_n - \delta_{bn}B_n. \tag{3.9}$$

A população é mantida por homeostase (α_{bn}) e sofre ativação dependente de células T efetoras, o que leva à diferenciação em células B ativas (B_a) ou de memória (B_m). A transição de B_n para B_a ocorre com taxa $\beta_{bn_{ba}}$, diretamente dependente da presença de células T efetoras (T_{he}), representando os sinais de coestimulação e suporte mediados por essas células. Uma vez ativadas, as células B_a atuam como precursoras de plasmócitos e podem ser reativadas na presença de antígeno, conforme descrito na Equação (3.10).

$$\frac{d}{dt}B_a = \beta_{bn_{ba}}B_nT_{he} + \gamma_{bm_{ba}}B_mS - \beta_{ba_{pc}}A_{pm}B_a - \delta_{ba}B_a. \tag{3.10}$$

A ativação de células B dependente de células T *helper* efetoras representa, de forma agregada, sinalização por citocinas e seleção clonal, por exemplo. Esses mecanismos são fundamentais para a diferenciação e expansão das células B, mas não são modelados explicitamente.

Os termos na Equação 3.10 representam, respectivamente, a ativação de células B *naïve*, a reativação de células de memória e a diferenciação em plasmócitos estimulada por APCs maduras. A dinâmica das células B de memória (B_m) é modelada pela Equação (3.11):

$$\begin{aligned}\frac{d}{dt}B_m = {} & \beta_{bm}T_{he}B_n + \frac{B_m}{k_0 + k_1B_m}\left(1 - \frac{B_m}{Bm_{max}}\right) - \\ & - \pi_{bm_{pc}}B_mS - \gamma_{bm_{ba}}B_mS - \rho_{bm_{pc}}B_m - \delta_{bm}B_m.\end{aligned} \tag{3.11}$$

O termo

$$\frac{B_m}{k_0 + k_1B_m}\left(1 - \frac{B_m}{Bm_{max}}\right)$$

codifica uma expansão saturável e autolimitada de células B de memória. Quando a população de células B de memória, (*pool*) de memória, é pequena em relação à escala característica, a fração $\frac{B_m}{k_0+k_1B_m}$ é aproximadamente $\frac{B_m}{k_0}$, e o termo comporta-se como um termo de crescimento convencional dependente da densidade (quase exponencial) com taxa efetiva $1/k_0$. À medida que o *pool* de memória aumenta, a fração satura em direção ao valor $1/k_1$, de modo que aumentos adicionais em B_m não elevam proporcionalmente a taxa de produção instantânea; isso modela um limite de processamento (*throughput*) imposto por restrições fisiológicas (por exemplo, nichos de sobrevivência limitados, disponibilidade de citocinas ou recursos metabólicos). O fator multiplicativo $(1 - B_m/Bm_{max})$ introduz

uma capacidade de carga explícita, garantindo que o crescimento líquido se anule quando o reservatório de memória atinge Bm_{max}. Juntos, esses fatores produzem um comportamento biologicamente plausível: expansão rápida quando as células B de memória são escassas, crescimento desacelerado à medida que surgem restrições de recursos e uma eventual estabilização da população em um patamar fisiologicamente realista. Outros termos representam a diferenciação em plasmócitos (resposta rápida via $\pi_{bm_{pc}} B_m S$ ou reposição constante via $\rho_{bm_{pc}} B_m$), reativação e decaimento.

Do ponto de vista imunológico, esse comportamento representa a limitação fisiológica na manutenção de células B de memória, associada à disponibilidade de nichos de sobrevivência e sinais de manutenção que não são explicitamente modelados.

3.2.5 Produção de Anticorpos

Os plasmócitos (P_c) representam a população efetora responsável pela secreção de anticorpos. A equação correspondente agrega tanto plasmócitos de curta quanto de longa duração, sem distinção explícita entre esses subtipos. Além disso, o modelo não diferencia subclasses de IgG nem mecanismos efetores como ativação do complemento ou citotoxicidade dependente de anticorpos, focando exclusivamente na dinâmica quantitativa dos títulos de anticorpos.

$$\frac{d}{dt} P_c = \beta_{ba_{pc}} A_{pm} B_a + \pi_{bm_{pc}} B_m S + \rho_{bm_{pc}} B_m - \delta_{pc} P_c. \tag{3.12}$$

Essas células se originam tanto de células B ativas quanto de células B de memória, e sua população decresce naturalmente com taxa δ_{pc}. Do ponto de vista imunológico, essa formulação representa de forma agregada os processos de diferenciação e manutenção das células produtoras de anticorpos, sem distinguir explicitamente entre subtipos celulares ou os diferentes sinais envolvidos em sua formação e sobrevivência.

Por fim, a dinâmica dos anticorpos IgG é dada por:

$$\frac{d}{dt} IgG = \pi_{pc} P_c - \delta_{IgG} IgG. \tag{3.13}$$

Nesta equação, o termo π_{pc} representa a taxa de produção de imunoglobulina G pelas células plasmáticas (P_c), refletindo a secreção contínua de anticorpos na circulação. Por sua vez, o termo δ_{IgG} representa a taxa de decaimento dos anticorpos, incorporando processos como degradação natural, depuração e perda de função ao longo do tempo. Do ponto de vista imunológico, essa formulação descreve de forma agregada a dinâmica dos níveis de IgG no organismo, sem distinguir entre diferentes subclasses ou mecanismos específicos de eliminação, sendo adequada para capturar a cinética global da resposta humoral (SOMPAYRAC, 2019).

Neste modelo, os níveis de IgG constituem a principal variável observável, em consonância com os dados experimentais disponíveis (FLAXMAN *et al.*, 2021). Assim, todos os mecanismos internos do modelo são avaliados indiretamente por sua capacidade de reproduzir a dinâmica temporal desses títulos.

Essa escolha reforça o caráter do modelo como uma representação funcional da resposta imune, voltada à explicação e predição de observáveis experimentais, ao invés de uma descrição exaustiva de todos os componentes moleculares do sistema imunológico.

Por fim, destaca-se que o modelo não inclui explicitamente diversos componentes relevantes do sistema imune, como células do sistema inato (por exemplo, neutrófilos, macrófagos e células NK), cascatas do sistema complemento, produção e dinâmica de citocinas ou processos intracelulares de sinalização. Esses elementos são incorporados de forma indireta nos parâmetros efetivos do modelo. Essa escolha permite reduzir a complexidade estrutural e garantir a identificabilidade dos parâmetros, mantendo o foco na descrição da resposta humoral em nível sistêmico.

3.3 Calibração do Modelo e Geração da Coorte Virtual

Para calibrar os parâmetros do modelo matemático e alinhar as suas previsões com os dados de concentração de anticorpos do estudo de coorte, empregamos a Evolução Diferencial (ED), um algoritmo de otimização estocástica bioinspirado (STORN; PRICE, 1997). Este método baseado em população foi utilizado para estimar os parâmetros desconhecidos do modelo descrito na Seção 3, com base em um subconjunto dos dados da coorte. Os dados restantes foram reservados para validação independente. A configuração detalhada do algoritmo de ED utilizado neste trabalho está resumida na Tabela 2.

A calibração requer a definição de uma função objetivo que quantifique a discrepância entre os níveis de anticorpos previstos pelo modelo e aqueles medidos no estudo de coorte. Para este propósito, utilizámos dados de uma coorte que recebeu duas doses de vacina administradas com um intervalo de 8–12 semanas. A função objetivo, denotada por ϵ, é definida na Equação (3.14) como o erro relativo mínimo entre as concentrações experimentais de anticorpos IgG (IgG) (FLAXMAN *et al.*, 2021) e as previsões correspondentes do modelo ($I\hat{g}G$):

$$\epsilon = \min\left(R_E(IgG, I\hat{g}G)\right). \tag{3.14}$$

O erro relativo, R_E, é expresso como:

$$R_E(IgG, I\hat{g}G) = \frac{\|IgG(t) - I\hat{g}G(t)\|_2}{\|IgG_{std}(t)^2\|_2}, \tag{3.15}$$

onde $IgG_{std}(t)$ denota o desvio padrão das medições de IgG em cada ponto temporal.

Tabela 2 – Configuração do algoritmo de Evolução Diferencial (ED) para calibração do modelo.

Componente	**Descrição**
Função Objetivo	Minimizar o erro relativo ponderado entre as concentrações de anticorpos IgG previstas pelo modelo e os valores experimentais obtidos na coorte clínica, considerando cinco esquemas vacinais distintos. Todos os parâmetros do modelo, exceto aqueles cujo valor foi previamente estabelecido na literatura [2], foram ajustados por meio de procedimento de calibração.
Estratégia ED	Estratégia `best1bin`, na qual novas soluções candidatas são geradas perturbando o melhor indivíduo da população atual, promovendo uma convergência eficiente.
Tamanho da População (N_p)	$N_p = 100$, valor selecionado para equilibrar a exploração do espaço de parâmetros e o custo computacional. Esse tamanho mantém diversidade suficiente para evitar convergência prematura, ao mesmo tempo em que mantém o tempo de execução administrável.
Critério de Parada	A otimização é encerrada após um número fixo de gerações, com o máximo definido como `maxiter = 10`.
Limites dos Parâmetros	A busca foi restrita a limites inferiores e superiores fisiologicamente plausíveis para cada um dos nove parâmetros calibrados (ver Tabela 4).

Selecionamos a norma L2 ($\|\cdot\|_2$), pois ela proporcionou um valor menor de R_E em comparação com outras normas, indicando um melhor ajuste entre os dados da coorte e as previsões do modelo. A norma L2 é amplamente empregada em problemas de ajuste paramétrico devido à sua capacidade de penalizar mais fortemente discrepâncias de maior magnitude, uma vez que os resíduos são elevados ao quadrado antes da soma. Essa característica é particularmente relevante no contexto da calibração de modelos imunológicos, pois concentra a otimização na redução de picos de erro local, resultando em um alinhamento mais uniforme entre dados e simulação. Adicionalmente, a norma L2 gera uma função objetivo contínua e suave, o que contribui para maior estabilidade numérica e eficiência no processo de otimização, mesmo ao utilizar algoritmos estocásticos como a Evolução Diferencial.

Além do erro relativo, também calculamos a Raiz do Erro Quadrático Médio (RMSE), uma métrica complementar para quantificar a precisão do modelo em termos absolutos. Ao contrário de R_E, que normaliza os desvios pela incerteza da medição, o RMSE mede diretamente a magnitude média dos erros de previsão nas mesmas unidades dos dados experimentais (EU/ml):

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(IgG(t_i) - \hat{IgG}(t_i)\right)^2}, \tag{3.16}$$

onde $IgG(t_i)$ são os níveis de anticorpos observados no tempo t_i, $\hat{IgG}(t_i)$ são as previsões correspondentes do modelo, e n é o número total de observações. O uso tanto de R_E quanto de RMSE fornece perspetivas complementares sobre o desempenho do modelo: o primeiro enfatiza a consistência com a incerteza da medição, enquanto o segundo captura o tamanho típico dos desvios em unidades biologicamente interpretáveis.

Os parâmetros e os valores iniciais do modelo foram ajustados aos dados da coorte utilizando os intervalos de valores apresentados na Tabela 4. Assumimos uma distribuição uniforme para a amostragem dos parâmetros dentro desses intervalos, garantindo uma cobertura abrangente do espaço de busca. Durante o processo de calibração, estabelecemos que todos os conjuntos de parâmetros com R_E inferior a 5% fossem retidos como candidatos válidos. Esse critério de 5%, escolhido para manter uma boa acurácia do modelo diante às várias soluções no processo de ajuste, resultou em um conjunto de 16.064 soluções viáveis.

A Tabela 3 apresenta os valores de erro relativo e RMSE obtidos na comparação entre as simulações do modelo e os dados da coorte para diferentes cenários de vacinação.

Tabela 3 – Erros relativos e valores de RMSE comparando as simulações do modelo com os dados de IgG da coorte em diferentes cenários de vacinação.

Cenário	**Erro Relativo (%)**	**RMSE (EU/mL)**
8–12 semanas (2 doses)	3.01	71.60
Mais de 1 ano (2 doses)	0.42	135.14
15–25 semanas (2 doses)	0.59	114.10
44–45 semanas (2 doses)	0.13	333.98
Regime de três doses	1.84	804.47

Observa-se que, em todos os cenários avaliados, os valores de erro relativo permaneceram abaixo do limiar de 5%, indicando boa concordância entre o modelo e os dados experimentais. Os valores de RMSE, por sua vez, refletem a magnitude absoluta dos desvios, variando conforme o cenário considerado.

A partir das 16.064 soluções, o conjunto padrão de parâmetros reportado na Tabela 4 foi obtido pela média dos valores entre todos os candidatos aceitos, produzindo parâmetros representativos e refletindo a variabilidade e a robustez do processo de calibração.

Na Figura 14, estão representadas cerca de 2.000 simulações obtidas a partir das mais de 16.000 observações, com variação dos parâmetros do modelo. Não foi possível a apresentação de todas as 16.064 trajetórias devido ao elevado custo computacional gráfico. Ademais, a sobreposição das curvas no gráfico resulta em uma aparência de preenchimento contínuo, dificultando a distinção individual das trajetórias. Ressalta-se que o ajuste do

modelo foi conduzido com base nos dados de indivíduos que receberam a segunda dose da vacina em um intervalo de 8 a 12 semanas após a primeira dose, conforme descrito em FLAXMAN *et al.* (2021). As simulações adicionais da CV, considerando diferentes intervalos entre doses, são apresentadas no Apêndice A.

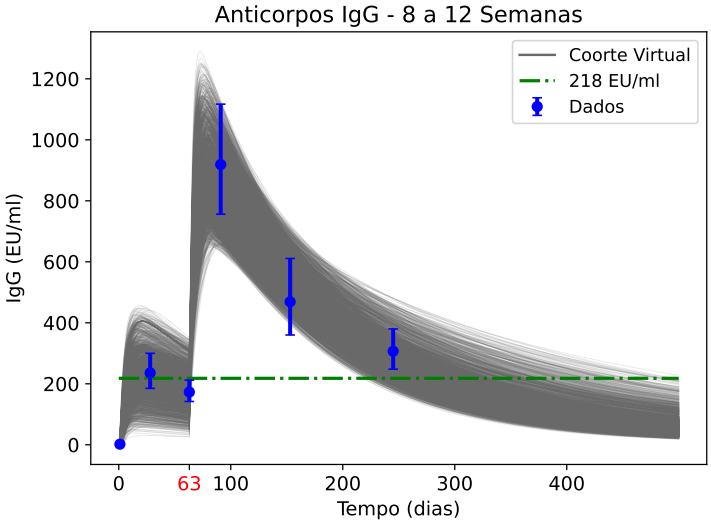

Figura 14: – Simulação do modelo utilizando 2.000 observações selecionadas aleatoriamente entre as 16.064 geradas no ajuste de parâmetros, todas apresentando erro relativo inferior a 5%. Os pontos destacados em azul representam os dados de indivíduos e são exibidos para evidenciar a pequena diferença em relação às previsões do modelo, sobretudo após a administração da dose de reforço no dia 63 (considerando o intervalo de 8 a 12 semanas entre doses como citado no artigo de base (FLAXMAN *et al.*, 2021)). A linha tracejada verde indica o limiar de proteção de 218,0 EU/ml.

Uma vez calibrado, o modelo foi validado sob diferentes condições experimentais, incluindo regimes de duas e três doses, para testar sua robustez e adaptabilidade. Esses testes forneceram *insights* sobre a capacidade preditiva do modelo em diferentes cenários e demonstraram que o modelo calibrado reproduz com sucesso a dinâmica de anticorpos observada. Ressalta-se que as demais simulações, referentes aos outros subgrupos da mesma coorte, foram realizadas utilizando o modelo calibrado, com base no conjunto padrão de parâmetros apresentado na Tabela 4.

O resultado da simulação, utilizando o conjunto de parâmetros padrão obtido pela média das observações, é apresentado graficamente na Figura 15. A figura demonstra a notável aderência da curva gerada pelo modelo (linha contínua preta) aos dados experimentais da coorte (pontos azuis), que representam a média das medições de anticorpos e suas respectivas barras de erro. A simulação captura com sucesso a dinâmica da resposta imune, incluindo o pico de anticorpos após a segunda dose e o decaimento subsequente. Adicionalmente, é traçado o nível de proteção referencial de 218,0 EU/ml (linha tracejada verde), indicando o período em que a concentração de anticorpos prevista pelo modelo permanece acima deste limiar.

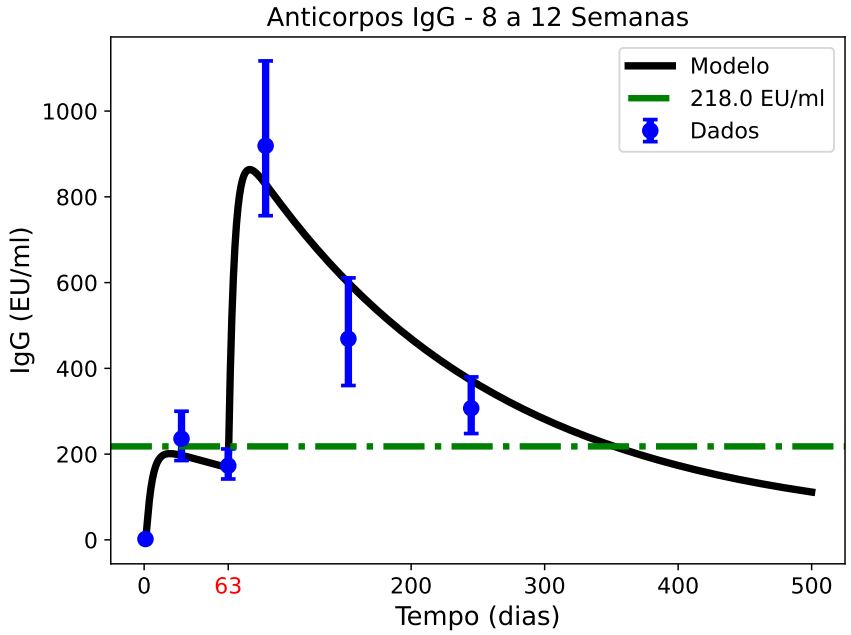

Figura 15: – Modelo calibrado (linha preta contínua) aos dados experimentais (pontos azuis com barras de erro) para o regime de vacinação com intervalo de 8 a 12 semanas. A simulação utiliza o conjunto de parâmetros padrão (média das observações aceites). A linha tracejada verde indica o limiar de proteção de 218,0 EU/ml.

O problema de calibração aqui abordado corresponde a uma otimização mono-objetivo e restrita num espaço de parâmetros contínuo. O panorama da otimização é não convexo, potencialmente multimodal e livre de derivadas, com avaliações moderadamente dispendiosas, uma vez que cada chamada de função requer a resolução de um sistema de EDOs. Estas características motivaram a nossa escolha pela ED, uma estratégia robusta baseada em população. Embora este trabalho se concentre na calibração mono-objetivo, avanços recentes em otimização evolutiva introduziram métodos multi-objetivo e de preservação da diversidade com convergência e robustez aprimoradas (ADALJA *et al.*, 2025; SRIKANTH *et al.*, 2024; KHISHE *et al.*, 2024; ALJAIDI *et al.*, 2025; JANGIR *et al.*, 2024; REN *et al.*, 2025). Tais abordagens poderiam ser incorporadas em trabalhos futuros para equilibrar objetivos concorrentes como precisão, robustez e generalização.

Tabela 4 – Valores de base, parâmetros calibrados e valores iniciais do modelo.

Parâmetro	**Intervalo → Valor Calibrado**	**Unidade**
δ_v	$(1,0 \times 10^{-4}, 1,00) \rightarrow 2,00 \times 10^{-2}$	(dia^{-1})
$\delta_{v_{igg}}$	$(1,00 \times 10^{-4}, 1,00) \rightarrow 6,50 \times 10^{-2}$	$[\text{dia}^{-1}(\text{EU/ml})^{-1}]$
α_s	$(1,00, 1,00 \times 10^{4}) \rightarrow 4,40 \times 10^{+1}$	(dia^{-1})
$\delta_{s_{igg}}$	$(1,00 \times 10^{-4}, 1,00) \rightarrow 4,08 \times 10^{-1}$	$[\text{dia}^{-1}(\text{EU/ml})^{-1}]$
$\delta_{s_{ap}}$	$(1,00 \times 10^{-4}, 1,00) \rightarrow 2,00 \times 10^{-3}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
α_{ap}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 2,90 \times 10^{-3}$	(dia^{-1})
$\gamma_{s_{ap}}$	$(1,00 \times 10^{-9}, 1,00 \times 10^{-5}) \rightarrow 5,90 \times 10^{-7}$	$[\text{dia}^{-1}(\textit{spike}/\text{ml})^{-1}]$
δ_{apm}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 1,10 \times 10^{-1}$	(dia^{-1})
α_{th}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 4,34 \times 10^{-3}$	(dia^{-1})
β_{th}	$(1,00 \times 10^{-9}, 1,00 \times 10^{-5}) \rightarrow 4,64 \times 10^{-6}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
π_{th}	$(1,00 \times 10^{-7}, 1,00 \times 10^{-3}) \rightarrow 1,00 \times 10^{-5}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
δ_{the}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 3,00 \times 10^{-1}$	(dia^{-1})
α_{bn}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 4,30 \times 10^{-3}$	(dia^{-1})
$\beta_{bn_{ba}}$	$(1,00 \times 10^{-7}, 1,00 \times 10^{-3}) \rightarrow 6,00 \times 10^{-6}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
δ_{bn}	$(1,00 \times 10^{-5}, 1,00 \times 10^{-1}) \rightarrow 1,00 \times 10^{-4}$	(dia^{-1})
$\gamma_{bm_{ba}}$	$(1,00 \times 10^{-6}, 1,00 \times 10^{-2}) \rightarrow 2,85 \times 10^{-4}$	$[\text{dia}^{-1}(\textit{spike}/\text{ml})^{-1}]$
$\beta_{ba_{pc}}$	$(1,00 \times 10^{-4}, 1,00) \rightarrow 4,00 \times 10^{-3}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
δ_{ba}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 2,00 \times 10^{-1}$	(dia^{-1})
β_{bm}	$(1,00 \times 10^{-7}, 1,00 \times 10^{-3}) \rightarrow 1,48 \times 10^{-5}$	$[\text{dia}^{-1}(\text{células/ml})^{-1}]$
k_0	$(1,00, 1,00 \times 10^{2}) \rightarrow 7,69$	adimensional
k_1	$(1,00 \times 10^{-8}, 1,00 \times 10^{-3}) \rightarrow 2,44 \times 10^{-5}$	(ml/células)
$B_{m_{\max}}$	$(1,00 \times 10^{5}, 1,00 \times 10^{8}) \rightarrow 1,00 \times 10^{7}$	(células/ml)
$\pi_{bm_{pc}}$	$(1,00 \times 10^{-5}, 1,00 \times 10^{-2}) \rightarrow 4,00 \times 10^{-3}$	$[\text{dia}^{-1}(\textit{spike}/\text{ml}^{-1})]$
$\rho_{bm_{pc}}$	$(1,00 \times 10^{-7}, 1,00 \times 10^{-3}) \rightarrow 2,00 \times 10^{-5}$	(dia^{-1})
δ_{bm}	$(1,00 \times 10^{-5}, 1,00 \times 10^{-2}) \rightarrow 3,02 \times 10^{-4}$	(dia^{-1})
δ_{pc}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 5,30 \times 10^{-3}$	(dia^{-1})
π_{pc}	$(1,00 \times 10^{-6}, 1,00 \times 10^{-2}) \rightarrow 2,00 \times 10^{-4}$	$[\text{dia}^{-1}(\text{EU/ml})^{-1}]$
δ_{IgG}	$(1,00 \times 10^{-4}, 1,00) \rightarrow 2,31 \times 10^{-1}$	(dia^{-1})

Valores Iniciais

Variável	**Descrição**	**Valor Inicial**
V	SARS-CoV-2	$1,35 \times 10^{6}$ cópias/ml
S	Proteína *Spike*	0 partículas
A_p	Células Apresentadoras (*naïve*)	$1,00 \times 10^{6}$ células/ml
A_{pm}	Células Apresentadoras (Maduras)	0 células/ml
T_{hn}	Células T CD4+ (*naïve*)	$1,00 \times 10^{6}$ células/ml
T_{he}	Células T CD4+ (Efetoras)	0 células/ml
B_n	Células B (*naïve*)	$2,5 \times 10^{5}$ células/ml
B_a	Células B (Ativas)	0 células/ml
B_m	Células B de Memória	0 células/ml
P_c	Plasmócitos	0 células/ml
IgG	Anticorpos IgG	0 EU/ml

3.3.1 Suporte da Literatura para os Parâmetros do Modelo

O valor calibrado $\delta_v = 0,02\ dia^{-1}$ para a depuração do vírus está no limite inferior das taxas de depuração de vírus livres reportadas. Por exemplo, a depuração do vírus da hepatite B foi estimada entre $\sim 0,69$ e $21,7\ dia^{-1}$ (CUPPENS *et al.*, 2015). Esta ampla faixa sugere que um decaimento viral muito lento ($\approx 0,02\ dia^{-1}$) está dentro de limites plausíveis, especialmente se o vírus persistir em reservatórios protegidos. Anticorpos neutralizantes aceleram a depuração viral. Em um modelo de SARS-CoV-2, a constante de neutralização de anticorpos foi $k_{Ab} \approx 0,11\ mL/(unit \cdot dia)$ (GONÇALVES *et al.*, 2020). Convertendo as unidades, este valor é da mesma ordem que $\delta_{v_{igg}} = 0,065\ dia^{-1}/(EU/ml)$, o que suporta o nosso valor ajustado. Estimativas diretas da literatura para a produção da proteína *spike* (α_s) ou para a depuração da *spike* mediada por IgG ($\delta_{s_{igg}}$) são escassas. As constantes de neutralização de anticorpos ($\sim 0,1\ mL/U/dia$ (GONÇALVES *et al.*, 2020)) implicam que a *spike* ligada é depurada em uma escala de tempo comparável. As taxas de captação de antígenos por APCs são menos documentadas, mas a depuração fagocítica é geralmente mais lenta do que a depuração de vírus livres. Nossos valores ajustados estão dentro das ordens de magnitude biológicas esperadas.

Modelos de dinâmica imune frequentemente usam taxas de renovação de APCs da ordem de $0,1$–$1,0\ dia^{-1}$. Por exemplo, um modelo de vacina para a COVID-19 usou uma renovação de APCs de $\gamma_{APC} \approx 0,49\ dia^{-1}$ e uma morte de APCs de $\delta_{APC} \approx 0,20\ dia^{-1}$ (GONÇALVES *et al.*, 2020). Em comparação, os nossos valores $\alpha_{ap} = 0,0029\ dia^{-1}$ e $\delta_{apm} = 0,11\ dia^{-1}$ são menores, mas biologicamente razoáveis. Eles implicam uma ativação lenta de APCs e uma vida útil de APC de cerca de 6–7 dias, consistente com a literatura (GONÇALVES *et al.*, 2020).

As células T CD4$^+$ *naïve* proliferam muito lentamente. Estudos de marcação estimam que apenas $\sim 0,2\%$ das células T CD4$^+$ *naïve* se dividem por dia em adultos jovens (BRABER *et al.*, 2012), implicando uma taxa de proliferação por célula de $\approx 0,002\ dia^{-1}$. O nosso $\alpha_{th} = 4,34 \times 10^{-3}\ dia^{-1}$ é da mesma ordem. As taxas de perda periférica de células CD4$^+$ *naïve* foram estimadas em $\delta \approx 0,0025\ dia^{-1}$ (BRABER *et al.*, 2012).

As células T CD4$^+$ efetoras possuem vida curta uma vez que o antígeno é eliminado. Modelos reportam taxas de mortalidade de efetoras de $\sim 0,0075$ a $0,39$ dia^{-1} (GONÇALVES *et al.*, 2020). Nossa taxa $\delta_{the} = 0,30$ dia^{-1} (meia-vida $\approx 2,3$ dias) situa-se dentro deste intervalo. Os parâmetros de estimulação de células T (β_{th}, π_{th}) governam a ativação induzida por contato e a proliferação. Não encontramos estimativas diretas, mas os valores ajustados de 10^{-6}–10^{-5} (por célula·dia) implicam encontros produtivos muito raros, o que é plausível dadas as densidades linfocitárias.

Linfócitos B *naïve* dividem-se de maneira extremamente lenta. Estudos de marcação *in vivo* demonstram que essas células se dividem a apenas $\sim 0,46\%$ por dia

($\approx 0,0046$ dia^{-1}) (HORST *et al.*, 2012). Isso condiz estreitamente com nosso valor $\alpha_{bn} = 4,30 \times 10^{-3}$ dia^{-1}. A mortalidade de linfócitos B *naïve* é muito lenta. Nossa taxa $\delta_{bn} = 1,0 \times 10^{-4}$ dia^{-1} corresponde a uma meia-vida de muitos anos, o que é consistente com a longevidade dessas células. A diferenciação de linfócitos B ativados em plasmócitos tem sido modelada em $\sim 0,1$–1 dia^{-1} (GONÇALVES *et al.*, 2020). Nosso valor $\beta_{ba_{pc}} = 4,0 \times 10^{-3}$ é inferior, refletindo uma forte dependência das células T.

As taxas de mortalidade de plasmócitos variam amplamente, desde plasmócitos de vida curta (dias) até plasmócitos de vida longa (anos). Um modelo citou valores de $\delta_P \approx 0,0083$ a $1,23$ dia^{-1} (GONÇALVES *et al.*, 2020). Nosso valor $\delta_{ba} = 0,20$ dia^{-1} (meia-vida $\approx$ 3–4 dias) é consistente com células secretoras de anticorpos de vida curta.

3.4 Análise de Sensibilidade e Quantificação de Incertezas

A análise de sensibilidade avalia como alterações nos parâmetros de entrada do modelo afetam suas saídas, identificando assim quais variáveis influenciam mais significativamente o comportamento do sistema. Esse processo auxilia tanto na otimização do modelo quanto na tomada de decisões, por meio da variação sistemática das entradas e da observação das flutuações correspondentes nas saídas. Tal análise aprimora a compreensão da dinâmica do modelo e destaca parâmetros que requerem calibração ou refinamento mais cuidadosos.

Neste estudo, utilizamos o SALib (*Sensitivity Analysis Library*) (HERMAN; USHER, 2017), uma biblioteca Python que oferece um conjunto de ferramentas para análise de sensibilidade abrangente. O SALib suporta métodos globais e locais, incluindo os índices de Sobol, o método de Morris, o Teste de Sensibilidade por Amplitude de Fourier (FAST) e Medidas de Importância Baseadas em Derivadas (DMIM). Essa flexibilidade permite uma exploração aprofundada da influência dos parâmetros em modelos matemáticos complexos.

Dentre esses métodos, os índices de Sobol (SOBOL, 2001; A *et al.*, 2008; NOSSENT; ELSEN; BAUWENS, 2011) foram selecionados para quantificar os efeitos individuais e interativos dos parâmetros de entrada sobre as saídas do modelo. Os índices de sensibilidade de Sobol decompõem a variância total da saída em contribuições de cada parâmetro e suas interações. Os índices de primeira ordem estimam a contribuição direta de um único parâmetro, enquanto os índices de ordem total capturam o efeito completo desse parâmetro, incluindo todas as interações com os demais.

Calculamos tanto os índices de primeira ordem quanto os de ordem total de Sobol para avaliar de forma abrangente a sensibilidade do modelo. Notavelmente, em modelos aditivos, a soma de todos os índices de primeira ordem é igual a um. No entanto, nosso modelo, que como vimos é baseado em um sistema de equações diferenciais ordinárias (EDOs), não é aditivo devido à sua natureza dinâmica, de modo que a soma dos índices de primeira ordem geralmente é ligeiramente inferior a um. Em contraste, a soma dos

índices de ordem total é sempre igual ou superior a um (SOBOL, 2001; A *et al.*, 2008). O índice de sensibilidade total S_{T_i} reflete os efeitos individuais e de interação do parâmetro P_i sobre a variância do modelo (HOMMA; SALTELLI, 1996; A *et al.*, 2008).

Como o modelo descreve fenômenos biológicos relacionados a uma vacina recente, os valores dos parâmetros são escassos ou apresentam elevada incerteza na literatura, com exceção daqueles discutidos na Subseção **3.3.1**. Essa limitação dificulta a validação direta das escolhas paramétricas e reforça a necessidade de empregar quantificação de incertezas (UQ) em conjunto com a análise de sensibilidade.

Para lidar com essa limitação, realizamos análises de sensibilidade considerando todos os parâmetros do modelo (31 ao todo). A análise de Sobol, por meio dos índices de primeira ordem e de ordem total, identificou nove parâmetros como os mais influentes na dinâmica de produção de anticorpos ao longo do tempo: δ_s, $\delta_{s_{ap}}$, $\gamma_{s_{ap}}$, B_{n_0}, k_0, k_1, δ_{pc}, π_{pc} e δ_{IgG}, em concordância com estudos FOLEGATTI *et al.* (2020); FLAXMAN *et al.* (2021); VOYSEY *et al.* (2023). A análise detalhada apresentada na Figura 18 refere-se ao regime de três doses, que captura os padrões representativos de sensibilidade observados. As demais análises para diferentes intervalos entre doses encontram-se apresentadas no Apêndice B.

A pequena diferença observada entre os índices de primeira ordem e de ordem total, bem como o comportamento semelhante de ambos ao longo do tempo, indica baixa interação entre os parâmetros dominantes. Dessa forma, optou-se por apresentar no corpo principal do trabalho apenas os resultados dos índices de Sobol de primeira ordem e total para o regime de três doses (Figuras 18 e 19), enquanto as demais figuras, referentes aos diferentes intervalos de dose (incluindo o intervalo de 8–12 semanas, utilizado na calibração do modelo) e aos índices de ordem total (Figuras 40, 41, 42, 43, 44, 45, 46 e 47), são disponibilizadas no Apêndice B. Embora o modelo tenha sido ajustado com base no cenário de duas doses com intervalo de 8–12 semanas, optou-se por destacar o regime de três doses no corpo principal por este apresentar maior variação na sensibilidade dos parâmetros ao longo do tempo simulado (500 dias), permitindo uma visualização mais abrangente das dinâmicas de influência paramétrica ao longo da resposta imune.

Em todas as figuras referentes aos índices de Sobol, adotou-se empiricamente um limiar igual a 0,07 para destacar os parâmetros mais influentes. Esse valor foi escolhido com o objetivo de filtrar e evidenciar os parâmetros com maior relevância ao longo da dinâmica da resposta imune, incluindo aqueles cuja influência se manifesta predominantemente nos estágios iniciais da simulação, como os parâmetros associados às células apresentadoras (A_p). Dessa forma, garante-se a visualização dos principais mecanismos que atuam tanto na fase inicial quanto nas etapas subsequentes da resposta imune induzida pela vacinação.

Para a quantificação de incertezas, foram conduzidos dois experimentos análogos: um considerando todos os 31 parâmetros do modelo e outro focado no subconjunto dos nove

parâmetros mais sensíveis, utilizando a biblioteca *chaospy* (FEINBERG; LANGTANGEN, 2015). Os resultados correspondentes são apresentados na Figura 20.

Na implementação referente à UQ, assumimos distribuições normais para modelar a incerteza dos parâmetros, sendo esta uma suposição comum na análise de sistemas biológicos (GENSER *et al.*, 2007; WILLIAMS, 2022). Os valores de média e desvio padrão foram estimados para cada parâmetro. O desvio padrão foi determinado utilizando a Regra Empírica (regra 68-95-99,7) (PUKELSHEIM, 1994) e a desigualdade de Bienaymé-Chebyshev (HEYDE; SENETA, 2012; SAW; YANG; MO, 1984), que descrevem a probabilidade de um valor cair dentro de um determinado número de desvios padrão em relação à média.

Como os valores ajustados dos parâmetros não incluem desvios padrão, os mesmos foram definidos da seguinte forma:

$$N(\mu, \sigma) = N\left(VA, \frac{VA \cdot 0{,}25}{3}\right) \tag{3.17}$$

onde o valor ajustado do parâmetro é representado por VA (*valor ajustado*), tomado como a média (μ) de sua distribuição normal, e σ é derivado de modo que $99,7\%$ das amostras estejam dentro de $\pm 25\%$ de VA.

Por exemplo, um parâmetro com $VA = 100$ seria modelado com um desvio padrão de $\sigma = \frac{100 \times 025}{3} \approx 8,33$, resultando em um intervalo de amostragem de aproximadamente 75 a 125.

Essa abordagem permite uma propagação robusta da incerteza através do modelo e informa como a variabilidade dos parâmetros influencia a dinâmica prevista de anticorpos, auxiliando tanto na interpretação quanto na validação dos resultados das simulações.

3.4.1 Implementação Computacional

O modelo foi implementado em Python, utilizando a função `solveivp` do pacote `integrate` da biblioteca `scipy` (INTEGRATE, 2025). Essa função resolve numericamente sistemas de equações diferenciais ordinárias (EDOs) e seleciona automaticamente o método numérico mais adequado com base nas características do sistema, definindo o método `LSODA`. A implementação do código de Evolução Diferencial (DE) também foi feita em Python, utilizando a biblioteca `Numpy` (versão 1.24.3).

Utilizamos o Python 64 bits, versão 3.11.3, e o ambiente de desenvolvimento integrado (IDE) Spyder 5.4.3 para realizar os experimentos. O ambiente de execução consistia em um processador Intel Core i5-9300HF com 16GB de memória RAM, rodando o sistema operacional Windows 11 Home versão 22H2.

O tempo de simulação não foi um obstáculo neste trabalho, considerando que uma execução simples do modelo leva apenas alguns segundos. A execução do algoritmo de

Evolução Diferencial e da análise de sensibilidade não excedeu 2 horas.

A Tabela 4 apresenta as condições iniciais e os acrônimos das populações, juntamente com os parâmetros.

4 Resultados Computacionais

Esta seção apresenta uma comparação detalhada entre as previsões do nosso modelo computacional e os dados de coorte de indivíduos vacinados com a ChAdOx1 nCoV-19 (AZD1222) (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023). Avaliamos também a sensibilidade do modelo e quantificamos as incertezas nas suas previsões. Por fim, identificamos os esquemas vacinais ótimos, com variações nas doses (duas e três doses, com dose padrão e meia dose), para maximizar a proteção ao longo de um período de 500 dias após a primeira dose.

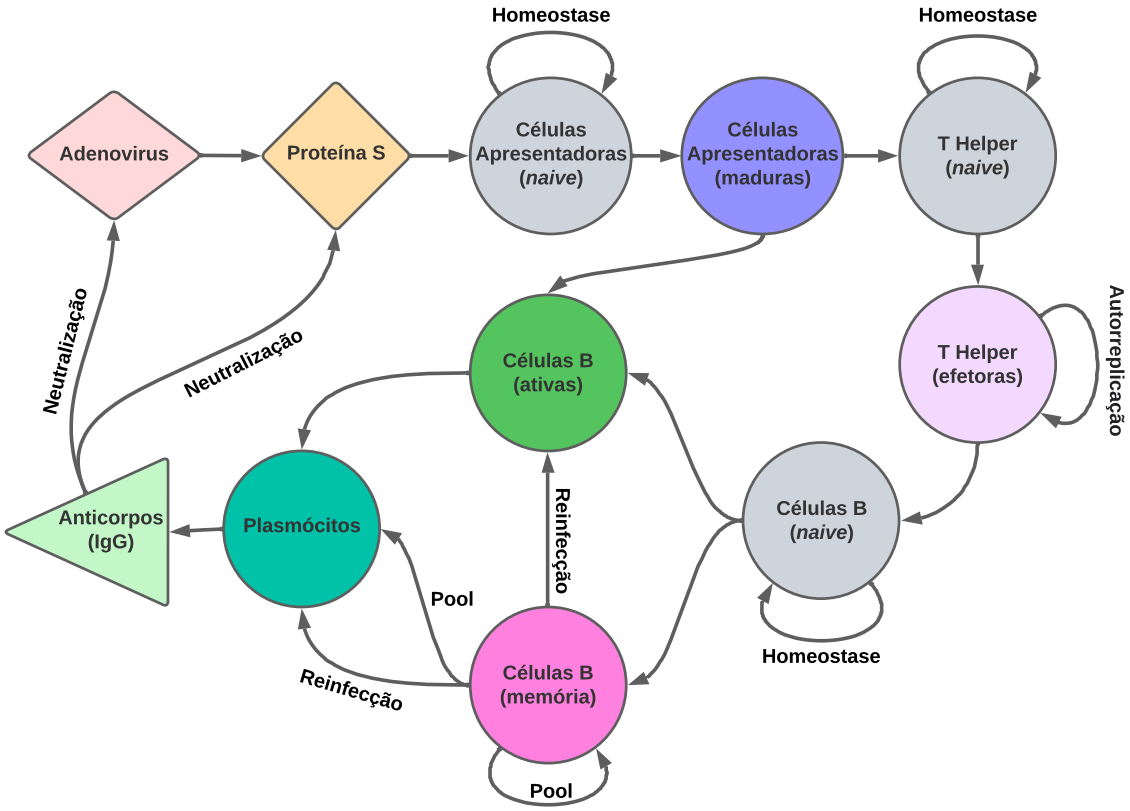

Figura 16: – Diagrama simplificado ilustrando a integração de 11 espécies biológicas no nosso modelo matemático. As setas indicam relações de ativação ou reativação. As populações ativas estão representadas em cores, enquanto as populações *naïve* (não ativadas) são mostradas em cinza.

A Figura 16 ilustra as interações entre as principais populações de células imunológicas, presentes no modelo simplificado, envolvidas na resposta à vacina ChAdOx1 nCoV-19, evidenciando a dinâmica entre os componentes virais e as células do sistema imune. As populações representadas em cores correspondem a estados ativos ou diferenciados, incluindo o adenovírus vacinal, a proteína *Spike* e os anticorpos IgG. Já as células em cinza representam estados *naïve*, isto é, células ainda não ativadas. Complementando esse esquema, a Figura 17 apresenta as dinâmicas simuladas dessas populações ao longo do tempo em um cenário com duas doses, sendo a segunda aplicada no dia 63.

Após a administração, a vacina entrega um adenovírus modificado que expressa a proteína *spike* do SARS-CoV-2. Esse vírus é inicialmente capturado por células apresentadoras de antígeno *naïve* (A_p), que então amadurecem, tornando-se células apresentadoras de antígeno ativas (A_{pm}) após o reconhecimento do antígeno. A Figura 17 ilustra o declínio das células *naïve* e o aumento das células maduras.

As células apresentadoras maduras ativam os linfócitos T auxiliares (T_{hn}), que se diferenciam em células efetoras (T_{he}). Essas, por sua vez, ativam os linfócitos B, que passam do estado *naïve* (B_n) para o estado ativo (B_a), iniciando a produção de anticorpos. Essa cascata leva ao aumento das células plasmáticas (P_c) e dos níveis de anticorpos IgG, como mostrado na Figura 17.

As células B ativadas se diferenciam em células plasmáticas, responsáveis pela secreção de imunoglobulina G (IgG), o principal anticorpo neutralizante. Parte das células B se transforma em células de memória (B_m), sustentando a imunidade de longo prazo. A Figura 17 ilustra a persistência das células B de memória, que contribuem para uma proteção imunológica duradoura.

Nosso modelo integra processos biológicos essenciais, incluindo homeostase, autor-replicação, neutralização e formação de complexos antígeno-anticorpo. No contexto do modelo, a neutralização mediada por anticorpos é considerada tanto para o vetor adenoviral quanto para a proteína *Spike*. No caso do adenovírus, essa neutralização representa a ação da imunidade anti-vetor, reduzindo a disponibilidade do vetor para infectar células e, consequentemente, a expressão do antígeno em exposições subsequentes. Já a neutralização da proteína *Spike* deve ser interpretada como uma abstração da ligação antígeno-anticorpo, resultando na remoção do antígeno circulante e servindo como uma representação indireta para os mecanismos de proteção mediados por anticorpos neutralizantes contra o SARS-CoV-2. Esses processos são representados quantitativamente na Figura 17, oferecendo uma visão mais detalhada das flutuações das populações imunológicas ao longo do tempo em resposta à vacinação.

O modelo emprega um sistema de 11 equações diferenciais ordinárias (EDOs), representando cada espécie biológica, e inclui 31 parâmetros, detalhados na Seção 3.2. A concordância entre o modelo conceitual (Figura 16) e os resultados numéricos (Figura 17) confirma a capacidade do modelo em reproduzir as principais dinâmicas imunológicas.

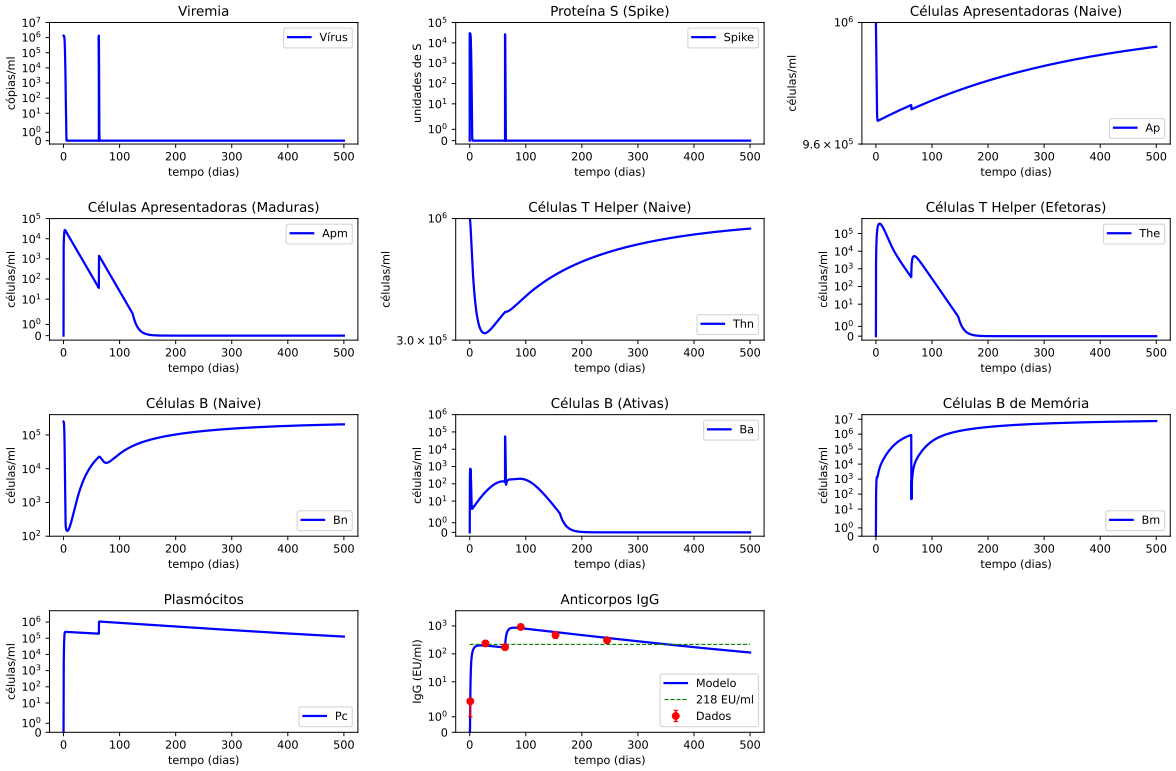

Figura 17: – Dinâmica das células imunológicas e dos componentes virais ao longo do tempo, modelada por meio de 11 EDOs. O eixo x representa o tempo (dias), e o eixo y reflete as unidades correspondentes de cada variável. Duas doses do vetor adenoviral (Virus) introduzem o vírus, desencadeando um aumento na proteína S (*Spike*) e resultando em dois picos de viremia e concentração de proteína S. As células apresentadoras *naïve* diminuem à medida que encontram a proteína S e amadurecem em células apresentadoras maduras. Os picos de células apresentadoras maduras coincidem com a ativação das células T e B. As células T auxiliares *naïve* e as células B *naïve* seguem um padrão semelhante, declinando à medida que se diferenciam em células efetoras após serem ativadas por células apresentadoras maduras e células T auxiliares efetoras, respectivamente. As células B de memória e as células plasmáticas surgem em fases posteriores da resposta. As células plasmáticas produzem IgG, que aumenta após cada dose da vacina. O IgG se liga às partículas virais e à proteína S, formando complexos imunes que facilitam a depuração. Esse mecanismo explica as quedas acentuadas da viremia e da proteína S após os picos de IgG. As populações de células *naïve* tendem a retornar aos níveis basais devido à regulação homeostática. As dinâmicas temporais destacam o efeito de reforço da segunda dose, levando a respostas imunes mais rápidas e robustas (por exemplo, níveis mais altos de IgG e depuração viral mais rápida). As células B de memória e a produção sustentada de IgG contribuem para a proteção de longo prazo contra reinfecções.

Este trabalho utilizou inicialmente cinco simulações numéricas para investigar a dinâmica da resposta de anticorpos induzida pela vacina ChAdOx1 nCoV-19, com base em dados clínicos de ensaios previamente publicados. Os parâmetros do modelo foram calibrados a partir de uma coorte de 115 participantes, com idades entre 18 e 55 anos, que receberam um regime de duas doses com intervalo de 8 a 12 semanas (FLAXMAN *et al.*,

2021).

Para a validação do modelo calibrado, foram inicialmente considerados dados de 704 indivíduos do grupo original com intervalo de 8 a 12 semanas, acompanhados por um período de um ano após a segunda dose, com o objetivo de avaliar a capacidade do modelo em prever a durabilidade da resposta imune (VOYSEY *et al.*, 2023). Em seguida, foram analisados indivíduos da mesma coorte que receberam a segunda dose em intervalos distintos: um grupo de 116 participantes com intervalo longo (15 a 25 semanas) e um grupo de 30 participantes com intervalo muito longo (44 a 45 semanas) (FLAXMAN *et al.*, 2021).

Finalmente, um quinto cenário explorou o efeito de uma dose de reforço, simulando um regime de três doses. Esse cenário foi baseado no mesmo estudo, considerando 80 participantes que receberam uma terceira dose, em média, 30 semanas após a segunda, sendo que as duas doses iniciais foram administradas com intervalo entre 8 e 16 semanas (adotando-se o dia 98 como valor médio para esta população) (FLAXMAN *et al.*, 2021).

Cabe destacar que os estudos de referência não apresentam de forma explícita os dias médios de administração das segundas doses para cada grupo analisado, sendo os intervalos reportados predominantemente em semanas ou por meio de estatísticas agregadas (como medianas e intervalos interquartis). Dessa forma, foram adotados valores representativos para as simulações com base nos intervalos descritos: dia 63 e dia 69 para o grupo de 8 a 12 semanas, dia 114 para o grupo de 15 a 25 semanas e dia 313 para o grupo de 44 a 45 semanas. No regime de três doses, considerou-se o dia 98 para a segunda dose e o dia 308 para a terceira dose, correspondendo este último a exatamente 30 semanas após a segunda dose, conforme descrito em (VOYSEY *et al.*, 2023).

Em um estudo anterior, um nível mediano de anticorpos de 218 Unidades ELISA/ml (EU/ml) no dia 28 após a vacinação foi associado a 50% de neutralização viral (FOLEGATTI *et al.*, 2020). Este valor, determinado pelo ensaio de neutralização por redução de placas (PHE PRNT50), foi a mediana alcançada por 100% dos 35 participantes do estudo no 28º dia após uma dose única da vacina ChAdOx1 nCoV-19 (FOLEGATTI *et al.*, 2020). Por essa razão, esse limiar (*threshold*) de 218 EU/ml é utilizado como referência de proteção e está indicado em todas as figuras de resposta de anticorpos.

4.1 Identificação dos Parâmetros Mais Sensíveis do Modelo

A Figura 18 exibe os índices de Sobol de primeira ordem para o regime de três doses, que captura os padrões representativos de sensibilidade observados nos diferentes esquemas de vacinação.

A análise de sensibilidade identificou nove parâmetros com maior influência sobre os níveis de IgG: a taxa de liberação da proteína *spike* pelo vírus (δ_s), a taxa de neutralização

da proteína *spike* mediada por células apresentadoras de antígeno ($\delta_{s_{ap}}$), a taxa de ativação de células apresentadoras imaturas em células maduras ($\gamma_{s_{ap}}$), o nível basal de células B *naïve* (B_{n0}), a dinâmica de autorreplicação das células B de memória (k_0 e k_1), a taxa de decaimento das células plasmáticas (δ_{pc}), a taxa de produção de anticorpos pelas células plasmáticas (π_{pc}) e a taxa de decaimento do IgG (δ_{IgG}). Todos os parâmetros foram modelados como distribuídos normalmente, com desvios padrão derivados da regra empírica (SHAFER; ZHANG, 2012), assegurando uma cobertura de 99,7% dentro de uma faixa de ±25% em torno da média, de acordo com a Equação 3.17. A Seção 3.4 apresenta mais detalhes metodológicos sobre a UQ e a análise de sensibilidade. Embora cinco esquemas de vacinação tenham sido simulados, o regime de três doses (Figuras 18 e 19) encapsulam o comportamento de sensibilidade de todos os parâmetros influentes.

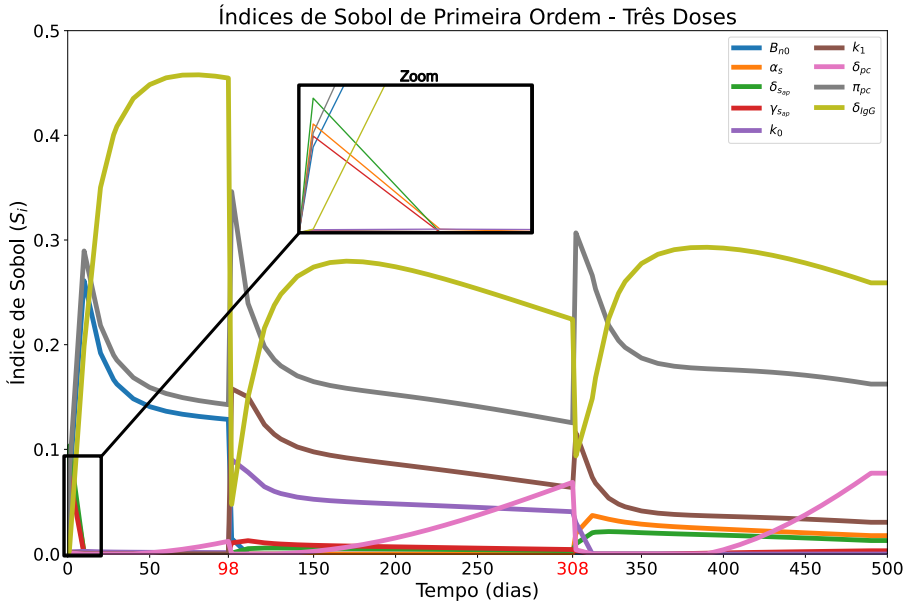

Figura 18: – Índices de Sobol de primeira ordem para o regime de três doses da vacina ChAdOx1 nCoV-19. Os marcadores vermelhos no eixo x indicam a segunda (dia 98) e a terceira (dia 308) doses. As linhas contínuas acompanham a sensibilidade temporal de cada parâmetro. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta quedas acentuadas de sensibilidade após cada dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) ganha influência após o reforço. A população de células B *naïve* (B_{n0}, azul) domina a sensibilidade na fase inicial, enquanto a taxa de replicação das células B de memória (k_1, marrom) se torna mais influente em estágios posteriores. O quadro interno fornece um zoom nas dinâmicas da fase inicial.

A Figura 18 destaca o subconjunto de parâmetros com índices de Sobol de primeira ordem acima de 0,07, enfatizando seu impacto ao longo dos 500 dias de simulação. Entre eles, nove parâmetros apresentam sensibilidade consistentemente alta, enquanto outros exibem influência mais localizada no tempo. A legenda da figura fornece uma análise detalhada sobre a relevância imunológica desses parâmetros.

A Figura 19 apresenta os índices de Sobol de ordem total para o regime de três doses. Observa-se que o comportamento temporal dos parâmetros é bastante semelhante ao identificado na análise de primeira ordem, com os mesmos parâmetros dominantes ao longo do período simulado. As diferenças entre os valores absolutos refletem a inclusão dos efeitos de interação, porém sem alteração significativa no padrão geral de sensibilidade. Esse resultado reforça que a contribuição dos parâmetros é majoritariamente individual, com interações de baixa magnitude, corroborando a interpretação de que a dinâmica do modelo é predominantemente governada por efeitos de primeira ordem.

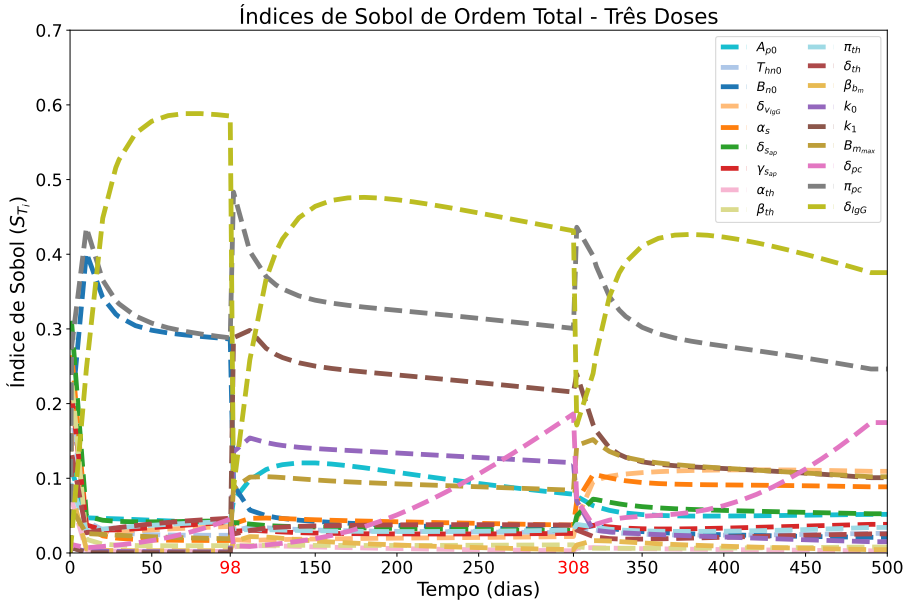

Figura 19: – Índices de Sobol de ordem total para o regime de três doses da vacina ChAdOx1 nCoV-19. Os marcadores vermelhos no eixo x indicam a segunda (dia 98) e a terceira (dia 308) doses. As linhas tracejadas representam a sensibilidade temporal de cada parâmetro considerando os efeitos totais, incluindo interações entre parâmetros. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com variações após cada dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente após o reforço. Observa-se ainda que os padrões gerais de sensibilidade acompanham aqueles obtidos para os índices de primeira ordem, indicando baixa interação entre os parâmetros dominantes.

Vários outros parâmetros apresentam sensibilidade específica por fase. Por exemplo, a taxa de produção da proteína S (α_s, laranja), sua taxa de apresentação pelas células

apresentadoras ($\delta_{s_{ap}}$, verde) e a taxa de maturação das células apresentadoras em resposta à exposição à proteína S ($\gamma_{s_{ap}}$, vermelho) afetam predominantemente os estágios iniciais, antes que as células B e as células plasmáticas se tornem ativas. Enquanto isso, a taxa de decaimento das células plasmáticas (δ_{pc}, rosa) contribui mais significativamente para as dinâmicas de longo prazo, à medida que as concentrações de anticorpos diminuem gradualmente.

Em resumo, a análise de sensibilidade revela influências dependentes da fase, com processos relacionados às células B e à produção de anticorpos desempenhando papéis centrais na modelagem das respostas imunológicas. Esses achados destacam a complexidade da modelagem da imunidade induzida por vacinas e orientam a seleção dos parâmetros para simulações robustas e informativas.

4.2 Quantificação de Incertezas - UQ

As Figuras 20, 21, 22, 23 e 24 apresentam as saídas do modelo sob variação de parâmetros. As regiões sombreadas correspondem aos resultados da quantificação de incerteza (UQ), obtidos a partir de funções de distribuição normal geradas pela biblioteca *chaospy*, em conformidade com a Equação 3.17. Nas Figuras, são apresentadas duas abordagens de UQ: (a) UQ completa, que varia todos os 31 parâmetros do modelo, e (b) UQ reduzida, que varia apenas os parâmetros mais sensíveis, identificados por meio da análise de sensibilidade. Aplicamos os índices de Sobol para quantificar a contribuição de cada parâmetro para a variância da saída do modelo (níveis de IgG), permitindo identificar aqueles com maior influência nas previsões. Essas variações nos parâmetros não apenas contribuem para a incerteza das previsões, mas também fundamentam a validação da CV, uma vez que cada conjunto de parâmetros amostrado pode ser interpretado como um indivíduo virtual, capturando a variabilidade interindividual das respostas imunes.

A análise de sensibilidade apresentada anteriormente permitiu identificar os parâmetros com maior influência na dinâmica da resposta imune, evidenciando a existência de diferentes níveis de relevância entre os componentes do modelo. No entanto, embora essa análise forneça informações sobre a importância relativa de cada parâmetro, ela não quantifica diretamente o impacto da variabilidade paramétrica nas saídas do modelo. Nesse contexto, a UQ é introduzida como uma etapa complementar, com o objetivo de avaliar como as incertezas associadas aos parâmetros se propagam ao longo do tempo e afetam as previsões de níveis de anticorpos. Além disso, a UQ permite comparar o comportamento do modelo quando todos os parâmetros são simultaneamente perturbados com aquele obtido ao se considerar apenas o subconjunto dos nove parâmetros mais sensíveis identificados pela análise de Sobol, fornecendo uma avaliação mais abrangente da robustez do modelo.

Para a modelagem das incertezas paramétrica do modelo, assumiu-se que todos os parâmetros seguem distribuições normais, conforme definido na Equação 3.17, em

consonância com a Regra Empírica (68–95–99,7), garantindo que aproximadamente 99,7% das amostras estejam contidas no intervalo de ±25% em torno do valor médio ajustado, cujos valores se encontram na Tabela 4. A biblioteca *Chaospy* foi empregada como ferramenta para geração das amostras aleatórias dos parâmetros a partir dessas distribuições, permitindo a propagação das incertezas no modelo. Embora a metodologia de expansões em caos polinomial esteja disponível na biblioteca, sua aplicação não foi viável neste estudo devido à elevada dimensionalidade do problema (31 parâmetros), o que resultou em dificuldades de convergência e custo computacional elevado. Dessa forma, a quantificação de incertezas foi conduzida por meio da análise direta das distribuições das trajetórias simuladas, permitindo avaliar a variabilidade das respostas do modelo ao longo do tempo sem a construção explícita de aproximações polinomiais.

A seguir, são apresentados os resultados dos cinco cenários base de esquemas vacinais considerados neste trabalho, conforme ilustrado nas Figuras 20, 21, 22, 23 e 24.

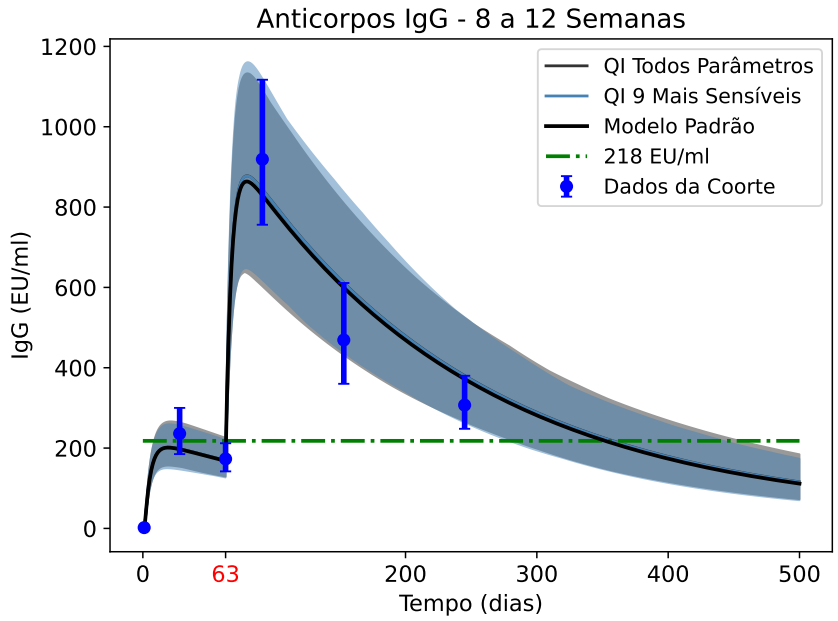

Figura 20: – Simulação dos níveis de anticorpos IgG (EU/mL) para o regime de duas doses com intervalo de 8 a 12 semanas, em que a segunda dose é administrada no dia 63 (destacado em vermelho no eixo x). São apresentados os resultados da quantificação de incerteza (UQ), em que as regiões sombreadas representam a variabilidade das simulações obtidas a partir da variação dos parâmetros do modelo, incluindo todos os parâmetros e o subconjunto dos mais sensíveis. A linha preta contínua corresponde ao modelo padrão, enquanto os pontos em azul representam os dados da coorte. A linha tracejada verde indica o limiar de proteção de 218 EU/mL. Observa-se a manutenção da resposta humoral ao longo de 500 dias.

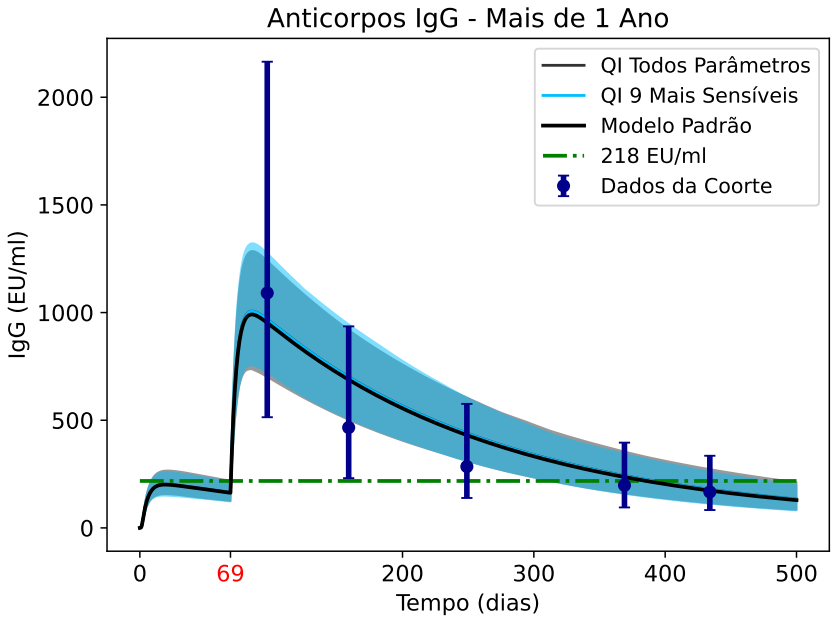

Figura 21: – Simulação dos níveis de anticorpos IgG (EU/mL) para o regime de duas doses com intervalo de 8 a 12 semanas, em que a segunda dose é administrada no dia 69 (destacado em vermelho no eixo x). São apresentados os resultados da quantificação de incerteza (UQ), em que as regiões sombreadas representam a variabilidade das simulações obtidas a partir da variação dos parâmetros do modelo, incluindo todos os parâmetros e o subconjunto dos mais sensíveis. A linha preta contínua corresponde ao modelo padrão, enquanto os pontos em azul representam os dados da coorte. A linha tracejada verde indica o limiar de proteção de 218 EU/mL. Os indivíduos considerados pertencem à mesma coorte, porém foram acompanhados por um período superior a um ano VOYSEY *et al.* (2023). Observa-se a manutenção da resposta humoral ao longo de 500 dias.

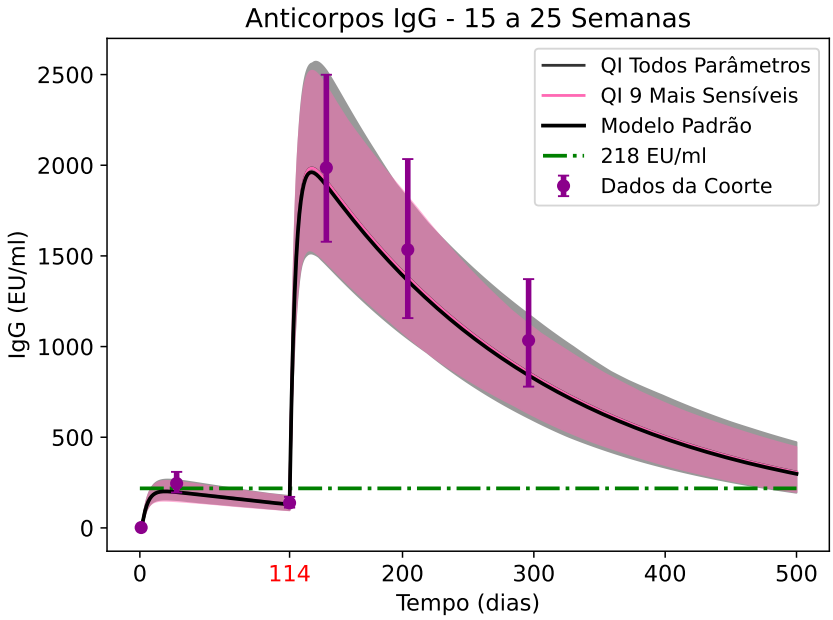

Figura 22: – Simulação dos níveis de anticorpos IgG (EU/mL) para o regime de duas doses com intervalo de 15 a 25 semanas, em que a segunda dose é administrada no dia 114 (destacado em vermelho no eixo x). São apresentados os resultados da quantificação de incerteza (UQ), em que as regiões sombreadas representam a variabilidade das simulações obtidas a partir da variação dos parâmetros do modelo, incluindo todos os parâmetros e o subconjunto dos mais sensíveis. A linha preta contínua corresponde ao modelo padrão, enquanto os pontos em roxo representam os dados da coorte. A linha tracejada verde indica o limiar de proteção de 218 EU/mL. Os indivíduos considerados pertencem à mesma coorte, com intervalo mais longo entre as doses, conforme descrito em (FLAXMAN *et al.*, 2021). Observa-se a manutenção da resposta humoral ao longo de 500 dias.

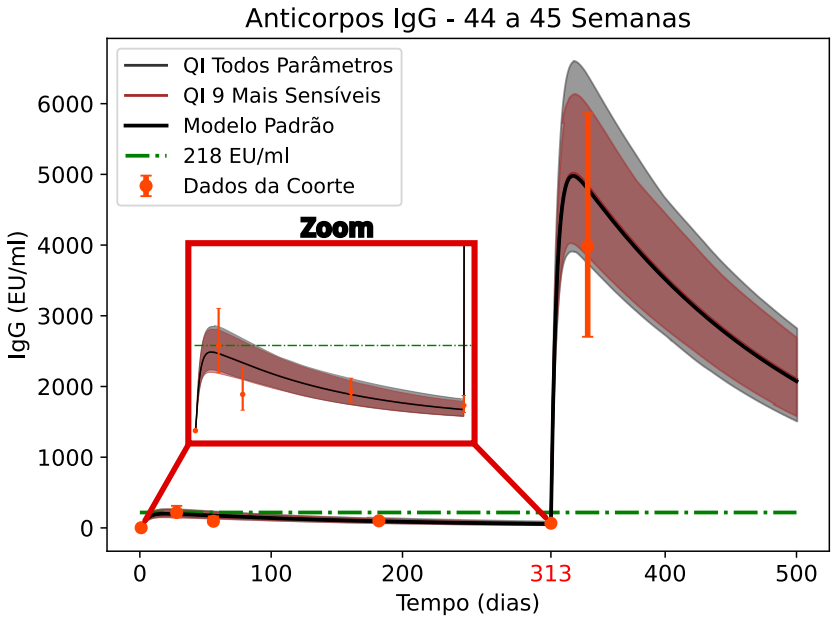

Figura 23: – Simulação dos níveis de anticorpos IgG (EU/mL) para o regime de duas doses com intervalo de 44 a 45 semanas, em que a segunda dose é administrada no dia 313 (destacado em vermelho no eixo x). São apresentados os resultados da quantificação de incerteza (UQ), em que as regiões sombreadas representam a variabilidade das simulações obtidas a partir da variação dos parâmetros do modelo, incluindo todos os parâmetros e o subconjunto dos mais sensíveis. A linha preta contínua corresponde ao modelo padrão, enquanto os pontos em laranja representam os dados da coorte. A linha tracejada verde indica o limiar de proteção de 218 EU/mL. O quadro em destaque apresenta um zoom na dinâmica da resposta no intervalo entre a primeira e a segunda dose, evidenciando a evolução dos níveis de anticorpos em escalas mais detalhadas. Os indivíduos considerados pertencem à mesma coorte, com intervalo muito longo entre as doses, conforme descrito em (FLAXMAN *et al.*, 2021). Observa-se a manutenção da resposta humoral ao longo de 500 dias.

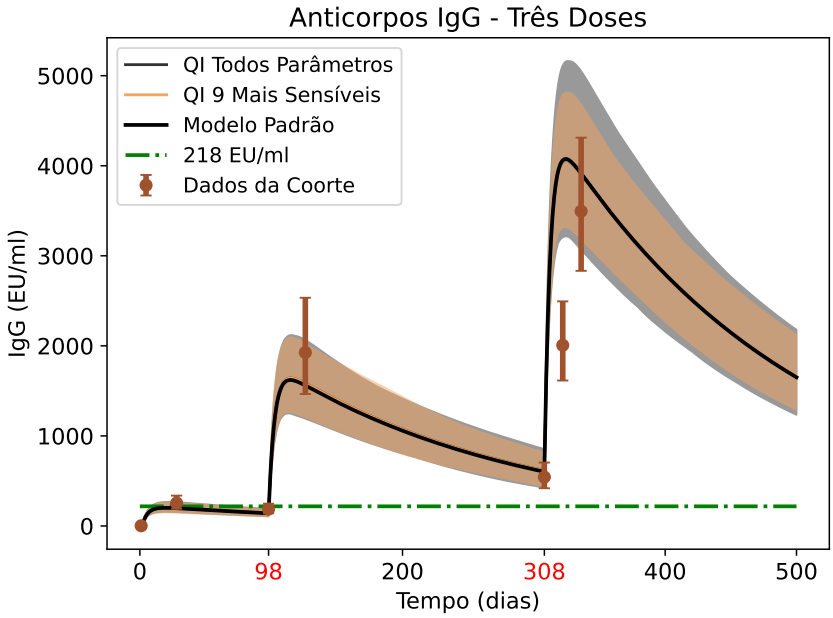

Figura 24: – Simulação dos níveis de anticorpos IgG (EU/mL) para o regime de três doses, em que a segunda dose é administrada no dia 98 e a terceira no dia 308 (destacados em vermelho no eixo x). São apresentados os resultados da quantificação de incerteza (UQ), em que as regiões sombreadas representam a variabilidade das simulações obtidas a partir da variação dos parâmetros do modelo, incluindo todos os parâmetros e o subconjunto dos mais sensíveis. A linha preta contínua corresponde ao modelo padrão, enquanto os pontos em marrom representam os dados da coorte. A linha tracejada verde indica o limiar de proteção de 218 EU/mL. Os indivíduos considerados pertencem à mesma coorte, com a inclusão de uma dose de reforço administrada, em média, 30 semanas após a segunda dose, conforme descrito em (FLAXMAN *et al.*, 2021). Observa-se um aumento significativo dos níveis de anticorpos após a terceira dose, seguido pela manutenção da resposta humoral ao longo de 500 dias.

A caracterização da variabilidade do modelo por meio da quantificação de incertezas permite avançar para a etapa de exploração sistemática de diferentes intervalos entre doses, na qual são realizadas simulações com o objetivo de identificar regimes que maximizem a resposta imune.

4.3 Otimização do Intervalo Entre Doses

Esta subseção apresenta os resultados das simulações realizadas para identificar intervalos de dosagem que maximizem a duração da proteção imunológica induzida pela vacina ChAdOx1 nCoV-19 (AZD1222). Utilizando o modelo matemático desenvolvido neste trabalho, com parâmetros previamente calibrados a partir de dados clínicos e representativos de um comportamento médio da resposta imune na população, foram avaliadas diferentes combinações de intervalos entre doses, tanto para regimes de duas quanto de três aplicações.

A otimização foi conduzida considerando como critério o Tempo de Proteção Sustentada acima de 218 EU/mL (TPS), definido como a fração do período simulado em que os níveis de anticorpos permanecem acima desse limiar de proteção. Dessa forma, buscou-se identificar esquemas de dosagem capazes de maximizar a duração da resposta humoral ao longo do horizonte temporal de 500 dias considerado nas simulações.

Para o regime de duas doses, um total de 423 simulações foi conduzido para avaliar como a variação do intervalo entre a primeira e a segunda doses da vacina ChAdOx1 nCoV-19 influencia a produção de anticorpos e a duração da proteção imunológica. As simulações começam no dia 28 e se estenderam até o dia 450. Esse total resulta da variação sistemática do intervalo entre as doses nesse período, com incrementos de um dia, de modo que cada valor inteiro corresponde a uma simulação distinta, totalizando $450 - 28 + 1 = 423$ cenários avaliados.

A proteção foi definida como o número de dias em que os níveis de IgG permaneceram acima do limiar de proteção de 218 EU/mL (FOLEGATTI *et al.*, 2020). Para avaliar a imunidade de longo prazo, simulamos um período de 500 dias e buscamos identificar os intervalos de dose que maximizam essa duração de proteção. Foram considerados dois cenários: regimes de duas e de três doses. Em ambos os casos, calculamos o TPS como a proporção do período simulado durante o qual os níveis de IgG permaneceram acima do limiar estabelecido.

Os resultados são apresentados nas Figuras 25, 26, 27 e 28. No regime de duas doses, o modelo identificou o dia 94 (décima terceira semana) como o momento ótimo para a administração da segunda dose, proporcionando proteção por aproximadamente 81% do período de simulação, conforme ilustrado na Figura 25. Além disso, observa-se que um intervalo mais amplo entre as semanas 11 e 21 ainda mantém níveis de proteção superiores a 70%, indicado pela faixa verde na Figura 25. Esse resultado sugere uma margem de flexibilidade no agendamento da segunda dose, o que pode ser particularmente útil em cenários de limitações logísticas ou de disponibilidade de vacinas.

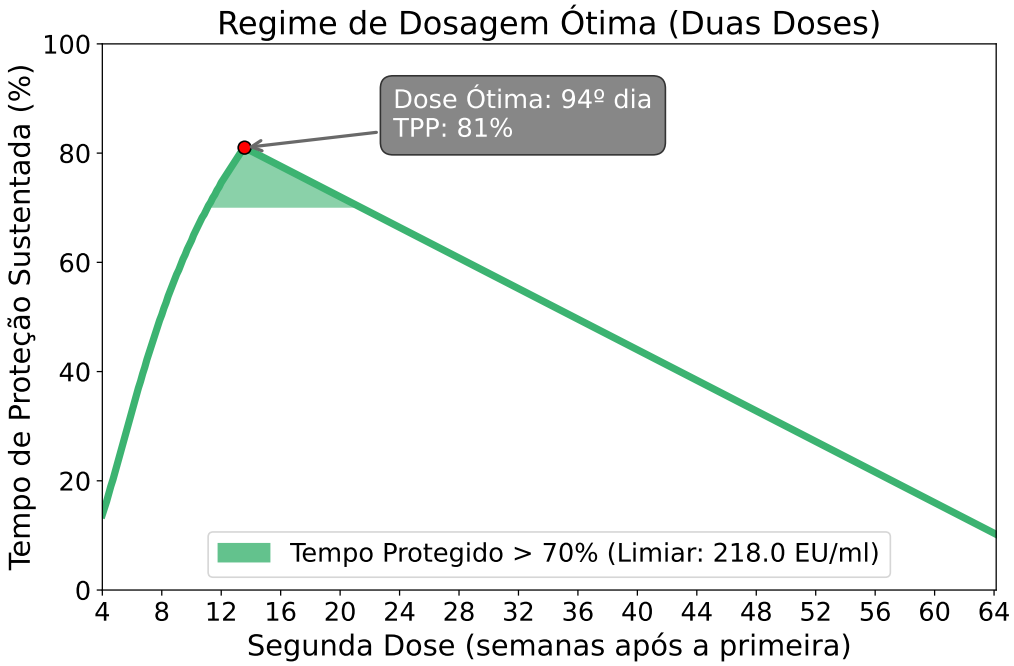

Figura 25: – Resultados da simulação do regime vacinal de duas doses da ChAdOx1 nCoV-19 em função do intervalo entre a primeira e a segunda dose. O gráfico apresenta o TPS, definido como a porcentagem do período simulado em que os níveis de anticorpos permanecem acima do limiar de 218 EU/mL. Observa-se que a proteção é maximizada quando a segunda dose é administrada no 94º dia (aproximadamente 13 semanas), alcançando cerca de 81% do tempo total de simulação com níveis de anticorpos acima do limiar considerado protetor. A região destacada indica os intervalos de administração da segunda dose que mantêm a proteção acima de 70% do período simulado, caracterizando regimes de dosagem potencialmente eficazes.

A Figura 26 apresenta a análise de sensibilidade do limiar de proteção utilizado no cálculo do TPS. Para essa análise, o limiar de referência de 218 EU/mL foi variado em ±25%, resultando nos valores de 163,5 EU/mL e 272,5 EU/mL. O gráfico mostra a porcentagem do período simulado em que os níveis de anticorpos permanecem acima desses limiares em função do intervalo entre a primeira e a segunda dose. Os resultados indicam que a variação do limiar altera tanto o tempo ótimo de administração da segunda dose quanto a duração da proteção estimada ao longo do período simulado.

No regime de três doses, inicialmente foram exploradas diferentes combinações de intervalos entre as doses. O intervalo entre a primeira e a segunda dose foi variado do dia 28 até o dia 225, enquanto, para cada um desses valores, o intervalo entre a segunda e a terceira dose foi sistematicamente variado, iniciando-se 28 dias após a segunda dose e estendendo-se até o dia 450. Os resultados dessa análise são apresentados na Figura 27, na qual o TPS é representado em função dos intervalos entre as doses. A escala de cores indica a fração do período simulado em que os níveis de anticorpos permanecem acima do limiar considerado protetor, enquanto a linha preta contínua delimita a região em que o tempo protegido permanece acima de 70% do período simulado.

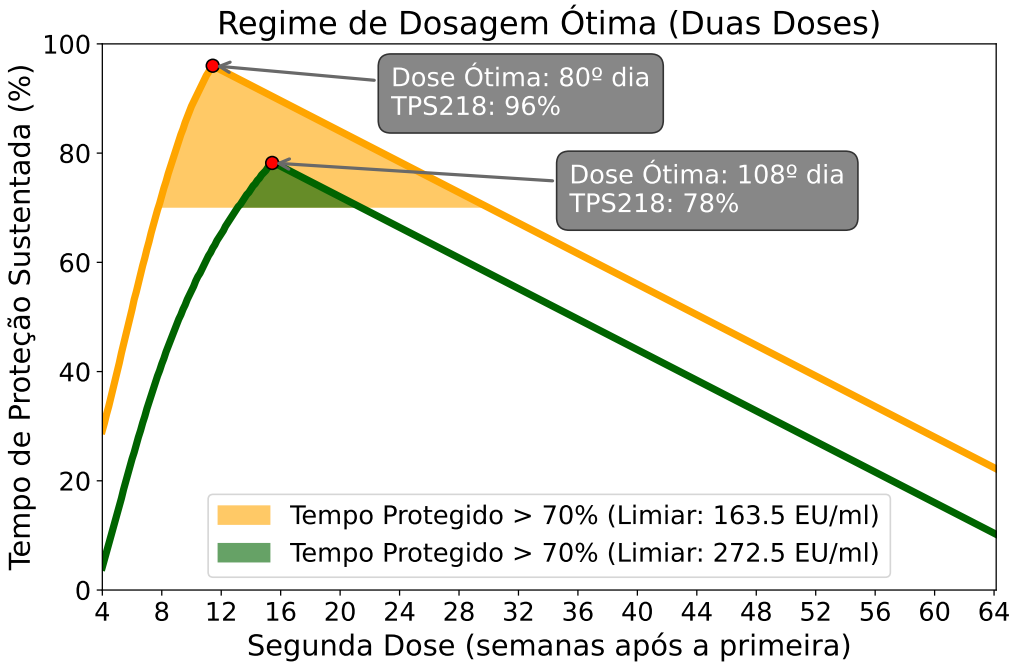

Figura 26: – Resultados da análise de sensibilidade do limiar de proteção utilizado para o cálculo do TPS. O limiar de referência de 218 EU/mL foi variado em ±25%, resultando nos valores de 163,5 EU/mL e 272,5 EU/mL. O gráfico mostra a porcentagem do período simulado em que os níveis de anticorpos permanecem acima desses limiares em função do intervalo entre a primeira e a segunda dose. Observa-se que, para o limiar reduzido (163,5 EU/mL), a proteção é maximizada quando a segunda dose é administrada no 80º dia, alcançando aproximadamente 96% do tempo simulado acima do limiar. Já para o limiar aumentado (272,5 EU/mL), o intervalo ótimo ocorre no 108º dia, com cerca de 78% de proteção sustentada. As regiões destacadas indicam os intervalos em que o tempo protegido permanece acima de 70% do período simulado para cada limiar considerado.

De acordo com as simulações, a proteção máxima é obtida quando a segunda dose é administrada aproximadamente na semana 4 após a primeira e a terceira dose na semana 12 após a segunda, ponto destacado na figura pelo marcador vermelho. Esse regime corresponde à administração da segunda dose por volta do dia 30 e da terceira dose aproximadamente no dia 117 da simulação. Nesse cenário, o modelo prevê um TPS de aproximadamente 94% ao longo do período de 500 dias considerado, indicando uma resposta imunológica mais robusta e sustentada em comparação com o regime de duas doses.

Esse procedimento resultou em um total de 58.707 simulações distintas de intervalos entre a segunda e a terceira dose avaliadas nas simulações. Esse número não corresponde simplesmente ao produto entre o número de valores possíveis para a segunda dose e o intervalo máximo considerado para a terceira dose, pois o início do intervalo da terceira dose depende diretamente do dia de aplicação da segunda. Em particular, a terceira dose foi sempre considerada a partir de 28 dias após a segunda dose, estendendo-se até o dia 450 da simulação. Dessa forma, à medida que a segunda dose é aplicada em dias mais

tardios, o número de possibilidades disponíveis para a terceira dose diminui, resultando no total de combinações analisadas.

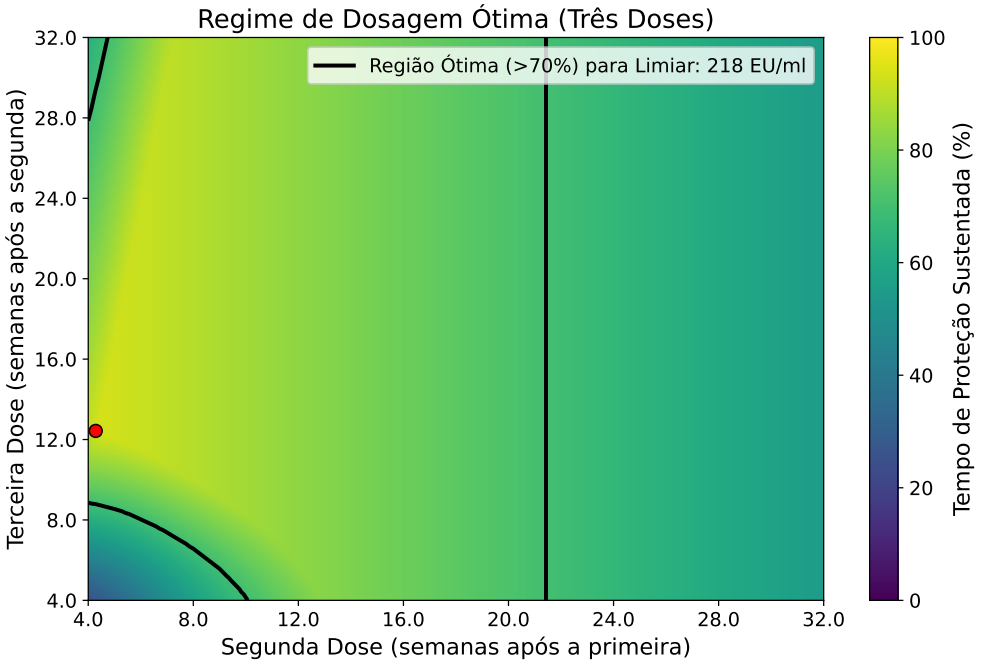

Figura 27: – Resultados das simulações para o regime vacinal de três doses da ChAdOx1 nCoV-19. O gráfico apresenta o TPS, definido como a porcentagem do período simulado em que os níveis de anticorpos permanecem acima do limiar de 218 EU/mL. O eixo horizontal representa o intervalo entre a primeira e a segunda dose, enquanto o eixo vertical indica o intervalo entre a segunda e a terceira dose, ambos representados em semanas. A escala de cores representa a fração do período simulado em que os níveis de anticorpos permanecem acima do limiar considerado protetor. Na simulação, a proteção máxima, com TPS $\sim 94\%$, ocorreria com a segunda sendo administrada na semana 4 e a terceira na semana 12 (indicada pelo ponto vermelho), e a linha preta contínua delimita a região protegida (>70% acima do limiar).

Na análise de sensibilidade do limiar de proteção para o esquema de três (Figura 28) novamente foi considerada uma variação de $\pm 25\%$ em torno do valor de referência de 218 EU/mL, resultando nos limiares de 163,5 EU/mL e 272,5 EU/mL. O gráfico apresenta o TPS em função dos intervalos entre a primeira, segunda e terceira doses, sendo a escala de cores utilizada para indicar a porcentagem do período simulado em que os níveis de anticorpos permanecem acima do limiar considerado. As linhas de contorno delimitam as regiões em que o tempo protegido permanece acima de 70% do período simulado para cada limiar avaliado, permitindo visualizar como diferentes definições do limiar de proteção influenciam os intervalos ótimos entre as doses.

No cenário com limiar reduzido (163,5 EU/mL), observa-se um deslocamento dos intervalos ótimos para momentos mais precoces. Nesse caso, a proteção máxima, com TPS de aproximadamente 98% do período simulado, é obtida quando a segunda dose é administrada na semana 10 após a primeira e a terceira dose na semana 5 após a segunda,

ponto destacado na figura pelo quadrado vermelho. Por outro lado, quando se considera o limiar aumentado (272,5 EU/mL), os intervalos ótimos são deslocados para momentos mais tardios. Nesse cenário, a proteção máxima, com TPS de aproximadamente 92%, ocorre quando a segunda dose é aplicada na semana 5 após a primeira e a terceira dose na semana 13 após a segunda, representado na figura pelo marcador em forma de X vermelho.

De modo geral, os resultados indicam que a definição do limiar de proteção influencia diretamente os intervalos ótimos entre as doses e a magnitude do Tempo de Proteção Sustentada. Ainda assim, mesmo considerando diferentes valores de limiar, o regime de três doses apresentou desempenho superior ao regime de duas doses na manutenção da proteção ao longo do período simulado.

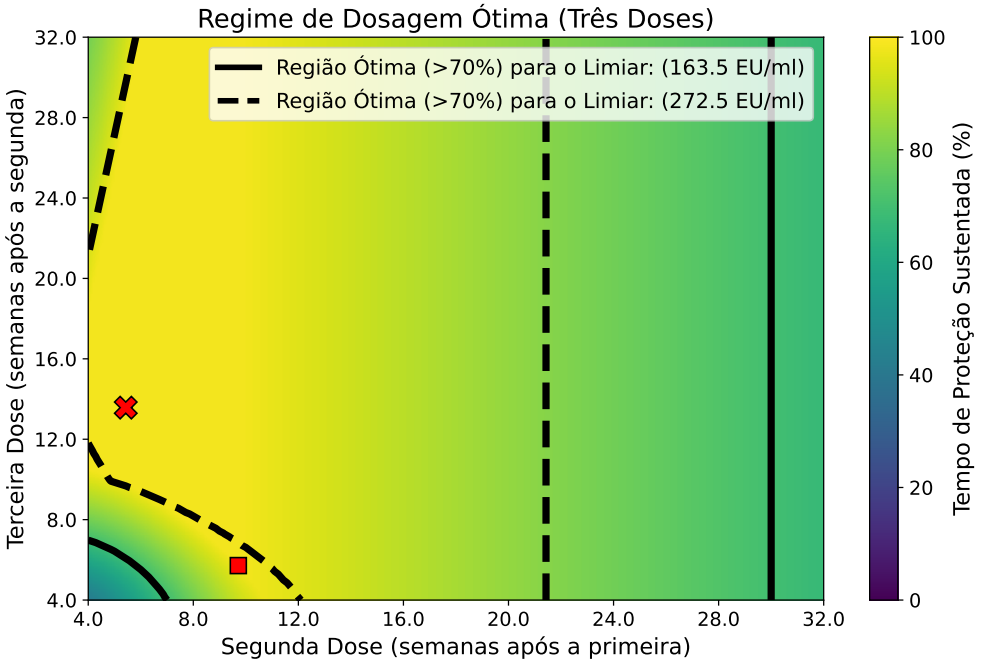

Figura 28: – Resultados da análise de sensibilidade do limiar de proteção para o regime vacinal de três doses. O limiar de referência de 218 EU/mL foi variado em ±25%, resultando nos valores de 163,5 EU/mL e 272,5 EU/mL. O gráfico mostra o TPS em função dos intervalos entre a primeira, segunda e terceira doses. A escala de cores indica a porcentagem do período simulado em que os níveis de anticorpos permanecem acima do limiar considerado. As linhas de contorno destacam as regiões em que o tempo protegido permanece acima de 70% do período simulado para cada limiar avaliado, permitindo identificar como a definição do limiar de proteção influencia os intervalos ótimos entre as doses. No limiar inferior (163,5 EU/ml), a proteção ótima, com TPS $\sim$ 98%, ocorre com a segunda dose na semana 10 e a terceira na semana 5 após a segunda (representada pelo quadrado vermelho); já no limiar superior (272,5 EU/ml), a proteção ótima, com TPS $\sim$ 92%, ocorre com a segunda dose na semana 5 e a terceira na semana 13 após a segunda (representada pelo X vermelho).

4.4 Limitações do Modelo

Na tentativa de validar o modelo para outros cenários, como o de comparar a eficácia da vacina com adminstração de meia dose ou dose padrão, segundo VALIM *et al.* (2022); VOYSEY *et al.* (2021, 2023); BARRETT *et al.* (2021), observamos os seguintes três casos de estudos presentes na literatura e tentamos replicar seus resultados.

O estudo de VALIM *et al.* (2022), conhecido como "Projeto Viana", caracteriza-se como um ensaio clínico controlado, não randomizado e de não inferioridade, ou seja, o estudo comprova que o uso de meia dose é tão eficaz quanto um tratamento por doses padrão. A pesquisa avaliou a efetividade, a segurança e a imunogenicidade de um esquema vacinal de duas doses fracionadas (meia dose, 0,25 mL) da vacina ChAdOx1 nCoV-19, em comparação ao esquema de duas doses integrais. O estudo foi conduzido com adultos na faixa etária de 18 a 49 anos, residentes na cidade de Viana, Espírito Santo, Brasil.

Observando a Figura 29, a análise da resposta imune primária — isto é, no período entre a administração da primeira e da segunda dose da vacina ChAdOx1 nCoV-19 — indica que o modelo reproduz adequadamente a dinâmica dos níveis de anticorpos IgG. Nesse intervalo, os níveis simulados de IgG para o regime de meia dose (MD) apresentam-se ligeiramente inferiores aos observados para a dose padrão (DP), em concordância com o comportamento esperado.

No entanto, uma divergência notável surgiu ao simular a resposta à segunda dose. O modelo previu um nível de produção de anticorpos superior para o regime de MD em comparação com o de DP. Este resultado contradiz os dados apresentados no estudo de referência VALIM *et al.* (2022). Esta inversão contraintuitiva é atribuída à dinâmica matemática implementada para as células B de memória (B_m), representada na Equação 3.11. A dinâmica simulada pelo modelo oferece uma explicação para este resultado contraintuitivo. Na primeira fase da imunização, um estímulo antigênico mais moderado (meia dose) resulta em uma eliminação e neutralização mais lenta do vírus (V) e da proteína *spike* (S), devido à redução na produção de anticorpos ao fim da cascata de eventos do modelo. Essa persistência prolongada do antígeno, dentro da lógica do modelo, favorece um desenvolvimento mais robusto da resposta de memória, culminando em um *pool* de células B de memória (B_m) numericamente um pouco superior ao final da resposta primária. Consequentemente, após a administração da segunda dose, embora o processo de diferenciação de células de memória em células plasmáticas (P_c) ocorra, o cenário de meia dose parte de uma população inicial de B_m mais elevada. É esta maior disponibilidade de células de memória para recrutamento que, no modelo, resulta em uma resposta secundária de maior magnitude e, por fim, em níveis de anticorpos mais elevados em comparação com o regime de dose padrão.

O comportamento citado acima, onde o modelo prevê uma resposta superior para a meia dose após um segundo estímulo, revela uma limitação em sua capacidade preditiva

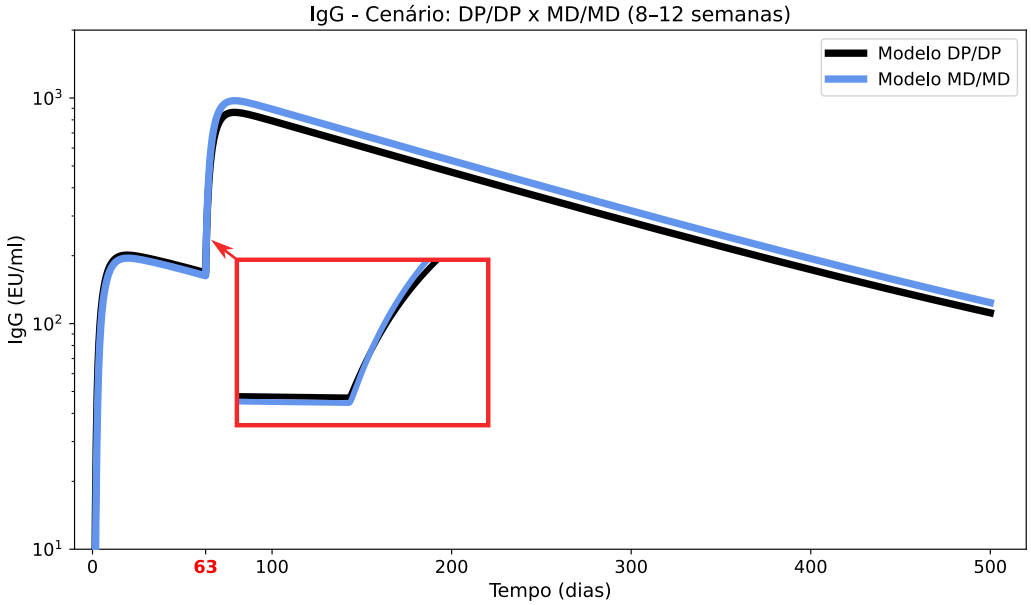

Figura 29: – Simulação dos níveis de anticorpos IgG (EU/mL) ao longo de 500 dias para dois regimes vacinais da ChAdOx1 nCoV-19: duas doses padrão (DP/DP) e duas meias doses (MD/MD), com intervalo de 63 dias entre as aplicações. O modelo reproduz a resposta primária após a primeira dose e uma resposta secundária pronunciada após o reforço. Entretanto, após a segunda aplicação, o regime MD/MD passa a apresentar níveis de IgG ligeiramente superiores aos observados no regime DP/DP, comportamento destacado na região ampliada da figura. Esse resultado evidencia uma limitação do modelo em cenários de reforço com doses fracionadas, uma vez que a previsão de resposta superior para a meia dose não é sustentada pelos dados clínicos reportados no estudo base (VALIM *et al.*, 2022). Ainda assim, no período entre a primeira e a segunda dose, o modelo apresenta boa concordância com os dados experimentais, com diferença de aproximadamente 2,9% entre os valores simulados e observados para o nível de anticorpos no dia 28 após a primeira aplicação.

em cenários de reforço com doses fracionadas. Esta característica do modelo, já evidente na resposta à segunda dose em indivíduos soropositivos (que funciona como um reforço imunológico), indica que o modelo não consegue generalizar sua aplicação de forma acurada. Contudo, sua validade é mantida para a análise da imunização primária em indivíduos de uma parcela do estudo, como apresentado na Figura 29. Neste contexto, o modelo demonstrou boa concordância com os dados clínicos reportados no estudo base (VALIM *et al.*, 2022), reproduzindo de forma adequada a cinética global da resposta humoral para os regimes de dose padrão e meia dose, no intervalo entre a primeira e a segunda aplicação. No 28º dia após a primeira dose, a diferença observada entre o valor previsto pelo modelo e os dados experimentais foi de apenas 2,89% (diferença entre 197,13 EU/ml e 191,43 EU/ml, em comparação a 0,37% obtido nas amostras (considerando o *Geometric Mean Titer* - GMT de 1359 BAU/mL e 1354 BAU/mL (VALIM *et al.*, 2022)).

O trabalho de seguimento de VOYSEY *et al.* (2023) apresenta uma análise longitudinal da persistência da resposta humoral e celular até 1 ano após o esquema de duas doses de ChAdOx1 nCoV-19, reportando medidas de IgG anti-*spike* em unidades EU/ml

(ELISA *Units*), além de dados de neutralização (ND_{50}) e ELISpot ($SFC/10^6$ PBMC). Nesta publicação, a população analisada para IgG compreendeu centenas de participantes (amostras agrupadas em janelas aproximadas a 90, 182 e 364 dias pós-segunda dose), e os autores demonstraram que os regimes que contêm ao menos uma dose padrão (MD/DP e DP/DP) produziram títulos geométricos de IgG significativamente maiores que o regime MD/MD, enquanto MD/DP e DP/DP não diferiram estatisticamente ($p = 0{,}47$).

Este mesmo estudo foi utilizado como base para a representação do cenário de coorte acompanhada por mais de um ano após a segunda dose, cujos resultados simulados são apresentados nas Figuras 36, 21 e 32. De modo geral, observa-se boa concordância entre as previsões do modelo e os dados experimentais ao longo do período analisado, especialmente na tendência de decaimento dos níveis de anticorpos. Adicionalmente, foram explorados os dados disponibilizados nos materiais suplementares do estudo, permitindo a comparação entre regimes envolvendo MD e DP, o que contribuiu para uma avaliação mais abrangente da capacidade do modelo em reproduzir diferentes esquemas vacinais.

No estudo COV002, o grupo que recebeu vacinas segundo o protocolo MD/DP incluiu 1.459 participantes (53,2%), dos quais a maioria recebeu a segunda dose com intervalo mínimo de 12 semanas após a primeira, com média de 84 dias (intervalo interquartil [IQR] 77–91). Apenas 0,8% dos participantes receberam a segunda dose em menos de 8 semanas. No grupo que seguiu o regime DP/DP, o intervalo médio entre as duas doses foi de 69 dias (IQR 50–86) (VOYSEY *et al.*, 2023).

Ao confrontarmos os resultados experimentais de VOYSEY *et al.* (2023) com as saídas do modelo, apresentadas na Figura 30 e já expressas em EU/ml, observa-se que, embora a tendência temporal geral — caracterizada por um pico pós-reforço seguido de declínio e posterior estabilização — seja qualitativamente bem reproduzida, o modelo não captura quantitativamente os níveis observados em todos os pontos de coleta.

Em particular, de forma análoga ao observado no estudo de Viana, o modelo tende a superestimar a resposta secundária no regime que se inicia com meia dose (MD/DP) em comparação ao regime DP/DP (ver Figura 30), em discordância com os resultados reportados por VOYSEY *et al.* (2023). Essa discrepância persiste mesmo com a compatibilidade das unidades (EU/ml), sugerindo que sua origem está mais associada a hipóteses estruturais do modelo — especialmente aquelas relacionadas à dinâmica das células B de memória (B_m) e sua diferenciação em plasmócitos — do que a possíveis inconsistências de escala ou unidade.

Em BARRETT *et al.* (2021) são apresentados dados de imunogenicidade obtidos em coortes experimentais de fase 1/2, reportados em unidades distintas das utilizadas neste trabalho, como *Arbitrary Units* (AU/ml), *Binding Antibody Units* (BAU/ml) ou títulos de neutralização (ND_{50}). Os resultados indicam que a administração de meia dose como reforço (regime DP/MD) está associada a níveis de anticorpos ligeiramente inferiores

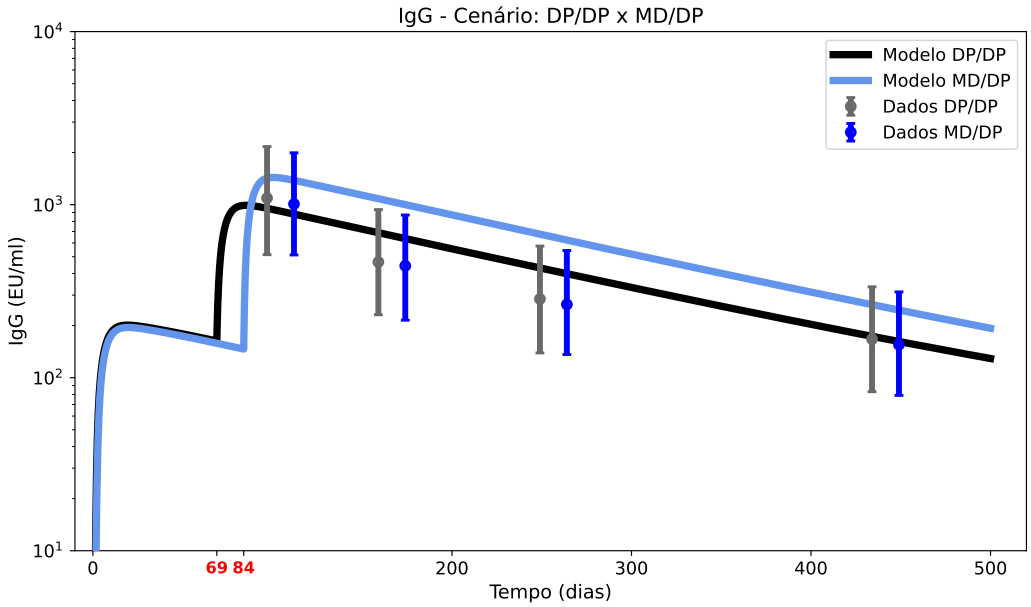

Figura 30: – Comparação entre os dados experimentais de IgG anti-*spike* (EU/ml) reportados por (VOYSEY *et al.*, 2023) e os resultados obtidos pelo modelo matemático para os regimes com DP/DP e MD/DP, com a administração da segunda dose nos dias 69 e 84, respectivamente. Observa-se que, apesar de captar a tendência temporal geral, o modelo superestima a resposta do regime MD/DP em relação ao DP/DP, divergindo dos resultados clínicos apresentados pela coorte.

quando comparados ao regime com duas doses padrão (DP/DP).

Ao confrontar esses achados com as previsões do modelo (Figura 31), observa-se boa concordância qualitativa, uma vez que a comparação quantitativa direta não é possível devido às diferenças de unidades. A dinâmica simulada reproduz a tendência de resposta discretamente inferior para o regime DP/MD em relação ao DP/DP, em alinhamento com os resultados reportados no estudo de referência.

Cabe destacar que os dados de IgG no estudo original são apresentados majoritariamente na forma de figuras, o que limita a extração quantitativa direta. Além disso, os resultados são discriminados por subclasses (IgG1, IgG2 e IgG3), sendo a IgG1 a mais abundante e a principal responsável pela neutralização de antígenos virais. Embora os valores absolutos não sejam explicitamente fornecidos, a análise visual das curvas (em escala logarítmica) permite inferir tendências gerais, possibilitando uma comparação indireta com os resultados do modelo. Nesse contexto, as diferenças observadas entre os regimes DP/DP e DP/MD são consistentes tanto nas simulações quanto nas evidências experimentais, ainda que de pequena magnitude.

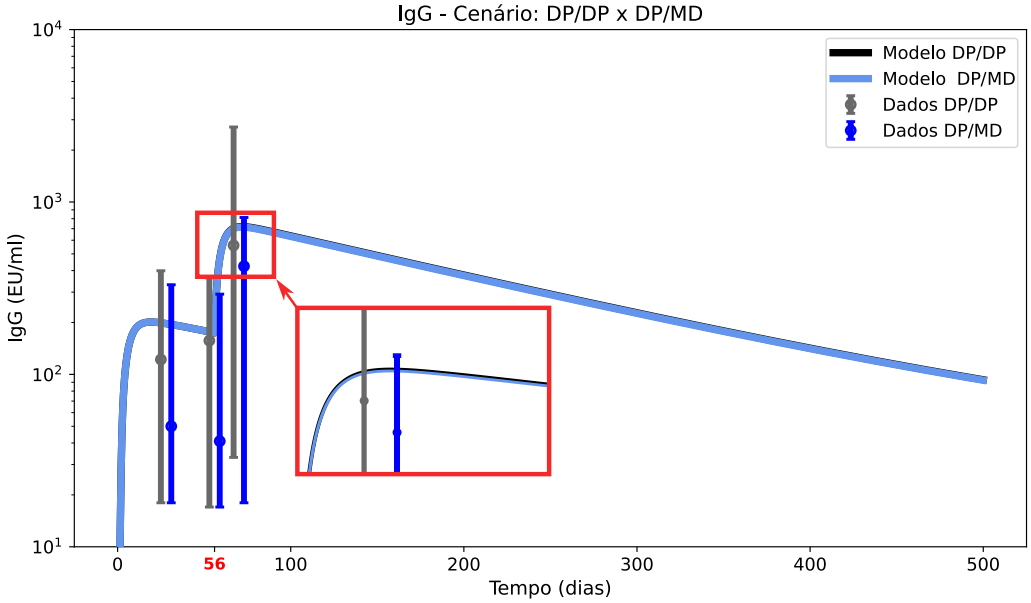

Figura 31: – Resultados do modelo matemático comparando os regimes DP/DP (duas doses padrão) e DP/MD (dose padrão seguida de meia dose). Embora o modelo indique uma tendência de resposta discretamente menor para o regime DP/MD, essa diferença é mínima e não reproduz a magnitude da redução observada experimentalmente por BARRETT *et al.* (2021) através dos dado, principalmente no dia 70. Entretanto, observa-se que o comportamento do modelo é consistente, reproduzindo a mesma tendência descrita no estudo de referência, com pouca diferença entre as curvas correspondentes aos regimes DP/DP e DP/MD. Os dados de coorte referentes aos dias 28, 56 e 70 pós-reforço (representados por barras verticais de erro em cinza e azul, indicando os valores médio, mínimo e máximo) foram ligeiramente deslocados no eixo temporal apenas para evitar sobreposição visual.

5 Discussão

Nosso modelo matemático, descrito na Seção 3, foi capaz de capturar de forma consistente a resposta imune à vacina ChAdOx1 nCoV-19 (AZD1222) em diferentes regimes de dosagem, a partir de um conjunto de parâmetros previamente calibrado. As previsões obtidas apresentaram boa concordância com os níveis de anticorpos observados em dados de coortes clínicas (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023), conforme ilustrado nas Figuras 32, 33, 34 e 35 (Apêndice A), sem a necessidade de reajustes específicos para cada cenário. Destaca-se que o processo de calibração foi realizado com base em apenas uma parcela da coorte, composta por indivíduos com intervalo de 8 a 12 semanas entre doses, evidenciando a capacidade de generalização do modelo.

A CV desenvolvida neste estudo foi construída a partir desses dados empíricos de IgG (Figura 15), provenientes de 115 indivíduos da coorte clínica (FLAXMAN *et al.*, 2021). A partir dessa base, foram gerados 16.064 indivíduos virtuais, por meio da amostragem de conjuntos de parâmetros capazes de reproduzir as trajetórias observadas. Apenas as simulações com erro relativo inferior a 5% foram mantidas, conforme definido na Equação 3.15. A calibração foi realizada utilizando o algoritmo de Evolução Diferencial, permitindo explorar eficientemente o espaço paramétrico em busca de configurações biologicamente plausíveis.

Essa estratégia assegura que a CV represente de forma realista a variabilidade interindividual da resposta imune. As trajetórias apresentadas nas Figuras 14, 36, 37, 38 e 39 evidenciam essa variabilidade sob diferentes esquemas vacinais. De forma complementar, as Figuras 20, 21, 22, 23 e 24 apresentam a propagação das incertezas paramétricas, permitindo avaliar a robustez do modelo.

Em conjunto, esses resultados demonstram que o modelo generaliza adequadamente além do cenário de calibração, reproduzindo tanto a magnitude dos picos quanto as tendências de decaimento observadas experimentalmente. Nos regimes de duas doses, as simulações capturam de forma consistente a cinética dos níveis de IgG (FLAXMAN *et al.*, 2021; VOYSEY *et al.*, 2023), enquanto, nos regimes de três doses, reproduzem o aumento associado ao reforço e a extensão da persistência dos anticorpos. Adicionalmente, observa-se a manutenção de níveis detectáveis de IgG por mais de um ano, em concordância com dados clínicos (VOYSEY *et al.*, 2023), indicando proteção prolongada contra formas graves da doença (FOLEGATTI *et al.*, 2020).

As simulações dos intervalos entre doses revelaram uma relação não linear entre o espaçamento das aplicações e a proteção imunológica: intervalos mais longos aumentam a magnitude dos picos de anticorpos, mas não prolongam proporcionalmente sua duração. Esse comportamento reflete limitações intrínsecas da dinâmica das células B de memória, modeladas por uma capacidade máxima de expansão ($Bm_{\max}$), que favorece respostas

mais intensas a reforços tardios sem estender significativamente o tempo de proteção.

A análise dos dados experimentais também revelou resultados contraintuitivos. No estudo de VOYSEY *et al.* (2021), o regime MD/DP apresentou maior eficácia clínica (90%) sem corresponder a níveis superiores de anticorpos quando comparado ao regime DP/DP. Como mostrado na Tabela 5, os títulos geométricos médios (GMT) de IgG anti-*spike* 28 dias após a segunda dose são comparáveis entre os dois regimes, não evidenciando superioridade quantitativa do MD/DP.

Tabela 5 – Níveis de anticorpos IgG (GMT) 28 dias após a 2ª dose (intervalo > 12 semanas).

Regime de Dose (UK)	**GMT (Unidades ELISA)**	**IC 95%**
Baixa Dose / Dose Padrão (MD/DP)	15.317	13.013 – 18.034
Dose Padrão / Dose Padrão (DP/DP)	18.740	16.071 – 21.843

A quantificação de incerteza reforçou os resultados obtidos, destacando a influência de parâmetros-chave, como a homeostase das células B *naïve* (B_{n0}), o decaimento das células plasmáticas (δ_{pc}) e as taxas de produção e depuração de IgG (π_{pc} e δ_{IgG}). A análise de sensibilidade revelou ainda que a importância desses parâmetros varia ao longo do tempo, com B_{n0} dominando a fase inicial e δ_{pc} influenciando a manutenção de longo prazo dos anticorpos.

As simulações de otimização permitiram identificar intervalos ideais entre doses. Para esquemas de duas doses, um intervalo de 106 dias maximizou o TPS (81%), enquanto, para três doses, intervalos de 30 e 94 dias resultaram em cobertura de até 94%. Esses resultados, entretanto, dependem do limiar de proteção adotado (218 EU/mL), cuja relação com a proteção clínica envolve múltiplos fatores além da resposta humoral.

Nesse sentido, os esquemas propostos devem ser interpretados como hipóteses mecanisticamente fundamentadas, cuja validação requer integração com modelos epidemiológicos e dados experimentais adicionais. Fatores como logística de distribuição, disponibilidade de vacinas e circulação de variantes virais também influenciam diretamente a implementação dessas estratégias em nível populacional.

Apesar dos resultados promissores, o modelo apresenta limitações importantes. Entre elas, destacam-se a ausência de infecção prévia na população modelada e a não inclusão explícita de componentes da imunidade celular. Embora parte desses efeitos esteja implicitamente incorporada em parâmetros do modelo, sua representação não captura completamente a complexidade da resposta imune.

Ainda assim, o modelo demonstra robustez na descrição da dinâmica imunológica em nível populacional e apresenta potencial para aplicações práticas, como planejamento de esquemas vacinais, avaliação de estratégias de dose fracionada e construção de coortes virtuais.

Por fim, futuras investigações poderão explorar a incorporação explícita da imunidade celular, o desenvolvimento de modelos estocásticos para representar a variabilidade individual, a análise de respostas a variantes virais e o uso de metaheurísticas alternativas para a calibração e otimização dos parâmetros do modelo. Esses avanços permitirão refinar a representação dos mecanismos imunológicos e ampliar a capacidade descritiva do modelo.

Para auxiliar na interpretação dos resultados e orientar investigações futuras, resumimos a seguir algumas potenciais limitações e fontes de viés do presente estudo:

- **Qualidade e completude dos dados:** os conjuntos de dados clínicos utilizados para calibração ocasionalmente não apresentavam medidas completas de dispersão, que precisaram ser aproximadas. Além disso, a ausência de metadados relevantes (como comorbidades ou distribuição etária detalhada) limita análises estratificadas da coorte.
- **Representatividade populacional:** a calibração do modelo foi realizada com dados provenientes de coortes compostas principalmente por indivíduos entre 18 e 55 anos. Dessa forma, a extrapolação quantitativa dos resultados para populações idosas ou imunocomprometidas deve ser feita com cautela, sendo recomendada a recalibração do modelo para esses grupos.
- **Omissões estruturais do modelo:** o modelo concentra-se principalmente na dinâmica da resposta humoral e simplifica ou não representa explicitamente alguns processos da imunidade celular, como respostas de células T $CD8^+$ e sinalização da imunidade inata, que podem influenciar a depuração do antígeno e a proteção de longo prazo.
- **Incerteza e identificabilidade de parâmetros:** alguns parâmetros do modelo são fracamente restringidos pelos dados disponíveis, o que pode ampliar os intervalos preditivos e permitir combinações de parâmetros que reproduzam os dados observados, mas com interpretações mecanísticas distintas.
- **Dependência do limiar de proteção:** os resultados de otimização baseados em um único limiar de proteção devem ser interpretados com cautela, uma vez que diferentes valores de limiar podem levar a intervalos de dose ótimos distintos.
- **Limitações na representação de regimes alternativos de dosagem:** o modelo não reproduziu plenamente o comportamento observado em regimes de baixa dose seguida de dose padrão (MD/DP), relatado em ensaios clínicos da vacina ChAdOx1 nCoV-19. Esse resultado sugere que aspectos qualitativos da resposta imune, possivelmente relacionados à maturação da memória imunológica ou a mecanismos celulares não explicitamente modelados, podem desempenhar um papel importante nesse contexto.

6 Considerações Finais

A pandemia de COVID-19 evidenciou a necessidade de compreender, de forma quantitativa, os mecanismos que governam a resposta imune induzida por vacinas, bem como de avaliar o impacto de diferentes estratégias de imunização em cenários caracterizados por elevada variabilidade populacional. Nesse contexto, a modelagem matemático-computacional emerge como uma ferramenta promissora, embora ainda existam lacunas relevantes relacionadas à integração entre modelos mecanicistas, dados clínicos e variabilidade interindividual.

Inserido nesse cenário, este trabalho investigou a capacidade de modelos matemáticos mecanicistas, integrados a coortes virtuais calibradas com dados clínicos, de descrever e prever a dinâmica da resposta imune humoral induzida por diferentes esquemas de vacinação com a ChAdOx1 nCoV-19. Os resultados obtidos fornecem evidências consistentes de que essa abordagem é capaz de capturar tanto o comportamento médio quanto a dispersão observada na resposta de anticorpos, corroborando a hipótese central desta pesquisa.

A construção de uma coorte virtual com mais de 16.000 indivíduos permitiu a realização de experimentos *in silico* em larga escala, possibilitando a análise sistemática de diferentes combinações de doses e intervalos de administração. A partir dessas análises, foi possível demonstrar que variações nos esquemas vacinais produzem efeitos mensuráveis na magnitude e na persistência da resposta humoral, evidenciando a utilidade do modelo como ferramenta quantitativa para a comparação de estratégias de imunização.

As principais contribuições deste trabalho podem ser compreendidas em três dimensões complementares. Em primeiro lugar, do ponto de vista metodológico, foi proposta e validada uma abordagem integrada que combina modelagem mecanicista baseada em equações diferenciais ordinárias com a construção de coortes virtuais calibradas a dados clínicos, permitindo a incorporação explícita da variabilidade interindividual. Em segundo lugar, no âmbito aplicado, o modelo desenvolvido foi capaz de reproduzir padrões observados experimentalmente e de explorar, de forma controlada, cenários vacinais não diretamente acessíveis por estudos clínicos tradicionais. Por fim, no plano conceitual, o trabalho contribui para o entendimento da dinâmica da resposta imune humoral, ao evidenciar como diferentes regimes de vacinação influenciam simultaneamente a intensidade e a duração da resposta de anticorpos.

Embora a vacina que serviu de base para este estudo, a ChAdOx1 nCoV-19 na formulação AZD1222, tenha tido sua produção e distribuição global encerradas em 2024 (DOREMALEN *et al.*, 2022), os resultados obtidos permanecem relevantes. O modelo desenvolvido contribui para o entendimento das dinâmicas da resposta imune humoral induzida por vacinas baseadas em vetor viral e pode ser adaptado para o estudo de outras plataformas vacinais com mecanismos imunológicos semelhantes.

Não obstante, algumas limitações devem ser consideradas. O modelo proposto concentra-se predominantemente na resposta humoral, não incorporando explicitamente componentes relevantes da imunidade celular, como a resposta mediada por linfócitos T. Além disso, a calibração do modelo depende da disponibilidade e qualidade dos dados clínicos, o que pode impactar a robustez das estimativas paramétricas e das previsões obtidas.

Uma limitação adicional relevante refere-se à heterogeneidade das unidades utilizadas para reportar níveis de anticorpos em diferentes estudos clínicos. Medidas de IgG e neutralização são frequentemente expressas em unidades distintas, como *Enzyme-Linked Immunosorbent Assay Units* (EU/ml), *Binding Antibody Units* (BAU/ml), *Arbitrary Units* (AU/ml) e títulos de neutralização, como ND_{50} ou ID_{50}. Essas unidades, em geral, não são diretamente conversíveis entre si, uma vez que dependem de protocolos experimentais específicos, kits laboratoriais distintos e padrões de calibração próprios. Essa falta de padronização dificulta a integração de dados provenientes de diferentes fontes, limitando tanto a calibração do modelo quanto a validação cruzada com estudos independentes. Como consequência, a generalização do modelo para novos conjuntos de dados requer cuidados adicionais, especialmente na interpretação quantitativa.

Como perspectivas futuras, destacam-se a ampliação do modelo para diferentes plataformas vacinais e contextos epidemiológicos, bem como sua integração com abordagens mais abrangentes, como gêmeos digitais e técnicas de aprendizado de máquina. Essas direções têm potencial para aumentar a capacidade preditiva do modelo e viabilizar sua aplicação em cenários clínicos e de saúde pública, incluindo estratégias de vacinação personalizadas.

REFERÊNCIAS

A, S. *et al.* **Global Sensitivity Analysis: The Primer**. Chichester (England): Wiley, 2008.

ABBAS, A. K.; LICHTMAN, A. H.; PILLAI, S. **Imunologia celular e molecular**. [S.l.]: Elsevier Brasil, 2015.

ADALJA, D. *et al.* Advancing truss structure optimization—a multi-objective weighted average algorithm with enhanced convergence and diversity. **Results in Engineering**, Elsevier BV, v. 25, p. 104241, mar. 2025. ISSN 2590-1230. Disponível em: <http://dx.doi.org/10.1016/j.rineng.2025.104241>.

ADOLPH, E. F. The metabolism and distribution of water in body and tissues. **Physiological Reviews**, v. 13, n. 3, p. 336–371, 1933.

ALJAIDI, M. *et al.* Morime: A multi-objective rime optimization framework for efficient truss design. **Results in Engineering**, Elsevier BV, v. 25, p. 103933, mar. 2025. ISSN 2590-1230. Disponível em: <http://dx.doi.org/10.1016/j.rineng.2025.103933>.

ALLEMAILEM, K. S. A comprehensive computer aided vaccine design approach to propose a multi-epitopes subunit vaccine against genus klebsiella using pan-genomics, reverse vaccinology, and biophysical techniques. **Vaccines**, MDPI AG, v. 9, n. 10, p. 1087, set. 2021. Disponível em: <https://doi.org/10.3390/vaccines9101087>.

BAKER, C.; BOCHAROV, G.; PAUL, C. Mathematical modelling of the interleukin-2 t-cell system: A comparative study of approaches based on ordinary and delay differential equation. **Computational and Mathematical Methods in Medicine**, Hindawi Publishing Corporation, v. 1, n. 2, p. 117–128, 1997.

BARRETT, J. R. *et al.* Phase 1/2 trial of sars-cov-2 vaccine chadox1 ncov-19 with a booster dose induces multifunctional antibody responses. **Nature medicine**, Nature Publishing Group US New York, v. 27, n. 2, p. 279–288, 2021.

BERNASCHI, M.; CASTIGLIONE, F. Design and implementation of an immune system simulator. **Computers in Biology and Medicine**, v. 31, n. 5, p. 303 – 331, 2001. ISSN 0010-4825.

BONIN, C. *et al.* Computational modeling of the immune response to yellow fever. **Journal of Computational and Applied Mathematics**, Elsevier, v. 295, p. 127–138, 2016.

BONIN, C. *et al.* A simplified mathematical-computational model of the immune response to the yellow fever vaccine. In: IEEE. **Bioinformatics and Biomedicine (BIBM), 2017 IEEE International Conference on**. [S.l.], 2017. p. to appear.

BONIN, C. R. B. *et al.* Validation of a yellow fever vaccine model using data from primary vaccination in children and adults, re-vaccination and dose-response in adults and studies with immunocompromised individuals. **BMC bioinformatics**, Springer, v. 21, p. 1–25, 2020.

BONIN, C. R. B. *et al.* Mathematical modeling based on ordinary differential equations: A promising approach to vaccinology. **Human vaccines & immunotherapeutics**, Taylor & Francis, v. 13, n. 2, p. 484–489, 2017.

BRABER, I. den *et al.* Maintenance of peripheral naive t cells is sustained by thymus output in mice but not humans. **Proceedings of the National Academy of Sciences of the United States of America**, National Academy of Sciences, v. 109, n. 12, p. 4828–4833, 2012.

CELADA, F.; SEIDEN, P. E. A computer model of cellular interactions in the immune system. **Immunology today**, Elsevier, v. 13, n. 2, p. 56–62, 1992.

CHANG, S. T.; LINDERMAN, J. J.; KIRSCHNER, D. E. Multiple mechanisms allow mycobacterium tuberculosis to continuously inhibit mhc class ii-mediated antigen presentation by macrophages. **Proceedings of the National Academy of Sciences of the United States of America**, National Acad Sciences, v. 102, n. 12, p. 4530–4535, 2005.

CHAO, D. L. *et al.* A stochastic model of cytotoxic t cell responses. **Journal of Theoretical Biology**, Elsevier, v. 228, n. 2, p. 227–240, 2004.

CUPPENS, B. *et al.* Mathematical modeling of hepatitis b virus infection: dynamics, treatment, and persistence. **PLoS Computational Biology**, Public Library of Science, v. 11, n. 10, p. e1004789, 2015.

DAINA, A.; MICHIELIN, O.; ZOETE, V. SwissADME: a free web tool to evaluate pharmacokinetics, drug-likeness and medicinal chemistry friendliness of small molecules. **Scientific Reports**, Springer Science and Business Media LLC, v. 7, n. 1, p. 1–10, 2017.

DAVIES, M. *et al.* Toward the discovery of vaccine adjuvants: coupling in silico screening and in vitro analysis of antagonist binding to human and mouse ccr4 receptors. **Plos One**, v. 4, p. e8084, 2009.

DELISI, C.; BERZOFSKY, J. A. T-cell antigenic sites tend to be amphipathic structures. **Proceedings of the National Academy of Sciences**, v. 82, p. 7048–7052, 1985.

DELVES, P. J. *et al.* **Essential immunology**. [S.l.]: John Wiley & Sons, 2017.

DOREMALEN, N. V. *et al.* Chadox1 ncov-19 vaccine prevents sars-cov-2 pneumonia in rhesus macaques. **Nature**, Nature Publishing Group UK London, v. 586, n. 7830, p. 578–582, 2020.

DOREMALEN, N. van *et al.* Chadox1 ncov-19 (azd1222) or ncov-19-beta (azd2816) protect syrian hamsters against beta delta and omicron variants. **Nature Communications**, Nature Publishing Group UK London, v. 13, n. 1, p. 4610, 2022.

DOYTCHINOVA, I.; FLOWER, D. Vaxijen: a server for prediction of protective antigens, tumour antigens and subunit vaccines. **BMC Bioinformatics**, v. 8, 2007.

European Medicines Agency. **Vaxzevria (previously COVID-19 Vaccine AstraZeneca): Withdrawal of the marketing authorisation in the European Union**. 2024. Accessed: 3 Mar. 2026. Disponível em: <https://www.ema.europa.eu/en/medicines/human/EPAR/vaxzevria>.

FEINBERG, J.; LANGTANGEN, H. P. Chaospy: An open source tool for designing methods of uncertainty quantification. **J. Comput. Science**, v. 11, p. 46–57, 2015. Disponível em: <https://doi.org/10.1016/j.jocs.2015.08.008>.

FENG, S. *et al.* Correlates of protection against symptomatic and asymptomatic sars-cov-2 infection. **Nature medicine**, Nature Publishing Group US New York, v. 27, n. 11, p. 2032–2040, 2021.

FLAXMAN, A. *et al.* Reactogenicity and immunogenicity after a late second dose or a third dose of ChAdOx1 nCoV-19 in the UK: a substudy of two randomised controlled trials (COV001 and COV002). **The Lancet**, Elsevier BV, v. 398, n. 10304, p. 981–990, set. 2021. Disponível em: <https://doi.org/10.1016/s0140-6736(21)01699-8>.

FLEGG, J. A. *et al.* Wound healing angiogenesis: the clinical implications of a simple mathematical model. **Journal of theoretical biology**, Elsevier, v. 300, p. 309–316, 2012.

FLOWER, D. R. *et al.* Computer aided selection of candidate vaccine antigens. **Immunome Research**, Springer Science and Business Media LLC, v. 6, n. Suppl 2, p. S1, 2010. Disponível em: <https://doi.org/10.1186/1745-7580-6-s2-s1>.

FOLEGATTI, P. M. *et al.* Safety and immunogenicity of the chadox1 ncov-19 vaccine against sars-cov-2: a preliminary report of a phase 1/2, single-blind, randomised controlled trial. **The Lancet**, Elsevier, v. 396, n. 10249, p. 467–478, 2020.

GENSER, B. *et al.* A guide to modern statistical analysis of immunological data. **BMC immunology**, Springer, v. 8, p. 1–15, 2007.

GONÇALVES, A. *et al.* Timing of antiviral treatment initiation is critical to reduce sars-cov-2 viral load. **Frontiers in Immunology**, Frontiers, v. 11, p. 591802, 2020.

GROOT, A. S. D. *et al.* From genome to vaccine: in silico predictions, ex vivo verification. **Vaccine**, Elsevier BV, v. 19, n. 31, p. 4385–4395, ago. 2001. Disponível em: <https://doi.org/10.1016/s0264-410x(01)00145-1>.

HAYNES, B. F. *et al.* B-cell–lineage immunogen design in vaccine development with HIV-1 as a case study. **Nature Biotechnology**, Springer Science and Business Media LLC, v. 30, n. 5, p. 423–433, maio 2012. Disponível em: <https://doi.org/10.1038/nbt.2197>.

HELGERS, H. *et al.* Digital twins for continuous mrna production. **Processes**, MDPI, v. 9, n. 11, p. 1967, 2021.

HERMAN, J.; USHER, W. SALib: an open-source python library for sensitivity analysis. **Journal of Open Source Software**, v. 2, n. 9, p. 97, 2017.

HEYDE, C. C.; SENETA, E. **IJ Bienaymé: Statistical theory anticipated**. [S.l.]: Springer Science & Business Media, 2012.

HOMMA, T.; SALTELLI, A. Importance measures in global sensitivity analysis of nonlinear models. **Reliability Engineering & System Safety**, Elsevier, v. 52, n. 1, p. 1–17, 1996.

HORST, D. van der *et al.* Naive b cells in humans: a rapidly renewing, heterogeneous population. **Blood**, American Society of Hematology, v. 119, n. 25, p. 5301–5309, 2012.

HU, B. *et al.* Characteristics of sars-cov-2 and covid-19. **Nature Reviews Microbiology**, Nature, v. 19, p. 141–154, 2021.

HUANG, C. *et al.* 6-month consequences of covid-19 in patients discharged from hospital: a cohort study. **The Lancet**, Elsevier, v. 401, n. 10393, p. e21–e33, 2023.

HUANG, C. *et al.* Clinical features of patients infected with 2019 novel coronavirus in wuhan, china. **The lancet**, Elsevier, v. 395, n. 10223, p. 497–506, 2020.

INTEGRATE. **Solve ivp**. November 2025. Acessado em: 20 mar. 2026. Disponível em: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.integrate.solve_ivp.html>.

JANGIR, P. *et al.* A cooperative strategy-based differential evolution algorithm for robust pem fuel cell parameter estimation. **Ionics**, Springer Science and Business Media LLC, v. 31, n. 1, p. 703–741, dez. 2024. ISSN 1862-0760. Disponível em: <http://dx.doi.org/10.1007/s11581-024-05963-x>.

KHISHE, M. *et al.* Innovative diversity metrics in hierarchical population-based differential evolution for <scp>pem</scp> fuel cell parameter optimization. **Engineering Reports**, Wiley, v. 7, n. 1, dez. 2024. ISSN 2577-8196. Disponível em: <http://dx.doi.org/10.1002/eng2.13065>.

KOHLER, B. *et al.* A systematic approach to vaccine complexity using an automaton model of the cellular and humoral immune system: I. viral characteristics and polarized responses. **Vaccine**, Elsevier, v. 19, n. 7, p. 862–876, 2000.

KSIAZEK, T. G. *et al.* A novel coronavirus associated with severe acute respiratory syndrome. **New England journal of medicine**, Mass Medical Soc, v. 348, n. 20, p. 1953–1966, 2003.

KUMAR, N. *et al.* Applying computational modeling to drug discovery and development. **Drug Discovery Today**, Elsevier BV, v. 11, n. 17-18, p. 806–811, set. 2006. Disponível em: <https://doi.org/10.1016/j.drudis.2006.07.010>.

LAUBENBACHER, R. *et al.* Digital twins in medicine. **Nature Computational Science**, Springer Science and Business Media LLC, v. 4, n. 3, p. 184–191, mar. 2024. ISSN 2662-8457. Disponível em: <http://dx.doi.org/10.1038/s43588-024-00607-6>.

LAUBENBACHER, R. *et al.* Building digital twins of the human immune system: toward a roadmap. **NPJ digital medicine**, Nature Publishing Group UK London, v. 5, n. 1, p. 64, 2022.

LEE, E. *et al.* Systems biology approach predicts immunogenicity of the yellow fever vaccine in humans. **Nature Immunology**, v. 10, p. 116–125, 2008.

LEVINSON, W. **Microbiologia médica e imunologia**. [S.l.]: McGraw Hill Brasil, 2016.

LI, Q. *et al.* Early transmission dynamics in wuhan, china, of novel coronavirus–infected pneumonia. **New England journal of medicine**, Mass Medical Soc, 2020.

MA, J. *et al.* Computer-aided discovery of potent broad-spectrum vaccine adjuvants. **Angewandte Chemie International Edition**, Wiley, v. 62, n. 18, mar. 2023. Disponível em: <https://doi.org/10.1002/anie.202301059>.

Ministério da Saúde (Brasil). **Painel Coronavírus – Casos e Óbitos de COVID-19**. 2020–2025. `https://covid.saude.gov.br/`. Painel oficial de dados sobre casos confirmados e óbitos por COVID-19 no Brasil (acesso contínuo).

MORPURGO, D. *et al.* Modelling thymic functions in a cellular automaton. **International immunology**, Oxford University Press, v. 7, n. 4, p. 505–516, 1995.

NANDY, A.; BASAK, S. A brief review of computer-assisted approaches to rational design of peptide vaccines. **International Journal of Molecular Sciences**, MDPI AG, v. 17, n. 5, p. 666, maio 2016. Disponível em: <https://doi.org/10.3390/ijms17050666>.

NOSSENT, J.; ELSEN, P.; BAUWENS, W. Sobol'sensitivity analysis of a complex environmental model. **Environmental Modelling & Software**, Elsevier, v. 26, n. 12, p. 1515–1525, 2011.

PAPPALARDO, F. *et al.* Computational modelling approaches to vaccinology. **Pharmacological research**, Elsevier, v. 92, p. 40–45, 2015.

PAPPALARDO, F. *et al.* Agent based modeling of relapsing multiple sclerosis: A possible approach to predict treatment outcome. In: IEEE. **2018 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)**. [S.l.], 2018. p. 1380–1385.

PERELSON, A. S. Modeling the interaction of the immune system with hiv. In: CASTILLO-CHAVEZ, C. (Ed.). **Mathematical and Statistical Approaches to AIDS Epidemiology**. [S.l.]: Springer Berlin Heidelberg, 1989, (Lecture Notes in Biomathematics, v. 83). p. 350–370.

PETTET, G. *et al.* A model of wound-healing angiogenesis in soft tissue. **Mathematical biosciences**, Elsevier, v. 136, n. 1, p. 35–63, 1996.

PIGOZZO, A. B. *et al.* On the computational modeling of the innate immune system. **BMC bioinformatics**, BioMed Central, v. 14, n. 6, p. S7, 2013.

PUKELSHEIM, F. The three sigma rule. **The American Statistician**, Taylor & Francis, v. 48, n. 2, p. 88–91, 1994.

QUINTELA, B. d. M.; SANTOS, R. W. dos; LOBOSCO, M. On the coupling of two models of the human immune response to an antigen. **BioMed research international**, Hindawi Publishing Corporation, v. 2014, 2014.

RAMIREZ, A.; COX, C. Improving on the range rule of thumb. **Rose-Hulman Undergraduate Mathematics Journal**, v. 13, n. 2, p. 1, 2012.

RAPPUOLI, R. Reverse vaccinology. **Current opinion in microbiology**, Elsevier, v. 3, n. 5, p. 445–450, 2000.

REIS, R. F. *et al.* A validated mathematical model of the cytokine release syndrome in severe covid-19. **Frontiers in Molecular Biosciences**, v. 8, p. 680, 2021. ISSN 2296-889X.

REN, Y. *et al.* Machine learning-based prediction of elliptical double steel columns under compression loading. **Journal of Big Data**, Springer Science and Business Media LLC, v. 12, n. 1, fev. 2025. ISSN 2196-1115. Disponível em: <http://dx.doi.org/10.1186/s40537-025-01081-1>.

RHODES, S. *et al.* Identifying covid-19 optimal vaccine dose using mathematical immunostimulation/immunodynamic modelling. **Vaccine**, Elsevier, v. 40, n. 49, p. 7032–7041, 2022.

RHODES, S. J. *et al.* Dose finding for new vaccines: The role for immunostimulation/immunodynamic modelling. **Journal of theoretical biology**, Elsevier, v. 465, p. 51–55, 2019.

SAW, J. G.; YANG, M. C.; MO, T. C. Chebyshev inequality with estimated mean and variance. **The American Statistician**, Taylor & Francis, v. 38, n. 2, p. 130–132, 1984.

SAWKA, M. N.; CHEUVRONT, S. N.; CARTER, R. Human water needs. **Nutrition reviews**, Oxford University Press Oxford, UK, v. 63, n. suppl_1, p. S30–S39, 2005.

SHAFER, D.; ZHANG, Z. **Introductory Statistics Version 1.0**. Flat World Knowledge, Incorporated, 2012. ISBN 9781453344859. Disponível em: <https://books.google.com.br/books?id=YzVcvgAACAAJ>.

SOBOL, I. M. Global sensitivity indices for nonlinear mathematical models and their monte carlo estimates. **Mathematics and computers in simulation**, Elsevier, v. 55, n. 1-3, p. 271–280, 2001.

SOMPAYRAC, L. **How the Immune System Works**. 6th. ed. Hoboken, NJ: Wiley-Blackwell, 2019. ISBN 978-1119542124.

SRIKANTH, G. *et al.* Food security based marine life ecosystem for polar region conditioning: Remote sensing analysis with machine learning model. **Remote Sensing in Earth Systems Sciences**, Springer Science and Business Media LLC, v. 8, n. 1, p. 65–73, dez. 2024. ISSN 2520-8209. Disponível em: <http://dx.doi.org/10.1007/s41976-024-00172-6>.

STORN, R.; PRICE, K. Differential evolution–a simple and efficient heuristic for global optimization over continuous spaces. **Journal of global optimization**, Springer, v. 11, n. 4, p. 341–359, 1997.

SU, B. *et al.* Mathematical modelling of immune response in tissues. **Computational and Mathematical Methods in Medicine**, Taylor & Francis, v. 10, n. 1, p. 9–38, 2009.

TANG, Y. *et al.* Cytokine storm in covid-19: the current evidence and treatment strategies. **Frontiers in immunology**, Frontiers, v. 11, p. 1708, 2020.

TAY, M. Z. *et al.* The trinity of covid-19: immunity, inflammation and intervention. **Nature Reviews Immunology**, Nature Publishing Group UK London, v. 20, n. 6, p. 363–374, 2020.

THOMAS, S. *et al.* Artificial intelligence in vaccine and drug design. **Methods in molecular biology (Clifton, N.J.)**, v. 2410, p. 131—146, 2022. ISSN 1064-3745.

TISONCIK, J. R. *et al.* Into the eye of the cytokine storm. **Microbiology and molecular biology reviews**, American Society for Microbiology 1752 N St., NW, Washington, DC, v. 76, n. 1, p. 16–32, 2012.

TYAGI, A. *et al.* In silico models for designing and discovering novel anticancer peptides. **Scientific Reports**, v. 3, 2013.

UWAMINO, Y. *et al.* Estimating immunity with mathematical models for sars-cov-2 after covid-19 vaccination. **npj Vaccines**, Nature Publishing Group UK London, v. 8, n. 1, p. 33, 2023.

VALIM, V. *et al.* Effectiveness, safety, and immunogenicity of half dose chadox1 ncov-19 covid-19 vaccine: Viana project. **Frontiers in Immunology**, Frontiers Media SA, v. 13, p. 966416, 2022.

VODOVOTZ, Y. *et al.* In silico models of acute inflammation in animals. **Shock**, LWW, v. 26, n. 3, p. 235–244, 2006.

VOYSEY, M. *et al.* Safety and efficacy of the ChAdOx1 nCoV-19 vaccine (AZD1222) against SARS-CoV-2: an interim analysis of four randomised controlled trials in brazil, south africa, and the UK. **The Lancet**, Elsevier BV, v. 397, n. 10269, p. 99–111, jan. 2021. Disponível em: <https://doi.org/10.1016/s0140-6736(20)32661-1>.

VOYSEY, M. *et al.* Single-dose administration and the influence of the timing of the booster dose on immunogenicity and efficacy of ChAdOx1 nCoV-19 (AZD1222) vaccine: a pooled analysis of four randomised trials. **The Lancet**, Elsevier BV, v. 397, n. 10277, p. 881–891, mar. 2021. Disponível em: <https://doi.org/10.1016/s0140-6736(21)00432-3>.

VOYSEY, M. *et al.* Persistence of the immune response after two doses of chadox1 ncov-19 (azd1222): 1 year of follow-up of two randomized controlled trials. **Clinical and Experimental Immunology**, Oxford University Press US, v. 211, n. 3, p. 280–287, 2023.

V'KOVSKI, P. *et al.* Coronavirus biology and replication: implications for sars-cov-2. **Nature Reviews Microbiology**, Nature Publishing Group UK London, v. 19, n. 3, p. 155–170, 2021.

WALLS, A. C. *et al.* Structure, function, and antigenicity of the sars-cov-2 spike glycoprotein. **Cell**, Elsevier, v. 181, n. 2, p. 281–292, 2020.

WATSON, P. E.; WATSON, I. D.; BATT, R. D. Total body water volumes for adult males and females estimated from simple anthropometric measurements. **The American journal of clinical nutrition**, Elsevier, v. 33, n. 1, p. 27–39, 1980.

WILLCOX, K.; SEGUNDO, B. The role of computational science in digital twins. **Nature Computational Science**, Springer Science and Business Media LLC, v. 4, n. 3, p. 147–149, mar. 2024. ISSN 2662-8457. Disponível em: <http://dx.doi.org/10.1038/s43588-024-00609-4>.

WILLIAMS, D. E. Statistics of antibody binding to the spike protein explain the dependence of covid 19 infection risk on antibody concentration and affinity. **Scientific Reports**, Nature Publishing Group UK London, v. 12, n. 1, p. 9379, 2022.

World Health Organization. **Statement on the second meeting of the International Health Regulations (2005) Emergency Committee regarding the outbreak of novel coronavirus (2019-nCoV)**. [S.l.]: World Health Organization, January 2020. `https://www.who.int/news/item/30-01-2020-statement-on-the-second-meeting-of-the-international-health-regulations-(2005)-emergency-committee-regarding-the-outbreak-of-novel-coronavirus-(2019-ncov)`. Accessed: 30 October 2025.

World Health Organization. **WHO Director-General's opening remarks at the media briefing on COVID-19 - 11 March 2020**. 2020. Accessed: 20 Jan. 2026. Disponível em: <https://www.who.int/news-room/speeches/item/who-director-general-s-opening-remarks-at-the-media-briefing-on-covid-19—11-march-2020>.

World Health Organization. **WHO Coronavirus (COVID-19) Dashboard**. 2026. Acesso em: 24 jan. 2026. Disponível em: <https://data.who.int/dashboards/covid19/cases>.

WRAPP, D. *et al.* Cryo-em structure of the 2019-ncov spike in the prefusion conformation. **Science**, American Association for the Advancement of Science, v. 367, n. 6483, p. 1260–1263, 2020.

XAVIER, M. *et al.* A simplified model of the human immune system response to the covid-19. In: **2020 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)**. Los Alamitos, CA, USA: IEEE Computer Society, 2020. p. 1311–1317.

XAVIER, M. P. *et al.* On the use of gillespie stochastic simulation algorithm in a model of the human immune system response to the yellow fever vaccine. In: **2017 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)**. [s.n.], 2017. v. 00, p. 1476–1482. Disponível em: <doi.ieeecomputersociety.org/10.1109/BIBM.2017.8217880>.

XAVIER, M. P. *et al.* Modelling the human immune system response to the chadox1 ncov-19 vaccine. In: IEEE. **2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)**. [S.l.], 2021. p. 3327–3333.

XAVIER, M. P.; SANTOS, R. W. D.; LOBOSCO, M. Reproduction of antibody levels following five distinct chadox1 ncov-19 vaccine regimens through virtual patient cohorts. **Computers in Biology and Medicine**, Elsevier, v. 198, p. 111149, 2025.

YANG, L. *et al.* Covid-19: immunopathogenesis and immunotherapeutics. **Signal transduction and targeted therapy**, Nature Publishing Group UK London, v. 5, n. 1, p. 128, 2020.

YANG, X. *et al.* Concepts of artificial intelligence for computer-assisted drug discovery. **Chemical Reviews**, American Chemical Society (ACS), v. 119, n. 18, p. 10520–10594, jul. 2019. Disponível em: <https://doi.org/10.1021/acs.chemrev.8b00728>.

ZHOU, P. *et al.* A pneumonia outbreak associated with a new coronavirus of probable bat origin. **nature**, Nature Publishing Group UK London, v. 579, n. 7798, p. 270–273, 2020.

A APÊNDICE A – Simulações adicionais para diferentes intervalos entre doses: modelo calibrado e Coorte Virtual

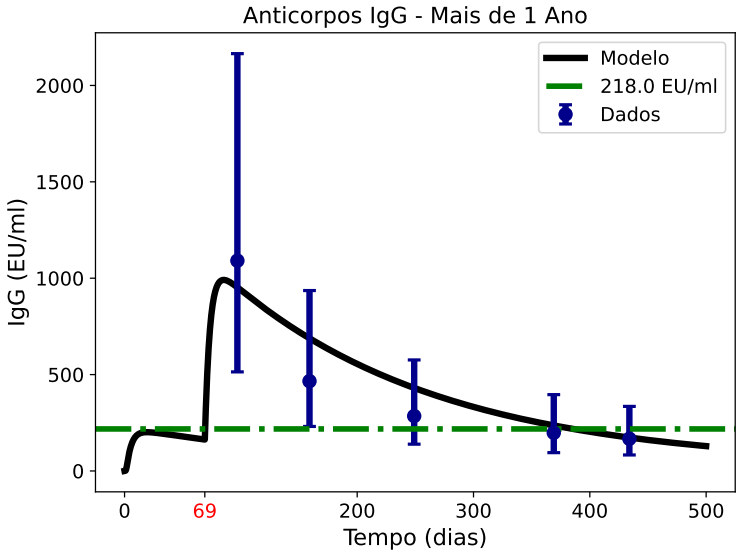

Figura 32: – Simulação do modelo (linha preta contínua) comparada aos dados experimentais (pontos em azul com barras de erro) para o regime de vacinação com duas doses e acompanhamento superior a um ano. A simulação utiliza o conjunto de parâmetros padrão (média das observações aceitas), previamente calibrado com base no cenário de duas doses com intervalo de 8 a 12 semanas, não havendo ajuste adicional para este regime. A segunda dose é administrada no dia 69 (destacado em vermelho no eixo x), considerando o acompanhamento longitudinal descrito em VOYSEY *et al.* (2023). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

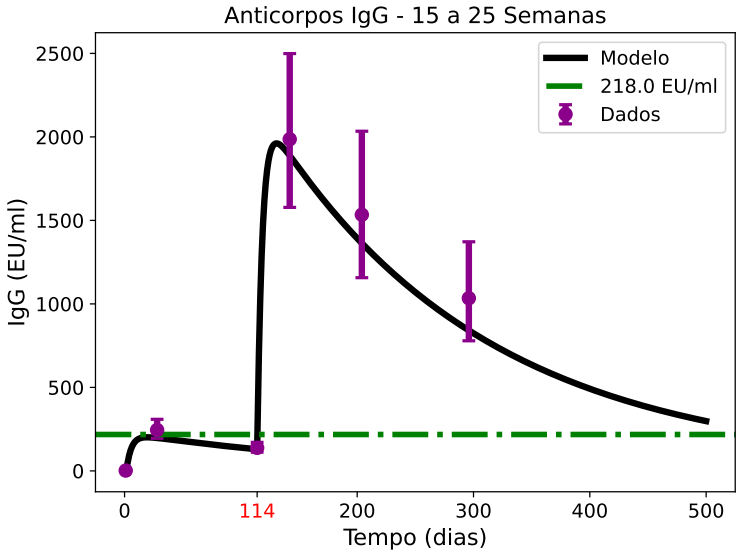

Figura 33: – Simulação do modelo (linha preta contínua) comparada aos dados experimentais (pontos em roxo com barras de erro) para o regime de vacinação com duas doses e intervalo de 15 a 25 semanas. A simulação utiliza o conjunto de parâmetros padrão (média das observações aceitas), previamente calibrado com base no cenário de duas doses com intervalo de 8 a 12 semanas, não havendo ajuste adicional para este regime. A segunda dose é administrada no dia 114 (destacado em vermelho no eixo x). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

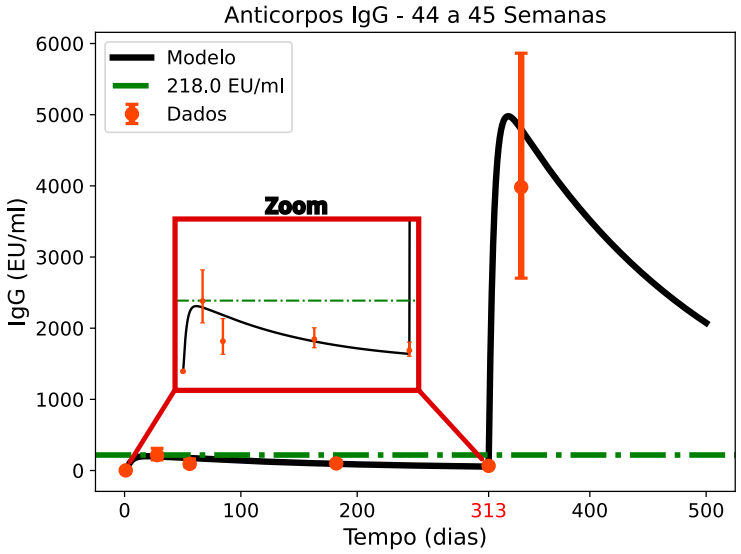

Figura 34: – Simulação do modelo (linha preta contínua) comparada aos dados experimentais (pontos em laranja com barras de erro) para o regime de vacinação com duas doses e intervalo de 44 a 45 semanas. A simulação utiliza o conjunto de parâmetros padrão (média das observações aceitas), previamente calibrado com base no cenário de duas doses com intervalo de 8 a 12 semanas, não havendo ajuste adicional para este regime. A segunda dose é administrada no dia 313 (destacado em vermelho no eixo x). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL. O quadro em destaque apresenta um zoom da dinâmica da resposta imune após a segunda dose, permitindo melhor visualização do comportamento do modelo em comparação com os dados.

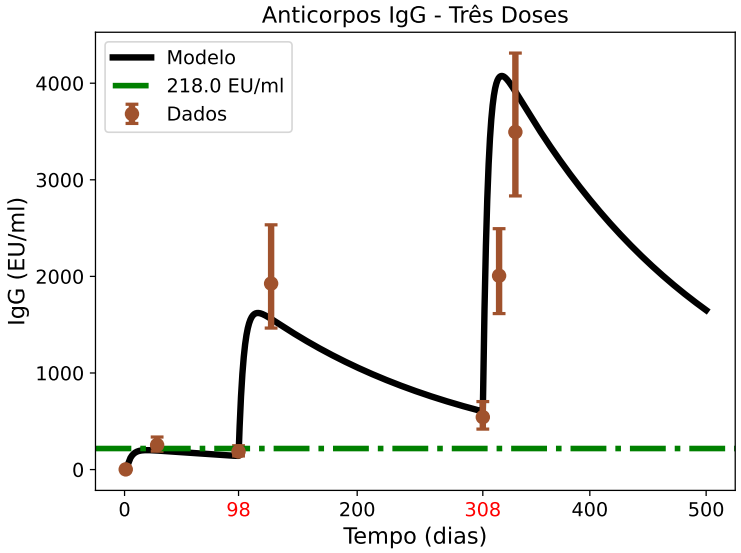

Figura 35: – Simulação do modelo (linha preta contínua) comparada aos dados experimentais (pontos em marrom com barras de erro) para o regime de vacinação com três doses. A simulação utiliza o conjunto de parâmetros padrão (média das observações aceitas), previamente calibrado com base no cenário de duas doses com intervalo de 8 a 12 semanas, não havendo ajuste adicional para este regime. As doses são administradas nos dias 98 e 308 (destacados em vermelho no eixo x). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

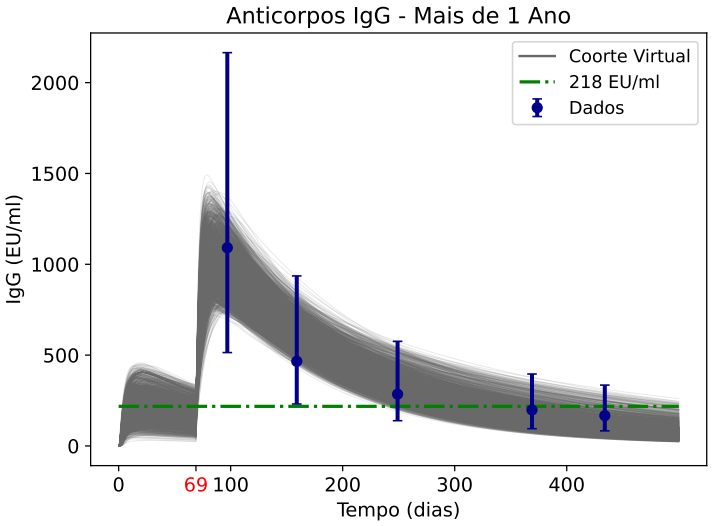

Figura 36: – Simulação do modelo utilizando 2.000 observações selecionadas aleatoriamente entre as 16.064 geradas no ajuste de parâmetros, todas apresentando erro relativo inferior a 5%. Os pontos destacados em azul representam os dados de indivíduos e são exibidos para evidenciar a pequena diferença em relação às previsões do modelo, especialmente após a administração da segunda dose no dia 69 (considerando o intervalo de 8 a 12 semanas entre doses e o acompanhamento por mais de um ano, conforme descrito no artigo de base (VOYSEY *et al.*, 2023)). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

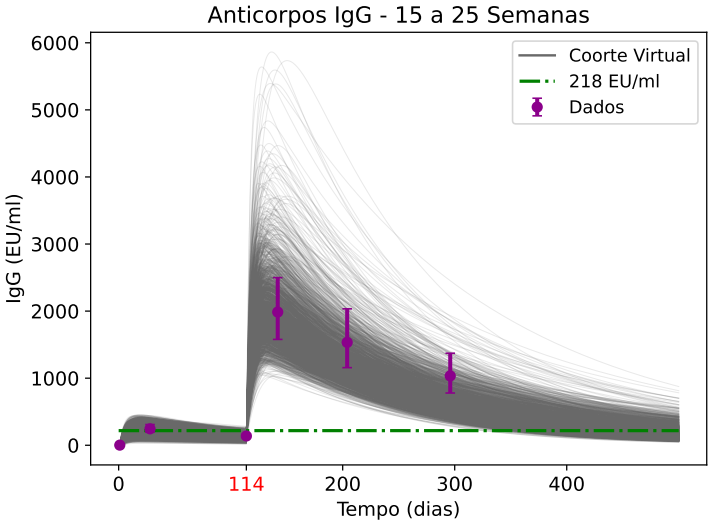

Figura 37: – Simulação do modelo utilizando 2.000 observações selecionadas aleatoriamente entre as 16.064 geradas no ajuste de parâmetros, todas apresentando erro relativo inferior a 5%. Os pontos destacados em roxo representam os dados de indivíduos e são exibidos para evidenciar a pequena diferença em relação às previsões do modelo, especialmente após a administração da segunda dose no dia 114 (considerando o intervalo de 15 a 25 semanas entre doses como descrito no artigo de base (FLAXMAN *et al.*, 2021)). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

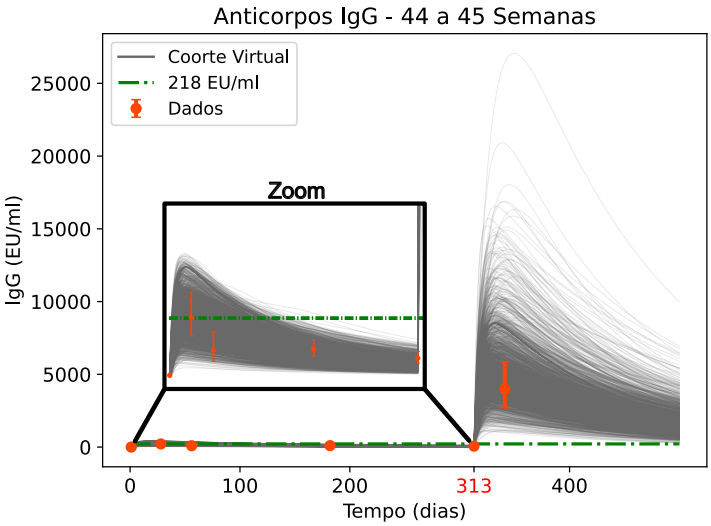

Figura 38: – Simulação do modelo utilizando 2.000 observações selecionadas aleatoriamente entre as 16.064 geradas no ajuste de parâmetros, todas apresentando erro relativo inferior a 5%. Os pontos destacados em laranja representam os dados de indivíduos e são exibidos para evidenciar a pequena diferença em relação às previsões do modelo, especialmente após a administração da segunda dose no dia 313 (considerando o intervalo de 44 a 45 semanas entre doses como descrito no artigo de base (FLAXMAN *et al.*, 2021)). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL. O quadro em destaque apresenta um zoom da dinâmica da resposta imune após a segunda dose, permitindo melhor visualização da distribuição das trajetórias simuladas nesse período.

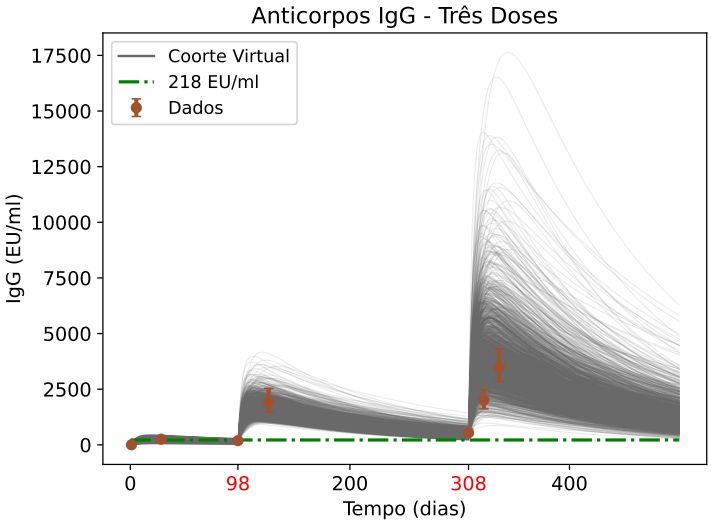

Figura 39: – Simulação do modelo utilizando 2.000 observações selecionadas aleatoriamente entre as 16.064 geradas no ajuste de parâmetros, todas apresentando erro relativo inferior a 5%. Os pontos destacados em marrom representam os dados de indivíduos e são exibidos para evidenciar a pequena diferença em relação às previsões do modelo, especialmente após a administração das doses de reforço nos dias 98 e 308 (considerando o regime de três doses descrito no artigo de base (FLAXMAN *et al.*, 2021)). A linha tracejada verde indica o limiar de proteção de 218,0 EU/mL.

B APÊNDICE B – Resultados adicionais da análise de sensibilidade de Sobol

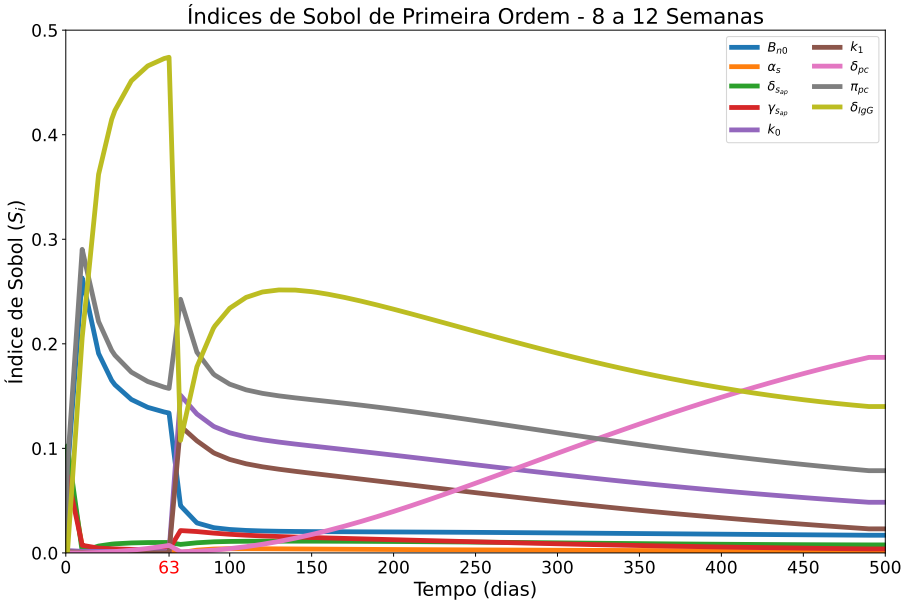

Figura 40: – Índices de Sobol de primeira ordem para o regime de duas doses da vacina ChAdOx1 nCoV-19, com intervalo de 8 a 12 semanas entre as doses. O marcador vermelho no eixo x indica a segunda dose (dia 63). As linhas contínuas acompanham a sensibilidade temporal de cada parâmetro. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com queda acentuada imediatamente após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente no período pós-vacinação. A população de células B *naïve* (B_{n0}, azul) apresenta maior influência nos estágios iniciais, enquanto parâmetros associados à resposta de memória tornam-se mais relevantes em estágios posteriores. Observa-se que a dinâmica de sensibilidade reflete os padrões imunológicos esperados para intervalos mais curtos entre doses.

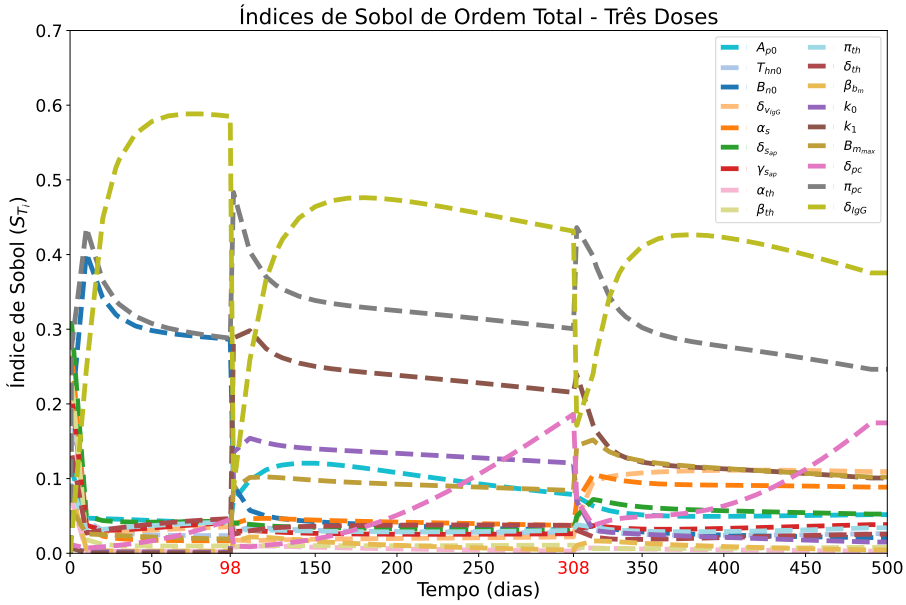

Figura 41: – Índices de Sobol de ordem total para o regime de três doses da vacina ChAdOx1 nCoV-19. Os marcadores vermelhos no eixo x indicam a segunda (dia 98) e a terceira (dia 308) doses. As linhas tracejadas representam a sensibilidade temporal de cada parâmetro considerando os efeitos totais, incluindo interações entre parâmetros. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com variações após cada dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente após o reforço. Observa-se ainda que os padrões gerais de sensibilidade acompanham aqueles obtidos para os índices de primeira ordem, indicando baixa interação entre os parâmetros dominantes.

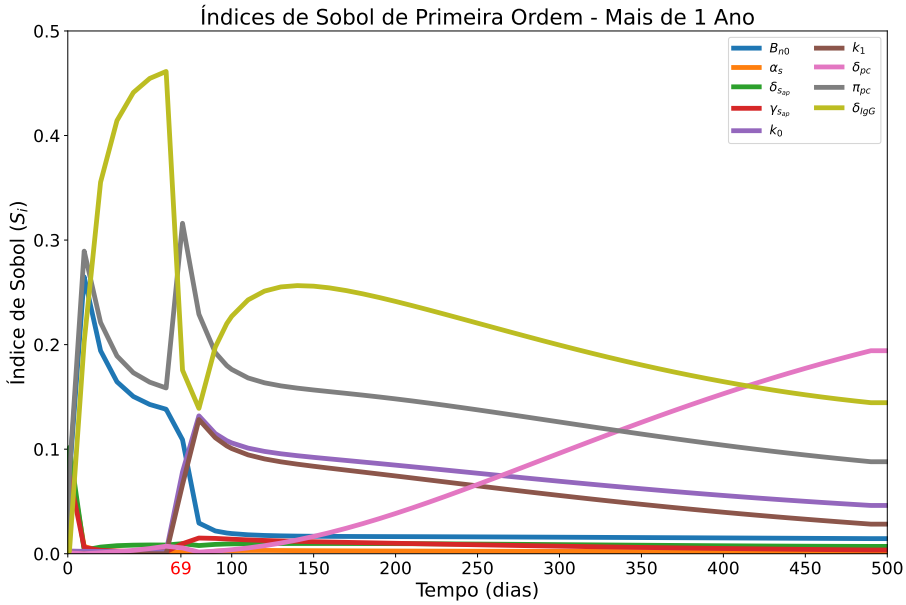

Figura 42: – Índices de Sobol de primeira ordem para o regime de duas doses da vacina ChAdOx1 nCoV-19, com acompanhamento superior a um ano após a segunda dose. O marcador vermelho no eixo x indica a segunda dose (dia 69). As linhas contínuas acompanham a sensibilidade temporal de cada parâmetro. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com queda acentuada imediatamente após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente no período pós-vacinação. A população de células B *naïve* (B_{n0}, azul) apresenta maior influência nos estágios iniciais, enquanto parâmetros associados à resposta de memória tornam-se mais relevantes em estágios posteriores. Observa-se que a dinâmica de sensibilidade reflete os padrões imunológicos esperados para respostas de longo prazo.

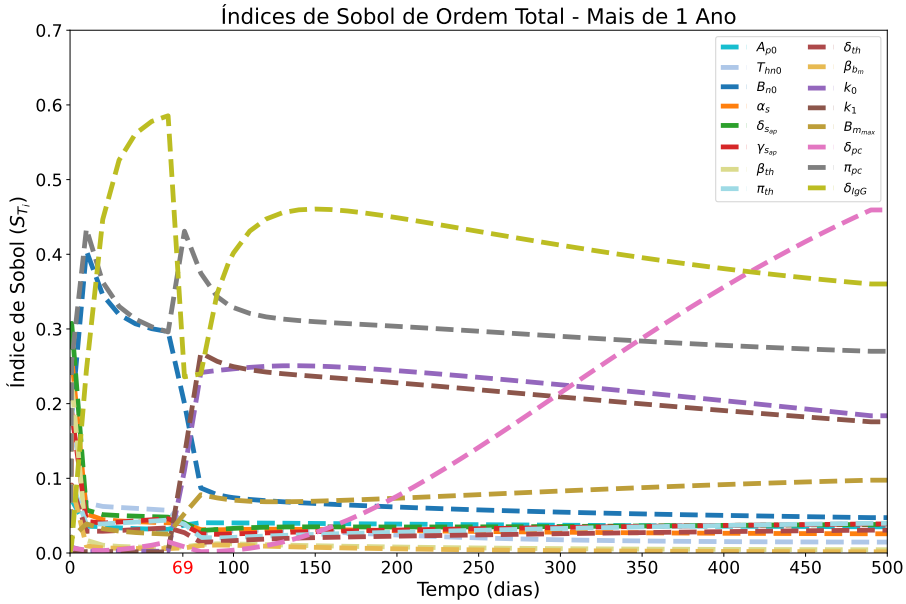

Figura 43: – Índices de Sobol de ordem total para o regime de duas doses da vacina ChAdOx1 nCoV-19, com acompanhamento superior a um ano após a segunda dose. O marcador vermelho no eixo x indica a segunda dose (dia 69). As linhas tracejadas representam a sensibilidade temporal de cada parâmetro considerando os efeitos totais, incluindo interações entre parâmetros. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com variações após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente no período pós-vacinação. Observa-se ainda que os padrões gerais de sensibilidade acompanham aqueles obtidos para os índices de primeira ordem, indicando baixa interação entre os parâmetros dominantes.

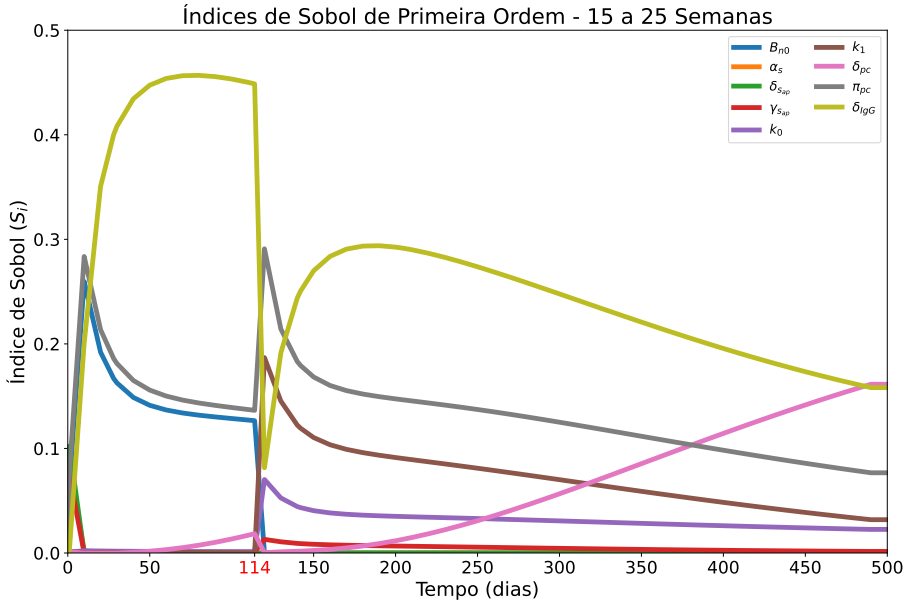

Figura 44: – Índices de Sobol de primeira ordem para o regime de duas doses da vacina ChAdOx1 nCoV-19, com intervalo de 15 a 25 semanas entre as doses. O marcador vermelho no eixo x indica a segunda dose (dia 114). As linhas contínuas acompanham a sensibilidade temporal de cada parâmetro. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com queda acentuada imediatamente após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente no período pós-reforço. A população de células B *naïve* (B_{n0}, azul) apresenta maior influência nos estágios iniciais, enquanto parâmetros associados à resposta de memória tornam-se mais relevantes em estágios posteriores. Observa-se que a dinâmica de sensibilidade reflete os padrões imunológicos esperados para intervalos intermediários entre doses.

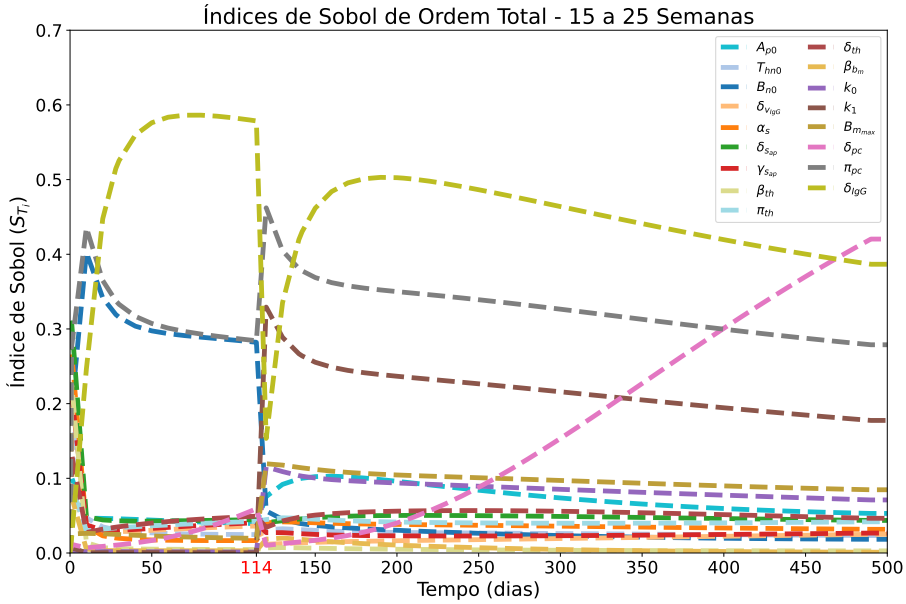

Figura 45: – Índices de Sobol de ordem total para o regime de duas doses da vacina ChAdOx1 nCoV-19, com intervalo de 15 a 25 semanas entre as doses. O marcador vermelho no eixo x indica a segunda dose (dia 114). As linhas tracejadas representam a sensibilidade temporal de cada parâmetro considerando os efeitos totais, incluindo interações entre parâmetros. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com redução momentânea após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente após a segunda dose. Observa-se ainda que os padrões gerais de sensibilidade acompanham aqueles obtidos para os índices de primeira ordem, indicando baixa interação entre os parâmetros dominantes.

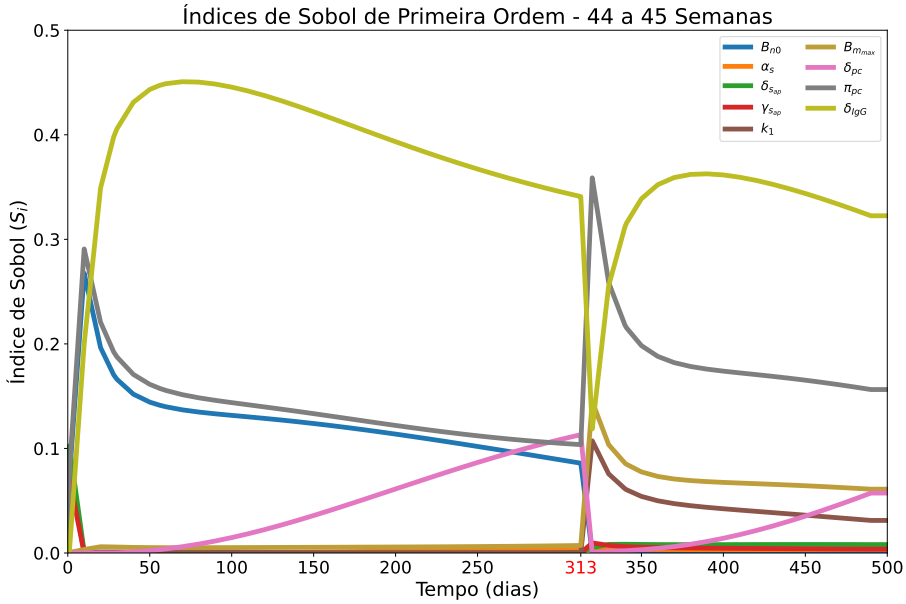

Figura 46: – Índices de Sobol de primeira ordem para o regime de duas doses da vacina ChAdOx1 nCoV-19, com intervalo de 44 a 45 semanas entre as doses. O marcador vermelho no eixo x indica a segunda dose (dia 313). As linhas contínuas acompanham a sensibilidade temporal de cada parâmetro. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com queda acentuada imediatamente após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente no período pós-reforço. A população de células B *naïve* (B_{n0}, azul) apresenta maior influência nos estágios iniciais, enquanto parâmetros associados à resposta de memória tornam-se mais relevantes em estágios posteriores. Observa-se que a dinâmica de sensibilidade reflete os padrões imunológicos esperados para intervalos prolongados entre doses.

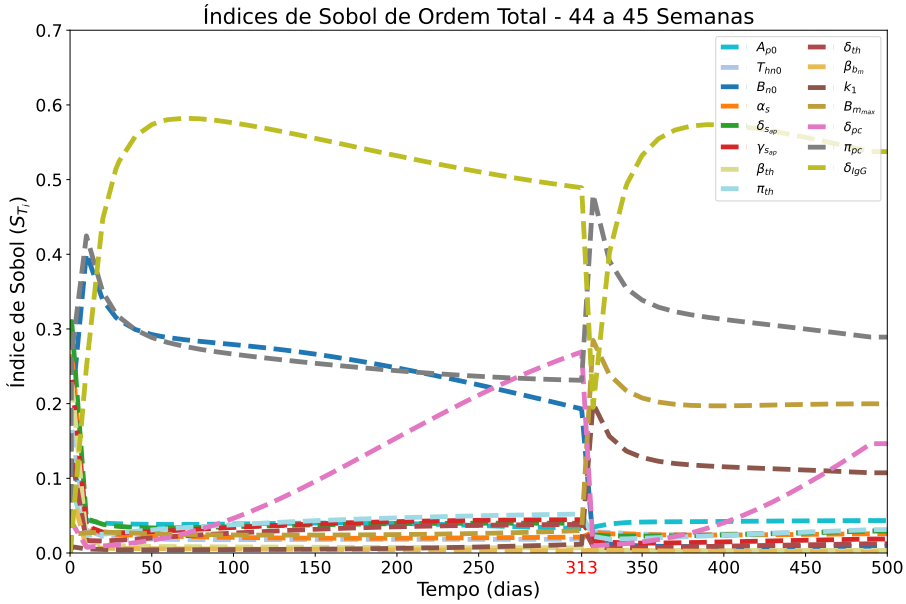

Figura 47: – Índices de Sobol de ordem total para o regime de duas doses da vacina ChAdOx1 nCoV-19, com intervalo de 44 a 45 semanas entre as doses. O marcador vermelho no eixo x indica a segunda dose (dia 313). As linhas tracejadas representam a sensibilidade temporal de cada parâmetro considerando os efeitos totais, incluindo interações entre parâmetros. São exibidos apenas aqueles que excedem um índice de Sobol de 0,07 em algum ponto do tempo simulado (500 dias). A taxa de decaimento do IgG (δ_{IgG}, amarelo) apresenta elevada influência ao longo de todo o período, com redução momentânea após a administração da segunda dose. A taxa de produção de IgG pelas células plasmáticas (π_{pc}, cinza) mantém contribuição relevante, especialmente após a segunda dose. Observa-se ainda que os padrões gerais de sensibilidade acompanham aqueles obtidos para os índices de primeira ordem, indicando baixa interação entre os parâmetros dominantes.